یادگیری ماشین – دکتر ناظرفرد – بهار ۹۹-۰۰

میان ترم (۲۰ تا ۲۵) | پایان ترم (۳۰ تا ۳۵) | تمرینات (۲۰ تا ۲۵)

پروژه (۱۵ تا ۲۰) | ارائه کوتاه (۵٪) | حضور و فعالیت کلاسی هم مهمه

جلسه دوم – ۱۳۹۹/۱۲/۵

۳ شرط استفاده از ML :

① یه الگویی وجود داشته باشه

② نتونیم با مدل سازی ریاضی اون پدیده رو فرموله کنیم

③ داده وجود داشته باشه

انواع الگوریتم‌های یادگیری ماشین :

① یادگیری تحت نظارت / با معلم ② یادگیری بدون نظارت / بدون معلم ③ یادگیری تقویتی

④ یادگیری نیمه تحت نظارت ← یه سری داده‌ی برچسب دار داریم : ground truth
(semi-supervised learning)

⑤ یادگیری عمیق (deep learning)

⑥ یادگیری از طریق انتقال (Trans Fer learning) ← مثلا یه agent داریم که فوتبال بلده حالای خواهیم هندبال یاد بگیره

⑦ یادگیری فعال (Active learning)

⑧ پیش‌بینی چند برچسبی (Multilable prediction)

کاربردهای ML :

تصویر / تشخیص صوت / NLP / تشخیص ناهنجاری / بیوانفورماتیک / تشخیص و بلاک spam

تشخیص کیفیت خراب

جلسه سوم - ۱۰/۱۲/۱۳۹۹

رگرسیون خطی

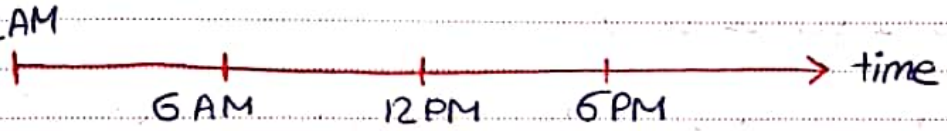
وقتی از یادگیری با معلم (تحت نظارت) ← اگر معلمی داریم که در مورد یک سری از داده‌ها مقدار متناظرشون (خروجی مطلوب) رو مشخص می‌کنه

دیگه می‌شه خطی ← متغیر هدف یک مقدار عددی است

اگر متغیر هدف یک label (دسته) باشد ← دسته‌بندی

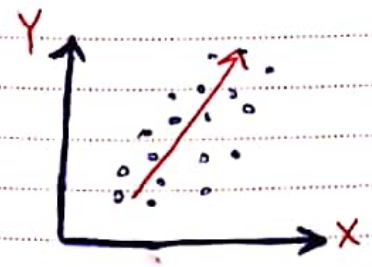
← متغیرهای پیوسته VS گسسته

← نکته: بیایم متغیرهای پیوسته رو گسسته سازی کنیم. مثال: گسسته کردن زمان



Francis Galton ← اولین بار مفهوم رگرسیون را ابداع کرد و هم‌چنین مفهوم Correlation

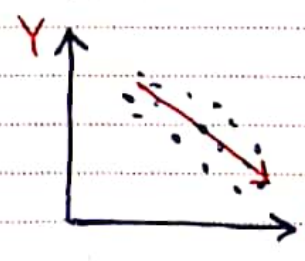
Correlation: هم بستگی بین داده‌ها، یک جور فرض نهفته است در تمام مسائل یادگیری ماشین. اینکه چون متغیر هدف با سایر متغیرها هم بستگی دارد می‌توانیم آن را به کمک سایر متغیرها پیش بینی کنیم.



مثبت Correlation ✓



0 = Correlation ✗



منفی Correlation ✓

Scanned with CamScanner

یکشنبه | 22 March 2020

ترمول محاسبه همبستگی:

$$\rho_{XY} = \frac{Cov(X,Y)}{\sigma_X \sigma_Y} = \frac{E[(X-\mu_X)(Y-\mu_Y)]}{\sigma_X \sigma_Y} \qquad -1 \leq \rho_{XY} \leq 1$$

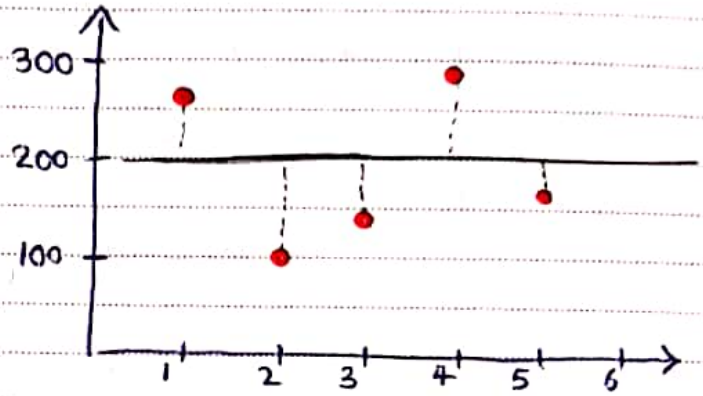
↳ Correlation(X, Y)

مثال: پیش بینی قیمت خانه

(House price prediction)

Training Data

	price
1	260
2	100
3	140
4	290
5	210



سوال: قیمت خانه‌ی ششم چقدر است؟ ← یک راه حل: میانگین گیری از ۵ جواب داده شده

← نکته: با اینکه این جا رفتار سیستمی دیده می‌شود اما نباید به آن توجه کرد چون ترتیب داده‌ها در مسائل ML مهم نیست.

residaul error; = خطای باقی مانده $= \bar{y} - y^i$

جواب high bias یعنی حافظه نیست تفاوتش را عوض کند، خیلی یک دنده و کوچ هست مثلا اگه ۵۰۰۰ داده دارید، تعدادی از داده‌های آموزش را که تغییر بدهید، جواب فرق چندانی نمی‌کند.

← کلا میانگین آماری high bias است.

سوال: چرا شلال بحث می‌کنیم؟ چون شاهدی نداریم و اینکه درحالتی که دلیلی نداریم، بین مدل ساده و پیچیده تمایل‌مان به مدل ساده بیشتر است.

Scanned with CamScanner

۱۳۹۹

Training Data

m : تعداد داده های آموزش

n : تعداد ویژگی ها

متراژ با قیمت خانه Correlation مثبت دارد ، عربنا با قیمت خانه Correlation منفی دارد

در مسئله رگرسیون هدفمون اینه که یک فرضیه (hypothesis) (تابع) رای خواهیم یادبگیریم

$$h: X \longrightarrow \mathbb{R}$$

اگر رگرسیون خطی باشد مجموعه جواب هایی که داریم:

$$h(x) = \theta_0 + \theta_1 x$$ hypothesis space

ازین بی نهایت خطی خواهیم بهترین خطی رابیابیم که به داده های ما fit شود.

یک مدل پارامتریک است که ی خواهیم پارامترهای θ_0 و θ_1 را یادبگیریم

یک اصل در ML : مدل های ساده مدل های بهتری هستند چون تعمیم پذیری بیشتری دارند.

چگونه پارامترها رایادبگیریم ؟

یک مسئله بهینه سازی

تابع هزینه (cost)

$$\underset{\theta_0,\theta_1}{\text{minimize}} \quad \frac{1}{(2)m} \sum_{i=1}^{m} \left(h(x^i) - y^i\right)^2$$ MSE

(برای اینکه اگر بعدا خواستیم مشتق بگیریم ساده شود) (برای اینکه بزرگ نشود)

L2 LOSS ← چون با توان ۲ علامت را ازبین بردیم

اگر با قدر مطلق باشد ← L1 (MAE)

۲ روش برای min کردن تابع هزینه :

① روش تکراری (iterative) ← روش گرادیان نزولی (iterative Gradient Descent)

② روش معادله نرمال (Non_iterative Normal Equation)

عید نوروز (تعطیل)

Scanned with CamScanner

الگوریتم گرادیان نزولی ساده شده:

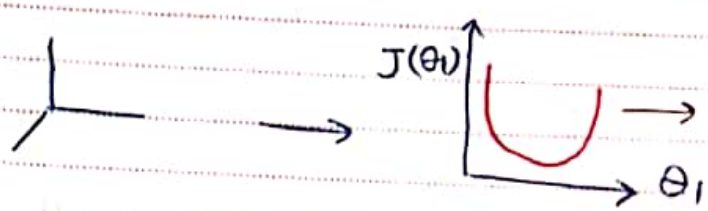
برای سادگی فرض می کنیم که $\theta_0 = 0$ ← ۳ بعدی تبدیل به ۲ بعدی می شود

θ_1 را مقداردهی اولیه می کنیم

این مرحله را آنقدر تکرار می کنیم که همگرا شود:

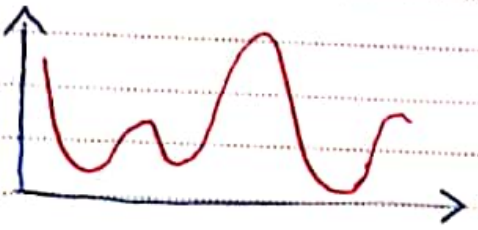
$$\theta_1 \leftarrow \theta_1 - \alpha \frac{d}{d\theta_1} J(\theta_1) \qquad (\alpha > 0)$$

α ضریب یادگیری است



تابع Convex

Convergence (همگرایی): یعنی در تکرارهای متوالی θ_1، تغییرات کمی داشته باشیم (می توانیم در مقدار تابع هزینه یک دقت در نظر بگیریم)

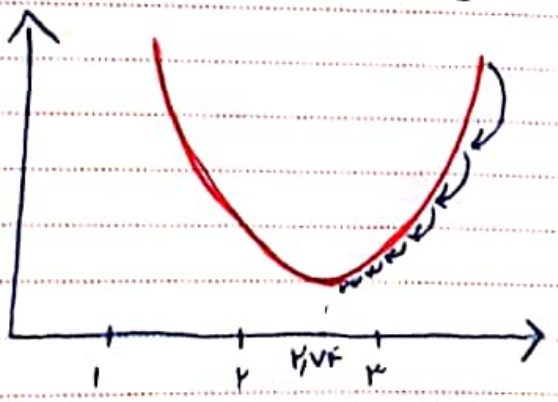


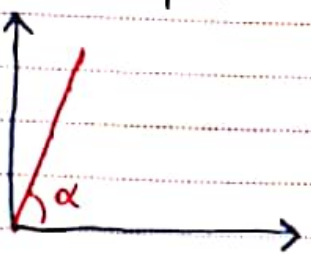
سوال: آیا ممکن است این شکل اتفاق بیفتد؟

خیر. در این شکل تابع خیلی پیچیده است

اما در رگرسیون خطی تابع ما نسبت به θ درجه ۲ هست. تابع هزینه نسبت به θ درجه ۲ هست

(Quadratic) و یک مینیمم هم بیشتر ندارد.





شهود: وقتی سمت راست Convex هستیم α و شیب مثبت اند و باعث می شوند θ_1 کمتر بشود

وقتی سمت چپ هستیم α مثبت و شیب منفی است ← θ_1 زیاد می شود

یه سیاست خوب برای تعیین α این است که در طول زمان آن را کاهش بدهیم

Scanned with CamScanner

رگرسیون خطی چند متغیره:

$$h(x) = \theta_0 + \theta_1 x_1 + \dots + \theta_n x_n$$

where $x = [x_1, x_2, \dots, x_n]^T$ ← T برای اینکه ستونی باشد ← بردار ویژگی ها

Feature Engineering

مثلا فیچرها را بیاوریم در یک محدوده مشخص ، یا مثلا اینکه ویژگی هایی که تاثیری ندارند حذف کنیم و...

Feature Selection ← یعنی یک سری از ویژگی ها را به عنوان بهترین ها انتخاب کنیم

↳ در این جا نیاز به Domain Expert داریم

Feature Extraction ← یعنی در یک سری از سناریو به این نتیجه برسیم که بهتره به سری از ویژگی را استخراج کنیم مثلا از طول و عرض ، مساحت را بسازیم یا مثلا بعضی مواقع توان دو

بعضی ویژگی ها بهتر از خود ویژگی نه. ← polynomial Features

Dimensionality Reduction ← کاهش ویژگی های غیر ضروری

PCA شناخته شده ترین هست ، Auto Encoders و ...

Representation Learning

جلسه چهارم ـ ۱۳۹۹/۱۲/۱۲

$$\theta^{k+1} \leftarrow \theta^k - \alpha \nabla_\theta J(\theta)$$

$$\nabla_\theta J(\theta) = \begin{bmatrix} \frac{\partial}{\partial \theta_0} J(\theta) \\ \frac{\partial}{\partial \theta_1} J(\theta_1) \\ \vdots \\ \frac{\partial}{\partial \theta_n} J(\theta) \end{bmatrix}$$

بردار گرادیان

ما در خلاف جهت بردار گرادیان حرکت می کنیم

تغییر می تواند به صورت سنکرون یا آسنکرون صورت بگیرد.

الگوریتم از مقدار آپدیت شده استفاده کنیم آسنکرون است

Scanned with CamScanner

چگونه از داده های آموزش استفاده کنیم؟ (داده ها را تُری زنند)

معمولا بین ۶۰ تا ۷۰ درصد داده به عنوان آموزش استفاده می‌شود و بقیه داده را به عنوان تست استفاده می‌کنیم. به این روش Holdout گفته می‌شود.

polynomial Regression (رگرسیون چند جمله‌ای)

دقت کنید که هم‌چنان univariate است اما غیرخطی است (univariate non_linear)

$$h(x) = \theta_0 + \cdots + \theta_i x^i + \cdots + \theta_d x^d$$

x تبدیل شده به بردار

در حالت پایین بیش از یک

$$h(x) = \theta_0 + \cdots + \theta_i x_i + \cdots + \theta_d x_d$$

دیتاکی داریم و x به بردار تبدیل شده

مدل‌مان غیرخطی است اما داریم به صورت خطی باهاش برخورد می‌کنیم

یک مثال از رفتن به ابعاد بالاتر:

a) $\theta_0 + \theta_1 x + \theta_2 x^2 = h(x)$

روز هنرهای نمایشی

b) $\theta_0 + \theta_1 x + \theta_2 x_2 = h(x)$

فروردین | ۸ | جمعه

۲ شعبان ۱۴۴۱

27 March 2020

فرض کنید حالت b را به همان روش گرادیان نزولی به دست می‌آوریم

فرض کنید جواب (حالت min) برابر $(\theta_0, \theta_1, \theta_2) = (1, 0, 1)$

شود.

$y = x_2 + 1$ ← بازگشت به فضای اولیه ← $y = x^2 + 1$

جواب حالت b

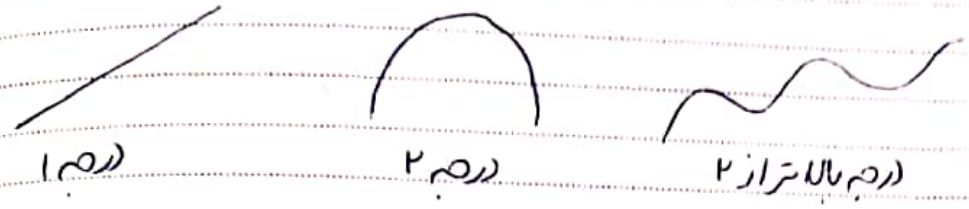
جواب حالت a

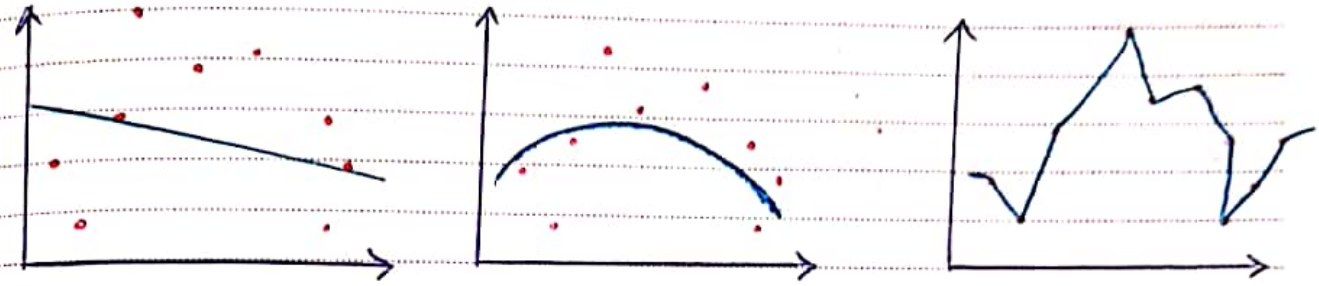
در رگرسیون چند جمله‌ای علاوه بر θ_iها درجه چند جمله‌ای (d) هم به عنوان یک پارامتر اضافه شده است، اما درجه چند جمله‌ای با پارامترهای قبلی متفاوت است. یعنی پارامتری است که ما ازابتدا باید مقدار آن را داشته باشیم تا بتوانیم حالت کلی مدل را بسازیم. به چنین پارامترهایی یک ابرپارامتر (hyper_parameter) می‌گویند.

Scanned with CamScanner

نیست. یعنی همان اول باید set شود.

به این مرحله که d های مختلف set می‌کنیم تا انتخاب کنیم کدام بهتر است، Model Selection می‌گوییم.





کدام یک از مدل های بالا بهتر است؟

مدل سمت چپی با توجه به پیچیدگی ای که داده ها دارند به نظری رسد که آن خط نتوانسته پیچیدگی داده ها را مدل کند (دست کم گرفته پیچیدگی داده ها را) ← under fit (کم برازش) گیره

مدل سمت راست اصلا داده ها را یاد نگرفته، داده ها را حفظ کرده! انقدر پیچیدگی مدل را زیاد کرده که آمده کل داده ها را دقیقاً یاد گرفته (حفظ کرده) ← over fit (بیش برازش)

مدل وسطی آمده به ازای کلی از داده ها یاد گرفته، به نظری رسد که این مدل، مدل بهتری است به منظور ست ← best fit

با توجه به اضافه شدن هایپر پارامتر d، دو مرحله یادگیری داریم:

① انتخاب مدل (Model Selection) ← d ← ابتدا باید انجام شود

② یادگیری پارامترها (parameter Learning) ← θ_iها

 با توجه به این نیاز فندی به این نتیجه می رسیم که داده ها عین رابه ۲ بخش

تقسیم بکنیم بلکه به ۳ بخش تقسیم کنیم:

① داده‌های آموزش (Training Data) ← حدود ۶۰٪ ← برای یادگرفتن پارامترهای θ_i

② داده‌های اعتبارسنجی (جهت سنجی) (Validation Data) ← حدود ۲۰٪

از این داده‌ها برای انتخاب مدل استفاده می‌کنیم

③ داده‌های تست (Test Data) ← حدود ۲۰٪

d	Hypothesis	Type	parameter Learning $\min J_{tr}(\theta)$	Error on validation data
1	$h(x)=\theta_0+\theta_1 x$	linear	$\theta_1=[\theta_0,\theta_1]^T$	$J_{cv}(\theta_1)$
2	$h(x)=\theta_0+\theta_1 x+\theta_2 x^2$	quadratic	$\theta_2=[\theta_0,\theta_1,\theta_2]^T$	$J_{cv}(\theta_2)$
3	$h(x)=\theta_0+\theta_1 x+\theta_2 x^2+\theta_3 x^3$	cubic	$\theta_3=[\theta_0,\theta_1,\theta_2,\theta_3]^T$	$J_{cv}(\theta_3)$
⋮	⋮	⋮	⋮	⋮

برای انتخاب مدل بهترین $J_{cv}(\theta_i)$ ها min را انتخاب می‌کنیم:

$$d=\arg\min_k J_{cv}(\theta_k)$$

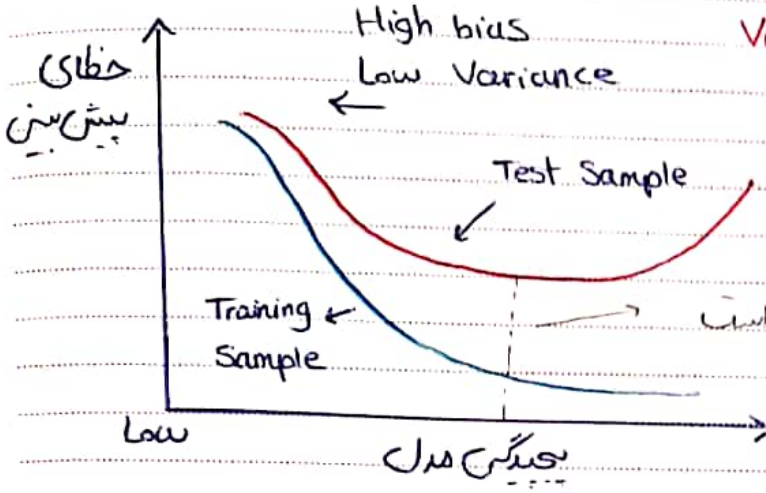
منظور در مورد دلیل استفاده از Validation Data:

در مسابقات داده‌کاوی این شرط را می‌گذارند که در هر روز تعداد خروجی می‌توان از داده تست استفاده کرد چون اگر زیاد استفاده شود مثل این است که از داده‌های تست برای یادگیری مدل استفاده شده باشد پس ما به جای از داده‌های validation هر تعداد بار که می‌خواهیم استفاده می‌کنیم.

نکته: مدلی که under fit است یعنی high bias است یعنی خیلی حاضر نیست تغییر را عوض کند. مدل overfit است یعنی high variance یعنی به ازای داده‌های مختلف خیلی تغییر می‌کند.

Scanned with CamScanner

مصالحه بین bias و Variance



دو جور خطا:

خطا آتی: خطای زمان آموزش

هرچقدر پیچیدگی مدل زیادی شود خطای زمان آموزش کمتری شود

خط قرمز: خطای داده‌های تست

از داده‌های validation یا تست (هرکدام دردسترس بود) استفاده می‌کنیم و مشاهده می‌کنیم از ابتدا خطای مدل شروع به کاهش می‌کند تا یک جایی، اما از آن جا به بعد خطا زیادی شود (مشکل over fitting دارد رخ می‌دهد)

تعاریف Bias:

تعریف ۱: احتمال اینکه مدل نظرش را عوض نکند.

ممکن است این ذهنیت به وجود بیاید که bias یک چیز مذمتی است اما اینطور نیست

تعریف ۲: اینکه چگونه یک الگوریتم یادگیری ماشین را در مسیری سوق بدهیم که مدل مان نسبت به یک سری رفتارها بی‌توجه (کم‌توجه‌تر) باشد. (مثال: Regularization, maximizing margins)

مثلا یک تغییری در cost function بدهیم که مدل از over fitting اجتناب کند.

در واقع خود ما این تغییرات را می‌دهیم و مدل را force می‌کنیم که بی‌توجه باشد نسبت به برخی

ولادت امام سجاد (ع) (۳۸ هـ ق) از مسائل.

Scanned with CamScanner

تعریف ۳: هر الگوریتم یادگیری باید یک bias ای داشته باشد که بتونه بین مدل ها انتخاب کنه. نه اینکه تمام مدل های دنیا بشن hypothesis space اش. به این میگن inductive bias.

اگر بخواهیم bias را با یک کلمه بیان کنیم ← preference

تمایل مدل نسبت به یک سری حالت های خاص را دارد نشان می دهد ← این تمایل هم توسط یک شخص از بیرون اعمال شده روی الگوریتم.

Cross Validation

مشکل روش Holdout: مثلا فرض کنید بخشی از داده ها برای آموزش است و بخشی برای تست. اگر داده های آموزش دیتاهای خاصی داشته باشند یا ارتفاعها را براساس آنها یاد می گیرد. وقتی که داده های تست آن دیتاها را ندارند. یک راه shuffle کردن (بُر زدن) داده هاست. یک راه کلی تر و بهتر: به هر کدوم از بخش های داده، فرصت این را بدهیم که هم داده آموزش باشه هم داده تست. داده ها را به K بخش تقسیم می کنیم و به هر کدام fold می گوییم. یک fold را به عنوان آموزش در نظر می گیریم و k-1 فولد را به عنوان تست. در این صورت K تا نتیجه داریم و می آییم میانگین می گیریم. معمولا k=10 رایج است.

به حالت دیگه: Leave-one-out Cross validation ← برای داده های کم استفاده می شود

Dataset Bias

یک مشکل دیگه ای در مورد bias وجود داره و اینه که دیتاست bias باشه. مثلا وقتی در گوگل mug را سرچ می کنیم اکثر تصاویری که برمی گرداند دسته شان سمت راست است.

این امر موجب انحراف الگوریتم ما می شود. باید سعی کنیم تا جایی که ممکنه دیتاست بایاس نباشد.

روز جمهوری اسلامی ایران (تعطیل)

Scanned with CamScanner

Regularization

یکی از مثال های خوب در جهت اضافه کردن bias ، حالت مثبت اضافه کردن bias برای اجتناب از overfitting.

میایم تابع هزینه (cost function) را تغییری دهیم:

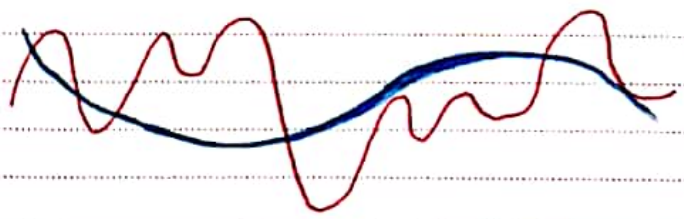
$$J(\theta) = \frac{1}{2m}\left[\sum_{i=1}^{m}(h(x^i) - y^i)^2 + \lambda \sum_{j=1}^{n} \theta_j^2\right]$$

اضافه کردن بخش قرمز باعث می شود از مدل های پیچیده اجتناب کنیم

چون وقتی داریم cost function را minimum کنیم ، جمله ی قرمز هم دارد min می شود و باعث می شود θ_j ها که ضرایب چند جمله ای هستند کم شوند و نمی تواند پیچیده شود

یعنی داریم جلوی زیاد شدن x های با توان بالا را می گیریم.

مثلا در شکل زیر مدل overfit با رنگ قرمز تبدیل به مدل آبی می شود که overfit نیست



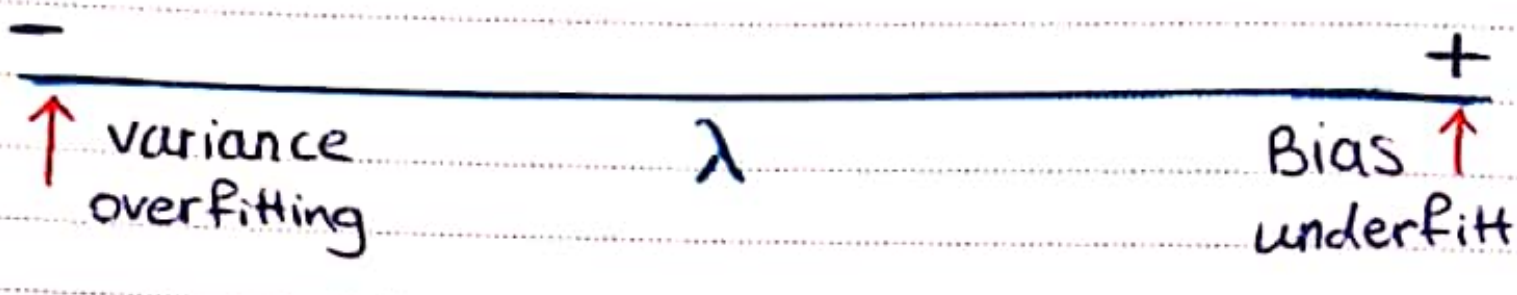
سوال: چگونه می توانیم جمله قرمز را هوشمندانه تر کنیم؟

چون هر چقدر درجه بیشتر شود این جمله خطرناک تر است در جهت overfitting. می توانیم یک ضریب j اضافه کنیم بدین صورت که مدل های متناظر با درجات بالاتر بیشتر جریمه شوند:

$$\lambda \sum_{j=1}^{n} j\theta_j^2$$

سوال: نقش ضریب λ چیست؟

به ضریب λ ، پارامتر Regularization می‌گویند



وقتی λ کم باشد اجتناب از overfitting کاهش پیدا می‌کند و داریم درگیر overfitting می‌شویم ولی وقتی λ را زیاد می‌کنیم باعث می‌شود θها خیلی کم شوند تا تابع هزینه min شود و مدل خیلی ساده و دچار underfitting می‌شویم.

Scanned with CamScanner

جلسه پنجم - ۱۳۹۹/۱۲/۱۷

هردوی روش های گرادیان نزولی و Normal Equation هم برای تک متغیره و هم چند متغیره کاربرد دارند

Normal Equation

$$h(x) = \theta_0 + \theta_1 x_1 + \cdots + \theta_n x_n$$

$$J(\theta_{0,\cdots,n}) = \frac{1}{2m} \sum_{i=1}^{m} \left(h(x^i) - y^i\right)^2$$ ← هدف: min کردن تابع هزینه

$$\theta = \begin{bmatrix} \theta_0 \\ \theta_1 \\ \vdots \\ \theta_n \end{bmatrix} \qquad x = \begin{bmatrix} x_0 = 1 \\ x_1 \\ \vdots \\ x_n \end{bmatrix}$$ ← x_0 فیچر هاست، فقط برای اینکه ابعاد θ, x یکی بشن

$$h(x) = \theta^T x$$

Design Matrix (ماتریس طراحی)

$$X_{m \times (n+1)} = \begin{bmatrix} (x^1)^T \\ (x^2)^T \\ \vdots \\ (x^m)^T \end{bmatrix}$$ ← داده آموزشی اول ... ← داده آموزشی m ام

ماتریس تابع هزینه می تواند این گونه هم نوشته شود:

$$J(\theta) = \frac{1}{2m} (X\theta - y)^T (X\theta - y)$$

اثبات:

$y = X\theta + \epsilon$ (هدف min کردن ϵ است)

$\epsilon = y - X\theta \longrightarrow \|\epsilon\| = \|y - X\theta\|$

$$\|\epsilon\|^2 = \|y - X\theta\|^2 = (y - X\theta) \cdot (y - X\theta) = (y - X\theta)^T (y - X\theta)$$

Scanned with CamScanner

$$J(\theta) = (y - X\theta)^T (y - X\theta) = ((X\theta)^T - y^T)(X\theta - y)$$

$$= (X\theta)^T X\theta - (X\theta)^T y - y^T X\theta + y^T y$$

$$= (X\theta)^T X\theta - 2(X\theta)^T y + y^T y$$

سوال: چرا $-(X\theta)^T y - y^T X\theta = -2(X\theta)^T y$ ؟

$X_{m\times(n+1)}$ $\quad \theta_{(n+1)\times 1} \Rightarrow X\theta_{m\times 1} \longrightarrow (X\theta)^T_{1\times m}$

$y_{m\times 1} \Rightarrow (X\theta)^T y \xrightarrow{\text{ابعادش}} 1\times 1 \longrightarrow$ اسکالر (عدد) است

$y^T_{1\times m}$ $X_{m\times(n+1)} \Rightarrow y^T X \xrightarrow{\text{ابعاد}} 1\times(n+1)$ $\quad y^T X\theta_{(n+1)\times 1} \xrightarrow{\text{ابعاد}} 1\times 1$ اسکالر

$X^T X$ یک ماتریس مربعی است $\quad \frac{\partial J}{\partial \theta} = 2X^T X\theta - 2X^T y = 0$ مشتق تابع هزینه نسبت به θ

اگر $X^T X$ وارون داشته باشد

$$\Rightarrow \boxed{\theta = (X^T X)^{-1} X^T y}$$

ما را به یک جواب تحویل به فرد (unique) می رساند اما اگر وارون پذیر نباشد از روش هایی مثل sudo inverse استفاده می شود که جواب های تقریبی می دهد و تحویل به فرد نیست جواب.

سوال: چه زمانی $X^T X$ وارون ندارد؟

① زمانی که ستون ها وابسته باشیم. (یعنی حداقل یکی ستون ها از بقیه مستقل نباشند)

روز سلامتی (یه دونه از ستون ها را بشود به صورت ترکیب خطی ستون های دیگه نوشت یعنی نمیشه خوب نیست)

② تعداد ستون ها خیلی بیشتر از تعداد سطرها باشد: $m \ll n$

ارزیابی مدل‌های رگرسیون

L_2 error : LSE → MSE → RMSE

برای اینکه خیلی بزرگ نشه

$$J(\theta) = \frac{1}{m}\sum_{i=1}^{m}(h(x^i) - y^i)^2$$

L_1 error : LAD → MAD

Least Absolute Deviation

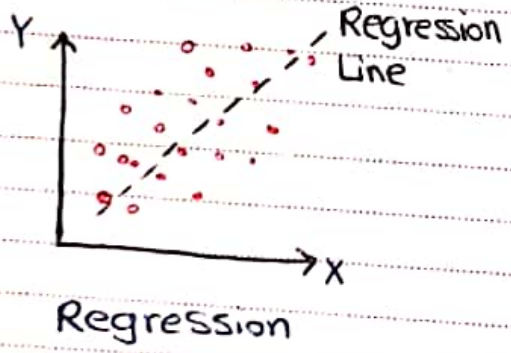
Mean Absolute Deviation

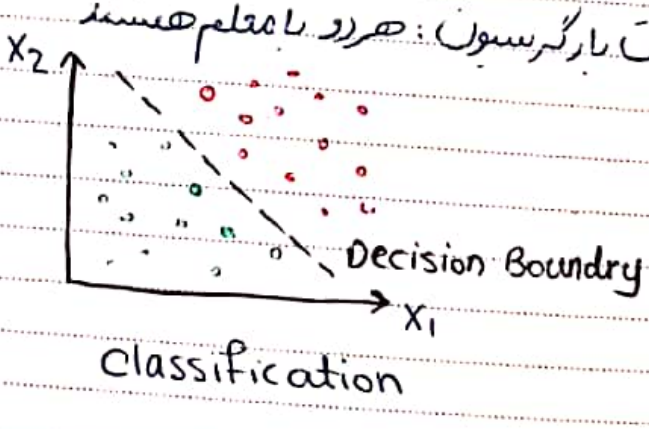
$$J(\theta) = \frac{1}{m}\sum_{i=1}^{m}|h(x^i) - y^i|$$

خطای MSE نسبت به داده‌های پرت حساسیت بیشتری دارد به همین دلیل از آن جذر می‌گیریم تا حساسیت آن نسبت به پرت کمتر شود ← RMSE

Classification (دسته‌بندی) ← هدف مسئله دسته‌بندی : بدست آوردن مرز تصمیم

شباهت با رگرسیون : هردو با معلم هستند





K_Nearest neighbors

Binary classification : $h: X \rightarrow \{+, -\}$

KNN یک الگوریتم instance_based است به این معنی که با خود داده‌ها سروکار دارد. داده‌های آموزشی بما داده شده و وقتی داده تست می‌آید، براساس اینکه به کدام داده‌های آموزشی نزدیکتر است پیش‌بینی می‌کنیم دسته‌ی تست را. معمولا تعداد فرد همسایگی گیرند مثلا ۳ نزدیکترین همسایه یا ۵ نزدیکترین همسایه و ...



دستمال روبه رو با ۳NN جواب مثبت است اما با ۵NN جواب مربع است. نشان دهنده حساسیت بالای الگوریتم های instance_based به خود داده‌هاست.

Scanned with CamScanner

به چنین الگوریتم هایی مانند KNN که فاز آموزش ندارند، lazy یا تنبل گفته می‌شود. موقتی الگوریتم کارش را شروع می‌کند که داده تست را به آن داده باشیم. در فاز آموزش کار خاصی نمی‌کند. در مقابل: الگوریتم های eager (مشتاق) الگوریتم هایی که، کار اصلی را در فاز آموزش انجام می‌دهند و وقتی داده تست می‌آید، سریع پاسخ می‌دهند

۲۰ | فروردین | ۱۴ شعبان ۱۴۴۱ | چهارشنبه | 8 April 2020 | ۱۳۹۹

انواع فاصله‌ها:

- فاصله اقلیدسی $$d(x, x') = \sqrt{\sum_i (x_i - x'_i)^2}$$

- KNN وزن دارد. مثلا در شکل قبلی با $K=5$، یکوبیم در سه تا که مقدار مثلث‌ها کمتره اما خیلی نزدیکترن به خاطر همین وزن بیشتری به آن‌ها بدهیم.

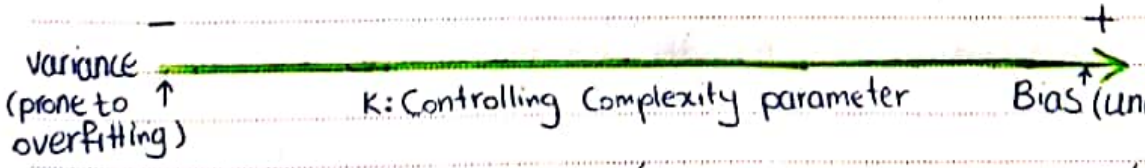
- فاصله منهتن، minkowski، cosine، chebyshev

یکی از ویژگی های KNN این است که Non_parametric است ← یعنی پارامتری نداریم که توزیع داده‌ها را به ما بدهد. کلا الگوریتم های instance_based پارامتری در مورد توزیع داده‌ها ندارند. مستقیم با خود داده‌ها کار می‌کنند.

پارامتر K در مورد KNN به توزیع داده‌ها ربطی ندارد، بلکه یک هایپرپارامتر است. (باید اول k را set کنیم و بعد با آن مسئله را حل کنیم)، پارامتر K، پیچیدگی الگوریتم را کنترل می‌کند

یکی از ویژگی های KNN ← scalable نیست ← برای داده‌های زیاد خوب عمل نمی‌کند. مثلا می‌خواهیم ۳ تا نزدیکترین همسایه را انتخاب کنیم باید فاصله داده تست را با همه‌ی داده‌ها حساب کنیم و بعد ۳ تا کمترین را انتخاب کنیم. پیچیدگی آن $O(m)$ است ← از مرتبه‌ی تعداد داده‌هاست

Bias_Variance tradeoff: پارامتر K و d هردو پیچیدگی الگوریتم را تعیین می‌کنند



وقتی K خیلی بزرگ باشد ← مثلا $K=m$ ← وقتی می‌خواهیم رأی‌گیری کنیم خواب. از قبل مشخص است و فرقی نمی‌کند که داده تست کجا قرار گرفته باشد. کلاس داده تست برابر کلاسی که بیشترین فراوانی را دارد می‌شود ← این همان تعریف bias است که الگوریتم نظرش را عوض نمی‌کند. (برعکس d)

روز ملی فناوری هسته ای

اگر K خیلی کوچک باشد ← variance و احتمال overfitting الگوریتم بالا می‌رود، بیش از حد به خود داده‌ها وابسته می‌شویم مثلا $k=1$ ← داده ای که در دیتاست است عمل است outlier باشد و الگوریتم را گمراه کند.

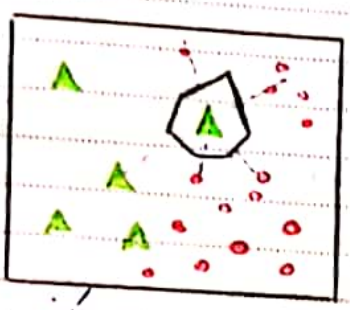
Scanned with CamScanner

جلسه ششم – ۱۳۹۹/۱۲/۱۹

prone to overfitting ← یعنی استعداد مدل برای overfit شدن

راه‌حلی که برای کمتر شدن زمان test در الگوریتم KNN به ذهن می‌رسد این است که قبل از اینکه داده بیاید مرز تصمیم (Decision boundry) مشخص کنیم. یعنی مشخص کنیم اگر داده در این ناحیه قرار گرفت کلاس آن چه خواهد شد.

Voronoi Cell



برای به دست آوردن Voronoi cell برای هر داده، عمود منصف خط واصل میان آن داده و همسایه‌هایش را رسم می‌کنیم و در اطراف آن داده یک چند ضلعی شکل می‌گیرد.

در این صورت دیگر نیازی نیست منتظر داده تست باشیم. دقت کنید که داریم در مورد INN صحبت می‌کنیم در اینجا.

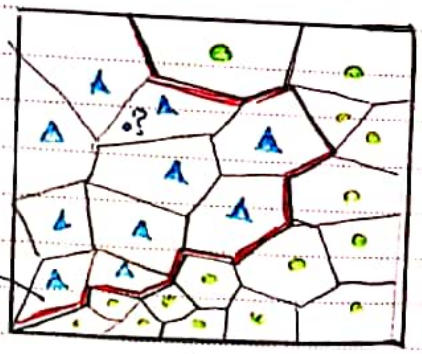
ولادت حضرت قائم (عج) (۲۵۵ هـ ق) (تعطیل) - روز جهانی مستضعفان

۲۲ فروردین جمعه

۱۶ شعبان ۱۴۴۱

10 April 2020

وقتی در مورد تمام داده‌ها Voronoi cell را رسم کنیم به چنین شکلی می‌رسیم



← مرز تصمیم

برای رسم مرز تصمیم، آن خطوطی را در نظر می‌گیریم که داده‌های دو طرفشان از دو کلاس متفاوت هستند

معایب این روش: ۱. رسم این Decision boundry پیچیده است و از مرتبه $O(m^2 \log m)$ است

۲. وقتی داده تست بیاید باید قانون پیچیده‌ای را اعمال کنیم تا کلاس آن مشخص شود. تعداد قوانینی که با هم and می‌شوند $O(m)$ است. (مثلا and کردن قوانین اینطور است که برای هر پاره خط در مرز تصمیم باید بگوییم داده تست از آن کوچکتر (یا بزرگتر) باشد و بعد این موارد را با هم and کنیم)

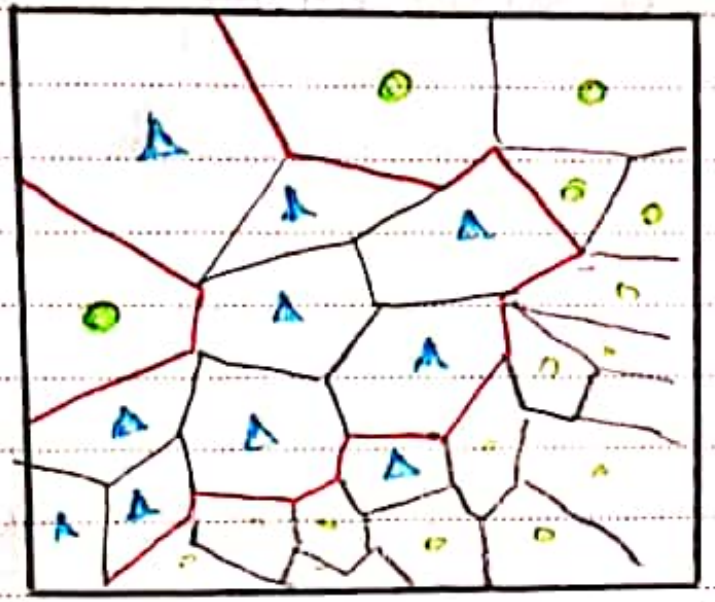
← مرز تصمیم در الگوریتم KNN پیچیده‌تر است.

Scanned with CamScanner

به دنبال مرز تصمیمی هستیم که smooth تر باشد.

در مورد KNN اگر داده نویز وارد کنیم به تابعون پیچیده ای که داشتیم OR هم اضافه می شود.

⇐ KNN نسبت به نویز حساس است



در شکل روبرو با وارد کردن داده ی سمت چپ مرز تصمیم تغییر می کند و یک قسمت خزیره ای برای این داده در سمت چپ شکل باید اضافه کنیم و به تابعون مرز تصمیم هم، OR اضافه می شود.

⇐ نکته: هرچقدر k بزرگتر باشد مرز تصمیم smooth تری شود. اگر k خیلی بزرگ شود دچار bias زیادی شود.

Scanned with CamScanner

Class of Interest

در دسته بندی به دونه از کلاس ها هستیم که با بیشتر بهشون علاقه داریم ← به عنوان کلاس مثبت (+) در نظر می گیریم. (و معمولا کشف آن کلاس، ساده تر است)

مثلا در spam Filtering ایمیل های spam کلاس (+) هستند ← تشخیص شان راحت تره

تشخیص نرمال ← اونی که بدرد ما هست رو کلاس (+) در نظر می گیریم چون تشخیص راحت تره

دو مثال بالا ۲ کلاسه بودند. مثال های چند کلاسه هم داریم مثلا تشخیص فعالیت در خانه های هوشمند. یک فعالیت را کلاس + می گیریم.

Prediction Errors : Type I, II

True class / corred label

- A Tumor
  - Maligant
    - Maligant : True positive (TP)
    - خطای تایپ 2 II — Benign : False Negative (FN)
  - Benign
    - خطای تایپ 1 I — Maligant : False positive (FP)
    - Benign : True Negative (TN)

$$\text{TP Rate} = TPR = \frac{\#TP}{\#P} = \frac{\#TP}{\#TP + \#FN} = \text{sensitivity} = \text{Recall}$$ حساسیت

$$\text{TN Rate} = TNR = \frac{\#TN}{\#N} = \frac{\#TN}{\#TN + \#FP} = \text{Specificity}$$ → اختصاص از بقیه کمتر هست

$$\text{Accuracy} = \frac{\#TP + \#TN}{\#P + \#N} = \frac{\#TP + \#TN}{\#TP + \#FN + \#TN + \#FP}$$ (دقت)

$$\text{Error Rate} = 1 - \text{Accuracy}$$

$$\text{precision} = \frac{TP}{TP + FP}$$

چرا اهمیت specificity از بقیه کمتر است؟

در حالت هایی که چند کلاس داریم TN ها به درستی شمرده می شوند، یعنی برای همه حدس هایی که کلاس را غیر از کلاس + گفته اند شمرده می شود و توجهی ندارد که کدام کلاس - گفته شده.

Scanned with CamScanner

$TPR + FNR = 1$ $\qquad$ $TNR + FPR = 1$

$G_mean = (precision \times sensitivity)^{1/2}$

$$F_Score = 2 \times \frac{precision \times sensitivity}{precision + Sensitivity} = F_measure$$

ماتریس درهم ریختگی (Confusion Matrix)

برای دسته بندی دو کلاسه:

		predicted as: positive	predicted as: Negative	
correct label	positive	TP	FN	= Sensitivity
	Negative	FP	TN	= specifity
		= precision		

Imbalanced learning ← داده های یک کلاس خیلی بیشتر از داده های کلاس دیگه هستن

راه حل های متعدد: ① وزن بدهیم به داده ها (cost sensitive learning)

② undersampling / oversampling ← برای اون کلاسی که داده کم دارد، بصورتی داده مصنوعی تولید کنیم

↓

اون کلاس که زیاد ازش داده داریم حذف می کنیم به تعدادی از داده ها شو

معروف ترین الگوریتم در این زمینه: SMOTE ← کلاس حداقل را oversample می کند

Scanned with CamScanner

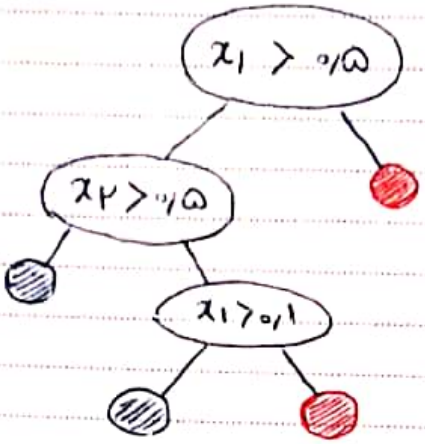
جلسه هفتم ـ ۱۳۹۹/۱۲/۲۴

درخت تصمیم (Decisin Tree)

یکی از روش های خوب و مطمئن.

در KNN مرز تصمیم حالت دندانه‌ای داشت و گفتیم خوب نیست چون واریانس آن بالاست





درخت تصمیم میاد فضای ویژگی‌ها را تقسیم می‌کند.

smooth بودن و راست بودن خط مرز تقسیم در درخت تصمیم معنی است

درخت تصمیم خیلی قابل تفسیر است و می‌توانیم آن را به صورت ترکیب یک سری قوانین نشان بدهیم

مثلا کلاس آبی را می‌توان به صورت SOP (sum of products) نشان داد.

کلاس آبی: $\Big((x_1 \leq 0/5) \wedge (x_2 \leq 0/5)\Big) \vee \Big((x_1 \leq 0/5) \wedge (x_2 > 0/5) \wedge (x_1 \leq 0/1)\Big)$

چالش های این روش چیست؟

① ترتیب ویژگی ها (شروط) چگونه باشد؟ ② حد آستانه (فقط در مورد ویژگی پیوسته)

ویژگی های درخت تصمیم:

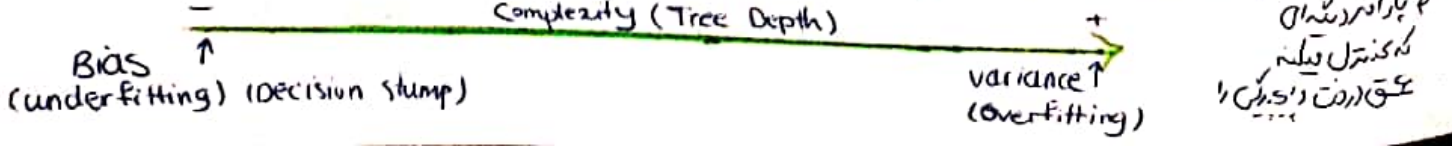
① خیلی قابل تفسیره (می‌توان به صورت SOP نوشت)

② الگوریتم ما non_parametric است. پارامتری که توزیع داده‌ها را مشخص کند نداریم

③ اگر عمق درخت خیلی زیاد باشد overfit می‌شود. اگر عمق خیلی کم باشد Bias می‌شود.

اصطلاحا به آن Decision stump می‌گویند یعنی درختی که عمقش ۱ است. پیچیدگی مدل با عمق درخت تنظیم می‌شود

Maximum depth cutoff ← تا به جای متوقف کردن الگوریتم عمق را



Scanned with CamScanner

مثال دیتاست iris در اسلایدها ← no limit یعنی آنقدر ادامه داده ایم که به برگ رسیده ایم در هرشاخه ای

۲۷ | فروردین / چهارشنبه | ۲۱ شعبان ۱۴۴۱ / 15 April 2020 | ۱۳۹۹

Minimum # parent data ← هرچه کمتر باشد معادل عمق بیشتر درخت است

اینکه توی هر سطح چند داده اگه داشته باشیم هم چنان می خواهیم ادامه بدهیم؟

مثلا در یک سطح به ⊕ ⊖ رسیده ایم ولی باز هم می خواهیم آن را split کنیم به این معناست که این پارامتر کم است و عمق درخت بیشتری می طلبد. این پارامتر هم با عمق درخت، پیچیدگی مدل را کنترل می کند.

آنتروپی (Entropy)

- بی نظمی داده ها، به تصادفی بودن یک پدیده اشاره می کند

مثال: ارسال اطلاعات مربوط به پرتاب سکه در هر روز، تصادفیت زیادی می خواهد

H T T H T H H H T ...

0 0 0 0 ... ارسال اطلاعات برنده شدن در قرعه کشی،

تصادفیت خیلی کمتری نیازه چون می دونیم قراره کی برنده بشه و فقط اینکه برنده شویم خبری می دهیم

(آنتروپی مثال دوم کمتر است)

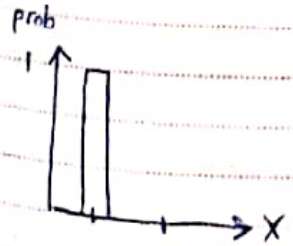
تعریف رسمی آنتروپی:

$$H(X) = \sum_i p(x_i) \log_2 \frac{1}{p(x_i)}$$

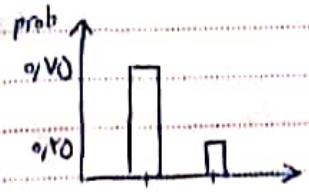
اندازه گیری میزان تصادفی بودن یک متغیر تصادفی X:

$$E(X) = -\sum_i p(x_i) \log_2 p(x_i)$$

مثال:



$E(X) = -(\log_2^1 + 0 \times \log_2^0) = 0$ ← 0 قاعده هوپیتال



$E(X) = -(0/75 \log_2^{0/75} + 0/25 \log_2^{0/25}) = 0/81$

همان طور که انتظار داشتیم در شکل سمت چپ که پدیده قطعی تر است آنتروپی هم کمتر است.

Scanned with CamScanner

آنتروپی = ۰ ← بهترین حالت ← $P_\ominus = 0 = P_\oplus$

آنتروپی همیشه بین ۰ و ۱ است.

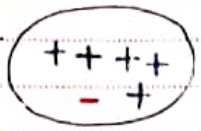
۲۸ | فروردین | پنجشنبه | ۲۲ شعبان ۱۴۴۱ | 16 April 2020

اندازه‌گیری درجه ناخالصی در یک مجموعه

مثلا در این مجموعه درجه ناخالصی بالاست: ← عدم قطعیت و randomness بالاست

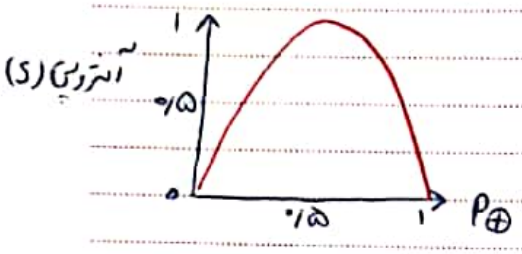


در این حالت درجه ناخالصی کمتره (آنتروپی کمتره): ← نظم بیشتره، قطعیت بیشتره



دقت یادگیری ماشین آنتروپی کمتر برای ما مطلوب است (دسته‌بندی بهتری انجام می‌دهیم)

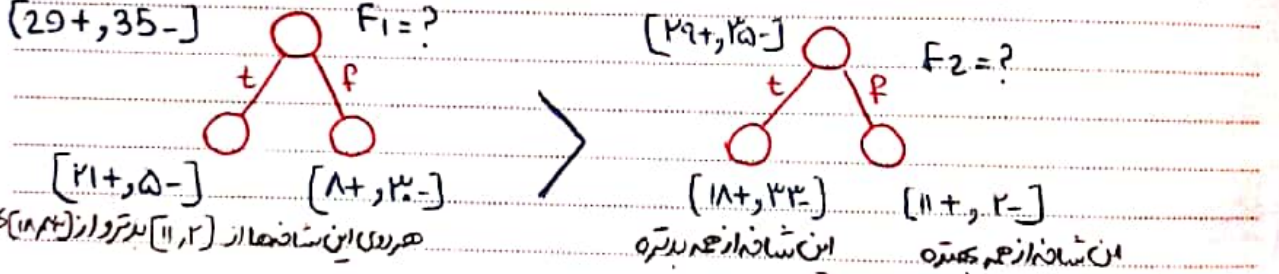
نمودار آنتروپی مربوط به دسته‌بندی دو کلاسه:



$P_\oplus$ بین ۰ و ۱ تغییر می‌کند، رشدش هم به صورت نمایی است

$$E(S) = -(P_\oplus \log_2^{P_\oplus} + P_\ominus \log_2^{P_\ominus})$$

← چه سوالی بپرسیم که بیشترین gain را داشته باشد؟



هر دوی این شاخه‌ها از [۱۱+, ۲-] بدترند و از [۱۸+, ۳۳-] بهترند

این شاخه از همه بدتره

این شاخه از همه بهتره

$IG = 0/26$

$IG = 0/12$

۲۹ | فروردین | جمعه | ۲۳ شعبان ۱۴۴۱ | 17 April 2020

جلسه هشتم ـ ۱۳۹۹/۱۲/۲۶

information Gain : امید ریاضی کاهش آنتروپی

مجموعه‌ای از داده‌ها — ویژگی F

$$Gain(S,F) = Entropy(S) - \sum_{v \in Values(F)} \frac{|S_v|}{|S|} Entropy(S_v)$$

identifier ها رو به طور پیش فرض جزو ویژگی‌ها در نظر می‌گیریم اما ممکنه در طول ساخت درخت تشخیص داده بشه که ویژگی خوبی نیست و کنار گذاشته بشه.

← مثال: مناسبت play Tennis/weather را در اسلاید دیدید ← در این مثال بدون اینکه از ویژگی "روز" استفاده کنیم درخت ساخته شد، بدین معنی است که ویژگی "روز" توسط سایر ویژگی‌ها به نوعی پوشش داده می‌شود. (می‌تواند نشانه‌ای از correlation باشه)

روز ارتش جمهوری اسلامی و نیروی زمینی

Scanned with CamScanner

درخت تصمیم حاوی درجه‌ای که بیشترین Gain را دارد انتخاب می‌کند

دیترگن که در ریشه DT است در تمام حوالی حاضری شود.

۳۰ | فروردین | ۲۴ شعبان ۱۴۴۱ | Hypothesis space در DT مجموعه‌ای از درخت‌هاست
شنبه | 18 April 2020 | این الگوریتمی که برای ساخت درخت ازش استفاده ۱۳۹۹

گریم در این مثال، ID3 نام دارد. ID3 → Iterative Dicotomize (تکثیر کردن) (تکراری)

درخت تصمیم نسبت به نویز چگونه رفتاری کند؟

یک روز ۱۵ام به صورت نویز وارد داده‌های کنیم، برچسب آن درتناقض با درخت است. در این صورت با اضافه کردن دیترگن Tempreture این داده نویزی را در درخت بگنجانیم. این به این معناست که درخت تصمیم درمقابل نویز robust (مقاوم) است.

با اضافه کردن دیترگن Tempreture این قابلیت را به درخت اضافه کرده‌ایم که داده‌های نویزی را بپذیرد اما دو چیز منفی هم درکنارش داریم: ① عمق درخت زیاد می‌شود و overfitting اتفاق می‌افتد

② دیترگن‌هایی که دیترگن خوبی هم نبود را به درخت اضافه کرده‌ایم

راه‌حل: این شرط که همه باید به برگ خالص برسیم را برداریم. با یک درجه اطمینان یا احتمال بیان کنیم نتیجه را. در صورت شاخه دوم بگوییم ۶۶٪ مثبت و ۳۳٪ منفی.

↳ مثلا یکی از شروط توقف می‌تواند حداکثر عمق باشد

پس شرط توقف الگوریتم را رسیدن به برگ قرار نمی‌دهیم چون به احتمال زیاد سبب over Fitting می‌شود.

نکته: اگر دیترگن Day را به عنوان اولین دیترگن درنظر می‌گرفتیم ۱۴ تا شاخه داشتیم مستقیم به برگ می‌رسیدیم. به این گونه دیترگن‌ها، دیترگن کشنده می‌گویند و توانایی پیش‌بینی را از الگوریتم می‌گیرد. الگوریتم‌های درخت تصمیم همان ابتدا چنین دیترگن‌هایی را در مرحله preprocessing تشخیص می‌دهد و حذف می‌کند.

C4.5 (که در weka به آن J48 می‌گویند) مثل ID3 است اما بعضی موارد را اصلاح کرده.

	ID3	C4.5
pruning (هرس کردن)	×	✓
Features	nominal	nominal + numeric
missing values	×	✓
Gain	Basic Info Gain	Gain Ratio

Scanned with CamScanner

توضیح pruning: اگر درخت ساخته شده درحین از شاخه‌ها به سمت overFitting رفتند، برگردیم و عقب را کم کنیم. یک روال راجع اینه که داده‌ها را به ۲ بخش تقسیم کنیم با یکی درخت را بسازیم و روی قسمتی که استفاده نکرده‌ایم تست می‌کنیم که ببینیم که با وجود عقب نشینی و برون رفتن آن آیا تغییر و نقصی به وجود می‌آید؟ اگر مستقل بیا تصمیم می‌گیریم

توضیح Features: توی C4.5 میتونیم ویژگی‌های عددی داشته باشیم. ID3 هنگ میکنه

missing values: اگر در داده‌ها missing valle داشته باشیم ID3 نمی‌تواند هندل کند اما C45 می‌تواند

Gain: اون عامل الگوریتم به ویژگی‌هایی که مقادیر زیادی دارند (Bias)، در C4.5 کاهش پیدا کرده نسبت به ID3. فرمول IG را تغییر داده به Gain Ratio

MDLPC:

Temp:	40	48	60	72	80	90
play:	−	−	+	+	+	−

54 | 85

اگر ویژگی numeric داشته باشیم، مقادیر آن را مانند مثال بالا sort می‌کنیم و در جاهایی که کلاس عوض می‌شود، در نقطه‌ی وسطش، حد آستانه در نظر می‌گیریم. باید از Gain Ratio هم استفاده کنیم تا... نام الگوریتم ← Minimum Description length principle cut (MDLPC)

Gain ←

$$GainRatio(S,F) = \frac{Gain(S,F)}{SplitEntropy(S,F)}$$ → عامل الگوریتم را به ویژگی‌هایی که مقادیر زیادی دارند کاهش می‌دهد

$$SplitEntropy(S,F) = -\sum_{i=1}^{|values\ F|} \frac{|S_i|}{|S|} \log \frac{|S_i|}{|S|}$$ مثلا ویژگی ID در دیتای weather

مثلا برای ویژگی ID، $\frac{|S_i|}{|S|} = \frac{1}{14}$ و یک عدد نسبتاً بزرگ در فرمول Gain قرار می‌گیرد تا عامل الگوریتم را به این نحو کاهش دهد.

SplitEntropy آنتروپی را نسبت به مقادیر خود آن ویژگی حساب می‌کند

$$SplitEntropy(S,D) = -\left(\frac{1}{14}\log\frac{1}{14}\right)\times 14 = \log 14 = 3,\ldots$$

Scanned with CamScanner

جلسه نهم - ۱۳۹۹/۱/۱۵

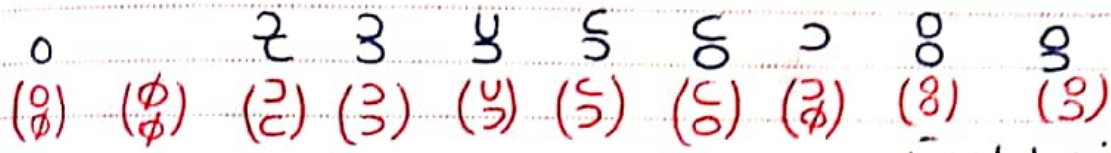
Multiclass ←

مثال: handwritting Digit Recognition

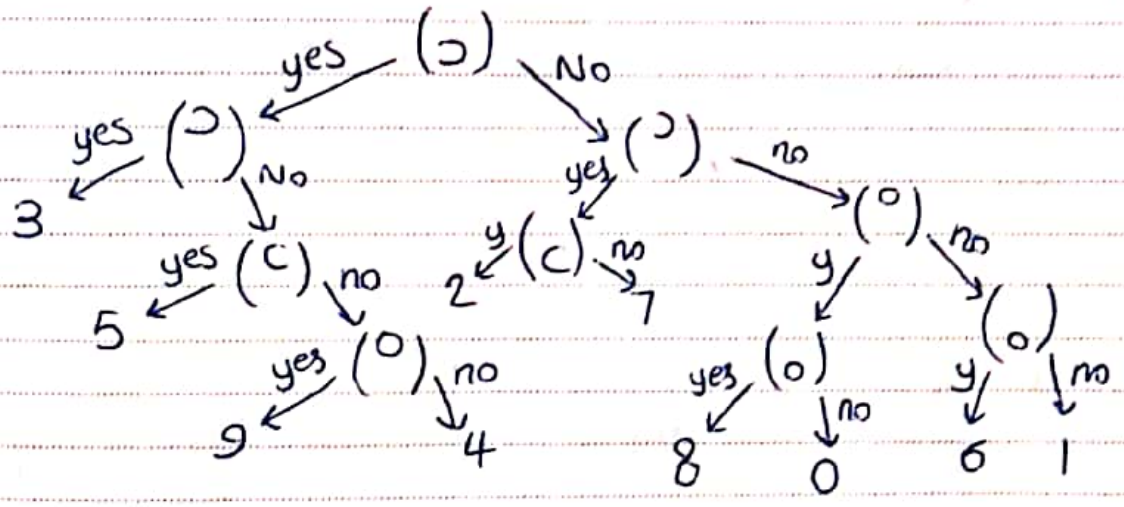
ویژگی ها: ○ ⊃ ⊂ ∪

اینو فقط 4 نیاز داره

0 1 2 3 4 5 6 7 8 9



شود فیچر پنشال دهنده ۱ است.



4 ← باعدم وجود فیچرها ساخته شده

Confusion Matrix

accuracy برای کل میشود جمع قطر اصلی تقسیم بر کل

Actual \ predicted	A	B	C	D	E	Accuracy
A	# TP_A	# E_{AB}	# E_{AC}	# E_{AD}	# E_{AE}	$TP_A / TP_A + E_{AB} + E_{AC} + E_{AD}$
B		# TP_B				
C			# TP_C			
D				# TP_D		
E					# TP_E	

روز برگشت سعدی

در هر مرحله class of interest را مثبت و بقیه را منفی در نظر می گیریم.

Scanned with CamScanner

وزن کلاسیه True positive ← قطر اصلی

False Negative ← یعنی به اشتباه منفی تشخیص داده شده

برای کلاس A

↳ سطر مربوطه A غیر از TP_A.

False positive ← ستون A به جز TP_A

برای کلاس A

True Negative ← درحالت های قالی کلاس معیار گویای نیست چون چیزهایی که اشتباه

درس زده شده راهم درست (True) درنظر می گیرد. مثلا اگر A بوده و تشخیص داده شده برای A جلوی TN

ثبت می شود

↳ در ماتریس: کل ماتریس به جز سطر و ستون کلاس مورد علاقه

$$precision = \frac{TP}{TP + FP}$$

TP Rate ← sensitivity

مدل های غیر پارامتری (Non-Parametric Models)

رگرسیون ← پارامتری KNN ← غیرپارامتری درخت تصمیم ← غیرپارامتری

آیا در مدل های non parametric مدل هیچ پارامتری ندارد؟

چرا، بدین معناست که پارامتری به توزیع داده ها اشاره نمی کند

← نکته: در مدل غیرپارامتری، با افزایش داده ها، مدل پیچیده تری شود. مثلا در KNN هرچقدر تعداد

داده ها زیادتر شود مدل پیچیده تری شود.

یک تعبیر: در KNN، فاصله ی بین داده ها پارامتر است. (که با افزایش تعداد آن ها مدل پیچیده می شود)

اما در مدل های پارامتری، تعداد پارامترها محدود است و مدل ساختار ثابتی دارد، با افزایش داده ها این

پارامترها زیاد نمی شود. (تعداد پارامترها محدود است)

سوال: آیا این جمله درست است؟ ← ✓ درست

" در مدل های غیرپارامتری با افزایش تعداد داده ها، پارامترهای مدل بیشتری شود "

قضیه No Free Lunch (NFL)

بیان خیلی ساده: هیچ الگوریتمی نیست که در همه مسئله ها خوب عمل کند، کاملا به مسئله و دیتاست بستگی

دارد.

Scanned with CamScanner

جلسه دهم - ۱۴۰۰/۱/۱۷

"شبکه های بیزین"

احتمال توأم ← Joint Probability

مثال: فرض کنید ۴ متغیر تصادفی داریم. (باینری)

① اینکه هوا ابری است (Cloudy) ② آب پاش (Sprinkler)

③ اینکه باران بیاید (Rain) ④ اینکه چمن خیس باشد (WetGrass)

یک راه برای نشان دادن احتمالات توأم استفاده از جدول درستی است. برای این مثال جدول دارای $2^4 = 16$ سطر خواهد بود.

C	S	R	W	Prob
F	F	F	F	1
F	F	F	T	0
F	F	T	F	0.01
...	...	...	...	...

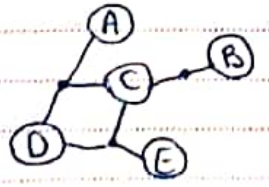
احتمال اینکه چمن ها خیس نباشد

حال داریم دنیا رو با چهار ۴ متغیر تصادفی مدل می کنیم و عوامل دیگری در نظر گرفته نمی شوند.

در مسائل واقعی تعداد متغیرها خیلی بیشتره و سطرهای این جدول به صورت نمایی افزایش پیدا می کنه و به نظر می رسد که روش قابل توسعه ای نیست. نیاز به یک نمایش Compact داریم.

سوال: چرا توزیع توام کم است؟ چون با داشتن توزیع توام به هر سوالی در دنیایی که ساخته ایم می توانیم پاسخ بدهیم.

Probabilistic Graphical Models



میان توزیع توأم رو جمع دوست نشون میدن.

۲ تا مدل احتمالی گرافی وجود دارد

- Factor Graph
- unDirected Graph مثل MRF, CRF
- Directed Graph

روز بزرگداشت شیخ بهایی

در هر سه نوع ها متغیرهای تصادفی هستند و یال ها ارتباط احتمالی آن ها را نشان می دهند. شبکه های بیز از نوع Directed Graph هستند.

Scanned with CamScanner

سوال: چرا نیاز داریم به عامیش گرافی؟ ۱- چون اولش نادل و توانیه که ارتباط متغیرها را باهم نشان می دهد

۲- مدل های احتمالاتی گرافی، رابطه ی استقلال شرطی بین متغیرها را

درک می کنند. Conditional Independence:

مثال: آیا A وابسته هستش به B، با داشتن C؟ A مستقل است از B

$A \perp\!\!\!\perp B \mid C \rightarrow P(A \mid B, C) = P(A \mid C)$

$A \perp\!\!\!\perp B \mid C \rightarrow P(A, B \mid C) = P(A \mid C) P(B \mid C)$

توزیع توام A و B

Directed Graphical Models (مدل گرافی جهتدار)

نودها متغیر تصادفی هستند و یال ها ارتباط علت و معلولی را نشان می دهند.

به دلیل نقض شدن ارتباط علت و معلولی گراف باید حلقه داشته باشد. (DAG)

bayesian/Belief Networks

$X = (X_1, X_2, \ldots, X_n)$ ← X_i ها متغیرهای تصادفی هستند

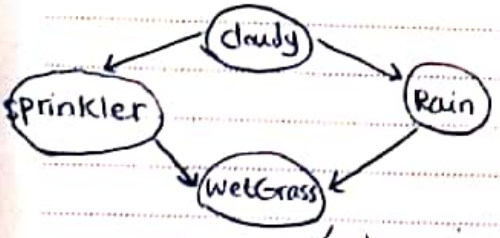
یک شبکه بیزین یک DAG است و توزیع توأم x اینگونه است:

$$p(X_1, X_2, \ldots, X_n) = \prod_i p(X_i \mid pa(X_i))$$

۲ سوال اصلی در مورد شبکه های بیز:

P ← به سری احتمالات شرطی رو باید داشته باشیم parameter Learning

G ← اینکه گرافش و ساختارش چگونه باشد؟ structure learning



مدل PGM یک مدل parametric است.

یک ساختار گرافی برای مثال چین های حبس:

نود cloudy والدندارد و چون اطلاعاتی نداریم در ابتدا توزیع یکنواخت در نظر می گیریم

C	P(C=F)	P(C=T)
	۰/۵	۰/۵

C	P(S=F)	P(S=T)
F	۰/۵	۰/۵
T	۰/۹	۰/۱

C	P(R=F)	P(R=T)
F	۰/۸	۰/۲
T	۰/۲	۰/۸

S	R	P(W=F)	P(W=T)
F	F	۱	۰
T	F	۰/۱	۰/۹
F	T	۰/۱	۰/۹
T	T	۰	۱

C احتمال شرطی هست ← احتمال پیشین

بقیه " " هستند ← " پسین

شکست حمله نظامی آمریکا به ایران در طبس

Scanned with CamScanner

استقلال شرطی:

"آیا A وابسته به B است با داشتن C ؟"

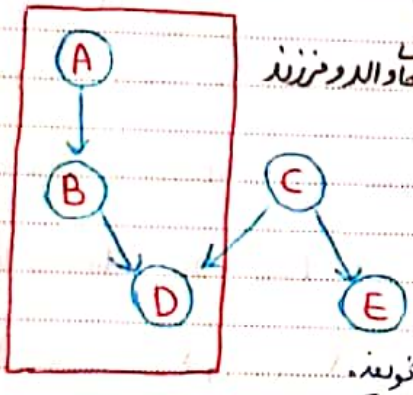
۶ | اردیبهشت ۱۴۴۱ رمضان | شنبه 25 April 2020 | ۱۳۹۹

مثال: "ژن های یک مستقل است از ژن های اجدادش با داشتن ژن های پدر و مادرش"

"میزان حرکت مستقل است از نوع ماشین با داشتن سرعت"

"سرطان ریه مستقل است از دندان های زرد سگ، با داشتن (داشتن) اینکه فرد اعتیاد دارد"

C1 Test ← سه تا حالت کلی دارد استقلال شرطی:



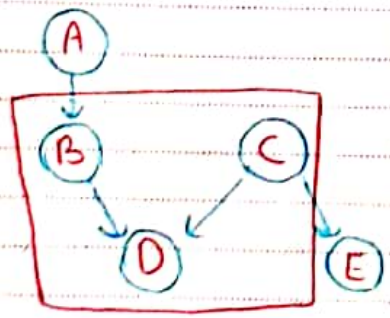
① Serial Connection (Head_Tail) ← مثال ژن حاد الدو فرزند

ارتباط A و B و D ← D از A مستقل است با شرط داشتن B.

در اصول هندسی به این ارتباط، "مرض مارکف درجه ۱" می گویند.

$P(A,B,D) = P(A)\,P(B|A)\,P(D|B)$ ..... B، D را از قبلی ها حذفش جدایی کند.

② Converging Connection (Head_Head)



ارتباط B و C و D ← B و C مستقل نیستند با داشتن D

v-structure هم می نامند. $B \perp\!\!\!\perp C \mid \phi$

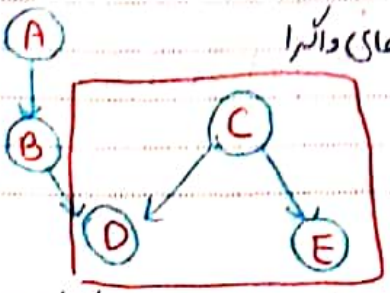
$B \not\perp\!\!\!\perp C \mid D$

مثال: بروتاس دوتاس ارهم مستقل است.

اگر دوتاس را ندارم، به خاطر اینکه من همیشه میدونم که جمع دوتاس همیشه ۹ است ← در اینصورت بروتاس این دوتاس مستقل نیست.

$P(B,C,D) = P(B)\,P(C)\,P(D|B,C)$

③ Diverging Connection (Tail_Tail) بال های واگرا



D مستقل از E است با شرط داشتن C

$D \perp\!\!\!\perp E \mid C$

$P(C,D,E) = P(C)\,P(D|C)\,P(E|C)$

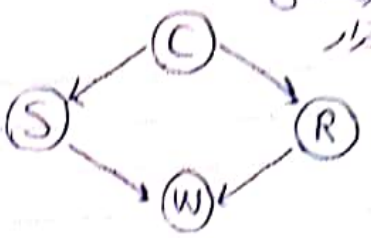
در پرتاب یک تاس اعداد کمتر از ۴ مستقل اند

Scanned with CamScanner

General Chain rule (قانون زنجیره‌ای)

$$P(C,S,R,W) = P(C)\,P(S|C)\,P(R|C,S)\,P(W|C,S,R)$$

در مورد متغیرهای تصادفی دلخواه این رابطه برقرار است



حکونه می‌توانیم رابطه توزیع توأم را با استفاده از این شکل، خلاصه کنیم؟

$P(R|C,S) = P(R|C)$ ← چون S و R به شرط C از هم مستقل بودند

$P(W|C,S,R) = P(W|S,R)$ ← چون فقط والدین مستقیم این متغیر هستند

به طور خلاصه: روابط استقلال شرطی کمک می‌کنند که روابط توزیع توأم را خلاصه‌تر نشان دهیم. خود دل گرافی احتمالی باعث شده بود تا بتوانیم $P(C,S,R,W)$ را به صورت ضرب نشان دهیم. به این گراف‌ها، گراف‌های پارامتری هم گفته می‌شود.

Inference (استنتاج) در شبکه‌های بیز

در دل احتمالی گرافی خلاصه می‌شود در پارامتری احتمالات شرطی.

با داشتن توزیع توأم می‌توانیم به خیلی سوالات حول آن متغیرها (متغیرهای تصادفی) پاسخ دهیم. راه ← marginalize کردن (به حاشیه بردن)

مثلا احتمال اینکه آب پاش روشن باشد به شرط اینکه باران نبارد و به کار بخاری داریم می‌بینیم باید همه حالت‌های ممکن برای آن را در نظر بگیریم

قانون بیز:

$$P(A|B) = \frac{P(B|A)\,P(A)}{P(B)}$$

$P(A|B)$ ← احتمال پسین

$P(A)$ ← احتمال prior

$P(B)$ ← marginalization

وقتی احتمال شرطی، عکس ارتباط علت و معلولی است از قانون بیز استفاده می‌کنیم.

مثال: مشاهده شده که چمن‌ها خیس‌اند. سوال این است که محتمل‌ترین علت آن چه بوده؟

$$P(S=1|W=1) = \frac{P(S=1, W=1)}{P(W=1)} = \frac{0.28}{0.65}$$

$$P(R=1|W=1) = \frac{P(R=1, W=1)}{P(W=1)} = \frac{0.64}{0.65}$$

نکته: در روش‌های قبلی مدل رگرسیون به دنبال min کردن خطا بودیم اما در این روش به دنبال max کردن likelihood هستیم. به اینگونه استنتاج که به دنبال max کردن هستیم استنتاج بیزین گفته می‌شود.

نکته: چون به دنبال مقایسه احتمال‌ها هستیم و مخرج همه کسرها یکسان است می‌توانیم مخرج‌ها را محاسبه نکنیم. به مخرج می‌گویند normalization factor

روز ایمنی حمل و نقل

Scanned with CamScanner

جلسه یازدهم - ۲۲/۱/۱۴۰۰

بیز bayesian Inference

ادامه مثال جلسه قبل:

به دنبال max کردن یک احتمال هستیم

۱۳۹۹

$$p(w=1) = \sum_{c,s,r} p(w=1 \mid s,R,C)\, p(s,R,C)$$

$$= \sum_{c,s,r} p(w=1 \mid s,R,C)\, p(s \mid R,C)\, p(R \mid C)\, p(C) =$$

$$\sum_{c,s,r} p(w=1 \mid s,R)\, p(s \mid C)\, p(R \mid C)\, p(C)$$

یادگیری ساختار شبکه بیز از بیتا با در نظر گرفتن تمام حالات یک مسئله NP_hard است

structure Learning

: Huristics

(S&S) Score and search_Based (1

ساختارهای مختلف داده می‌شود و یک fitness برای هرکدام

بیان می‌شود تا بدانیم کدام ساختار بهتر است

خودشبکه را یاد می‌گیرد

Constraint_Based (CB) (2

بودن یا عدم وجود یک یال را بررسی می‌کند (از شروط استقلال شرطی استفاده می‌کنیا

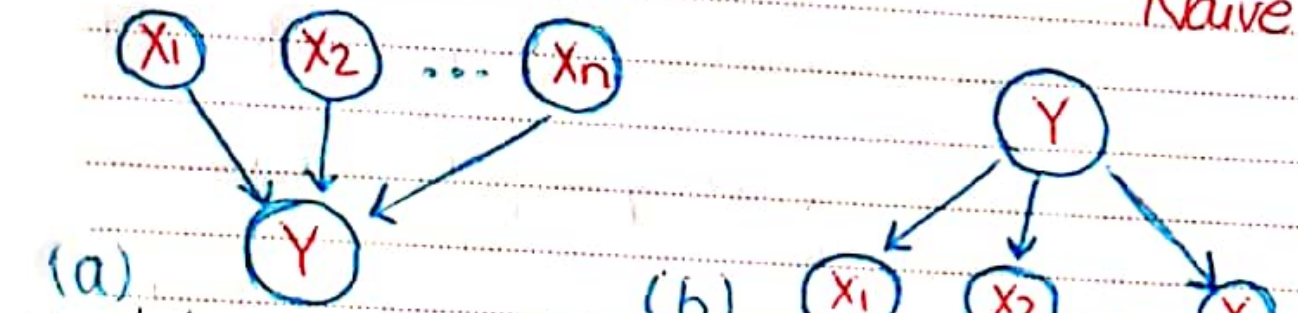
یال‌ها را یاد می‌گیرد.

یک روش سومی هم وجود دارد: یادگرفتن ساختار خیلی مسئله پیچیده‌ای است

برای ساده کردن آن فرض کنیم تمام ویژگی‌ها (نودها) از هم مستقل هستند

Scanned with CamScanner

Naive Bayes Classifier (NBC)



کدام یک از این مدل ها NBC است؟

(a) دیگر ساختار از پیش داده شده هست و نیازی به یادگیری آن نیست

در Naive Bayes $h: X \to Y$

در a فیچرها وابسته اند، مدل b همان NBC است

$h: X \to Y \rightarrow h: X \to \{+, -\}$ binary classification

می خواهیم یک تابع ناشناخته $f: X \to Y$ را تخمین بزنیم

$$y_{MLE} = \underset{y \in Y}{\operatorname{argmax}}\ p(Y=y \mid X) = \underset{y \in Y}{\operatorname{argmax}}\ \frac{P(X \mid Y=y)\,P(Y=y)}{P(X)}$$ (قانون بیز)

$$= \underset{y \in Y}{\operatorname{argmax}}\ p(X \mid Y=y)\,p(Y=y) = \underset{y \in Y}{\operatorname{argmax}}\ p(X, Y=y)$$ (احتمال توأم)

$X = \langle X_1, X_2, \ldots, X_n \rangle$, $X_i \perp\!\!\!\perp X_j \mid Y$ $(i,j = 1,2,\ldots,n \ \&\ i \neq j)$

↓

Naive شرط : X_i مستقل است از X_j به شرط Y

Scanned with CamScanner

روش Naive Bayes یک روش scalable است.

۹ | اردیبهشت | ۴ رمضان ۱۴۴۱
سه شنبه | 28 April 2020

$$y_{MLE} = \underset{y\in\{+,-\}}{\operatorname{argmax}}\ p(X, Y=y) = \underset{y\in\{+,-\}}{\operatorname{argmax}}\ p(X|Y=y)\,p(Y=y)$$

$$= \underset{y\in\{+,-\}}{\operatorname{argmax}}\ p(X_1|Y=y)\,p(X_2|Y=y)\cdots p(X_n|Y=y)\,p(Y=y)$$

$$= \underset{y\in\{+,-\}}{\operatorname{argmax}}\ p(Y=y)\prod_{i=1}^{n} p(X_i=x_i|Y=y)$$

مثال: با استفاده از روش NBC کلاس داده‌ی

داده‌ی تست زیر را از مجموعه داده‌ی آب و هوا (play Tennis) تهیه شده، تعیین کنید.

Test Data: (<O=Rainy, T=Cool, H=High, W=True>, ?) → yes or no? تعیین بارش گیم یا نه

prior probability: $p(Y=yes)=\frac{9}{14}$ $p(Y=no)=\frac{5}{14}$

$p(rainy|yes)=\frac{3}{9}$ $p(rainy|no)=\frac{2}{5}$

$p(Cool|yes)=\frac{3}{9}$ $p(Cool|no)=1/5$

$p(high|yes)=3/9$ $p(high|no)=4/5$

$p(true|yes)=3/9$ $p(true|no)=3/5$

$$p(Y=yes)\prod_{i=1}^{4} p(X_i=x_i|Y=yes)=0/0079$$

$$p(Y=no)\prod_{i=1}^{4} p(X_i=x_i|Y=no)=0/0137$$

$p(Y=no) > p(Y=yes)$

مثال:

Test Data: (<O=Rainy, T=Cool, H=high, W=False>, ?)

$p(false|yes)=6/9$ $p(false|no)=2/5$

$P(Y=yes)=0/0159 > P(Y=no)=0/0091$

Scanned with CamScanner

Test Data: مثال:

(<O=overcast, T=Cool, H=High, W=False>, ?)

۱۳۹۹ $P(overcast|yes)=\frac{4}{9}$ $P(overcast|no)=0$ ← * مشکل Zero probability

وجود یه دونه صفر باعث می‌شه تمام احتمال صفر بشه و بقیه موارد را بی‌اثر می‌کند.

راه حل: Smoothing (Laplace)

Smoothed likelihood: در واقع داریم راه حلی برای تعداد داده‌های آموزش ناکافی ارائه می‌دهیم

$$P(X_i=x_{ik}|Y=y_j)=\frac{count(X_i=x_{ik},Y=y_j)+\ell}{count(Y=y_j)+\ell\times k} \qquad \begin{matrix} i=1\dots4 \\ j=1,2 \end{matrix}$$

ℓ: Laplace smoothing strength → $\ell=1$ اکثر اوقات

k: تعداد حالات ممکن برای X_i ← برای همه ویژگی‌ها این کار را انجام می‌دهیم.

چرا مجازیم از این کار استفاده کنیم؟ چون می‌دانیم که به دلیل کمبود داده آموزشی این احتمال صفر شده و انگار داریم به صورت مجازی فرض می‌کنیم یه سری داده دیگه هم داشته‌ایم

جلسه دوازدهم ـ ۱/۲۴ ـ ۱۴۰۰

می‌توان گفت که با اضافه کردن ℓ (smooth کردن) از overfit هم جلوگیری می‌شود.

Naive Bayes → Hidden Markov Model

HMM هم مثل NB سعی می‌کند یه توزیع توأم را دنبال بزند. دیدیم که NB توزیع توأم را اینگونه نشان می‌دهد:

$$P(X,Y)=\prod_{i=1}^{n}P(X_i|Y)P(Y)$$

(X,Y: متغیرها، n: تعداد)

HMM احتمال بین state ها را اضافه می‌کند و از این طریق، برای داده‌های ترتیبی (sequential) مناسب می‌شود.

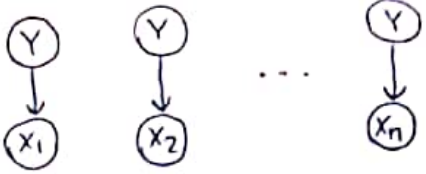
$P(Y_i|Y_{i-1})$ ← احتمال انتقال

$$P(X,Y)=P(X_1|Y_1)P(Y_1)\prod_{i=2}^{n}P(X_i|Y_i)P(Y_i|Y_{i-1})$$

روز ملی خلیج فارس داده‌های ترتیبی مثلا اونایی که زمان براشون مهمه یا مثلا داده‌های ژنی.

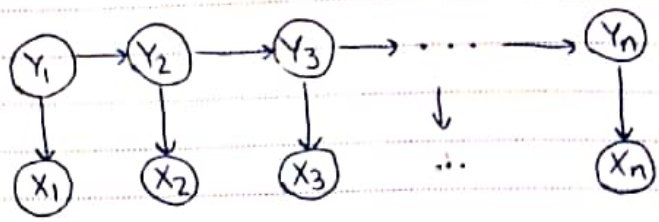
Scanned with CamScanner

Naive Bayes



۱۱ | اردیبهشت | ۶ رمضان ۱۴۴۱
پنجشنبه | 30 April 2020

Hidden Markov Model



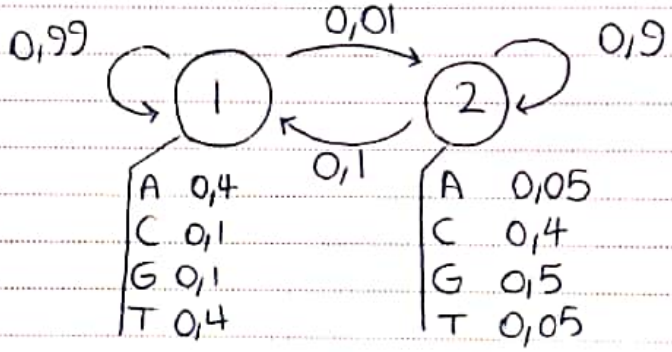
Xها خروجی هستند و آن ها را داریم و قابل مشاهده است ، Yها علت به وجود آمدن خروجی اند و جزو شان پنهان هستند ، ی خواهیم با توجه به Xها ، Yها را بیابیم.

مثلا در خانه هوشمند فعال شدن یک سری از سنسورها را مشاهده می کنیم اما علت آن برای ما پنهان است

(خود علت ها هم ترتیب دارند)

چون Y_1 اولین است دیگر قبلی ندارد و prior است به همین دلیل بیرون سیگما گذاشته شده در فرمول

HMM_state Machine



۱۲ | اردیبهشت | جمعه

۷ رمضان ۱۴۴۱

1 May 2020

در هرکدام از state ها که باشیم تمایل داریم که در آن state بمانیم و احتمال انتقال به حالت دیگر کم است.

state sequence (hidden):

... ① ① ① ① ① ① ② ② ② ② ② ① ① ..

symbol sequence (observable) :

A T C A A G G C G A T

٠/٤ ٠/٤ ٠/١ ٠/٤ ٠/٤ ٠/٥ ٠/٥ ٠/٤

چیزی که به ما داده می شده اینه

و سوال اینه که محتمل ترین رشته ای از حالات که می تواند این رشته از dna را تولید کند کدام است ؟

یک مسئله : رشته ای از حالت های قابل مشاهده را داریم ، خود مدل را هم داریم (احتمالات انتقال و ...)

سوال این است که چگونه $P(x|M_i)$ را بدست آوریم به عبارتی می خواهیم احتمال اینکه آن رشته توسط مدل ساخته شده چقدر است ؟

راه حل : الگوریتم Forward_Backward

روز معلم - روز جهانی کار و کارگر

Scanned with CamScanner

مثال: در خانه حوشنگ، مجموعه‌ای از سنسورهای مادون قرمز نصب شده که فعال شده اند:

M_1 M_7 D_6 M_{11}

۱۳ | اردیبهشت ۸ رمضان ۱۴۴۱
شنبه | 2 May 2020

۱۳۹۹

چندتا activity در نظر گرفته هست، مثلا:

① غذا پختن M_1
② غذا خوردن M_2
③ نظافت M_3

این مسئله این را بیان می‌کند که الان این سنسورهایی که فعال شده اند مربوط به غذا پختن است یا غذا خوردن است یا نظافت؟ $P(x|M_i)$

مسئله دوم: یک sequence از حالت های قابل مشاهده به همراه مدل به ما داده شده می‌خواهیم محتمل‌ترین ترتیب از حالت های پنهان که می‌تواند این رشته را تولید کند پیدا کنیم.

از بین ۳ مسئله، این مسئله پرکاربردترین است.

راه حل: الگوریتم Viterbi

مسئله سوم: در این مسئله وقتی داریم خودمان مدل را می‌سازیم و پارامترهای مدل را یاد بگیریم

راه حل: الگوریتم Baum_welch

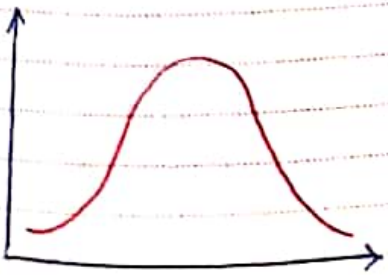
مثالی از کاربرد HMM ← Tablet PC ← دست خط حالت قابل مشاهده است و حالت تولید آن، حالت پنهان است. دقت کنید حالت پنهان است که حالت قابل مشاهده را تولید می‌کند. مثلا سرما خوردگی است که باعث ترشح بینی می‌شود.

از روی ترتیب فهمیده که l است نه a

Salad → salaa
salaam → salaam

جلسه سیزدهم ـ ۱۴۰۰/۱/۲۹

توزیع نرمال/گوسی ← دو پارامتر واریانس و میانگین را دارد (μ ، σ → انحراف معیار)



خیلی از پدیده ها در طبیعت هم از این توزیع پیروی می‌کنند

تابع چگالی احتمال (برای حالت تک متغیره)

$$f(x) = \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{1}{2}\left(\frac{x-\mu}{\sigma}\right)^2}$$

Scanned with CamScanner

تابع چگالی احتمال برای حالت چندمتغیره:

$$f_X(x_1,\dots,x_k)=\frac{1}{\sqrt{(2\pi)^k|\Sigma|}}e^{-\frac{1}{2}(x-\mu)^T\Sigma^{-1}(x-\mu)}$$

$$X=(X_1,\dots,X_k)^T$$

بجای واریانس ماتریس کوواریانس را داریم

$\mu_{k\times 1}$ → بردار میانگین

$\Sigma_{k\times k}$ → ماتریس کوواریانس

$$\mu=E[X]=[E[X_1],\dots,E[X_k]]^T \qquad \Sigma=E[(X-\mu)(X-\mu)^T]$$

Gaussian naive Bayes (GNB)

مثال: می خواهیم کیه ها و پسرکسالان را از هم تشخیص بدهیم. بیژگی ها: قد و وزن (ویژگی های پیوسته)

prior class probabilities:

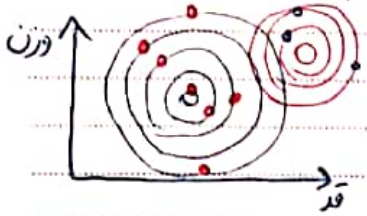
۱۴ تا داده داریم ← ۱۲ تا کودک، ۲ تا پسرکسال

$$P(Y=a)=4/14=0.25 \qquad P(Y=c)=12/14=0.75$$

قد کودکان:
$$\mu_{h,c}=\frac{1}{12}\sum_{i:y_i=c}h^i$$
$$\sigma^2_{h,c}=\frac{1}{12-1}\sum_{i:y_i=c}(h^i-\mu_{h,c})^2$$

وزن کودکان:
$$\mu_{w,c}=\frac{1}{12}\sum_{i:y_i=c}w^i$$
$$\sigma^2_{w,c}=\frac{1}{12-1}\sum_{i:y_i=c}(w^i-\mu_{w,c})^2$$

در توزیع گوسی نقاطی که روی یک دایره هستند دارای احتمالات برابر هستند که به آن ها isol Line گفته می شود



(به نوعی حاصل ضرب دو تا توزیع را استاندارد می دهد)

مثل naive Bayes ویژگی ها را مستقل در نظر گرفته ایم و در هم ضرب کرده ایم

مثلا در مورد کودکان قد و وزن را در هم ضرب کرده ایم

فاز تست:

$$X=\langle h_x,w_x\rangle \quad \text{(test data)}$$

به طور مشابه $P(h_x|Y=c)$

$$P(h_x|Y=a)=\frac{1}{\sqrt{2\pi\sigma^2_{h,a}}}\exp\left(-\frac{(h_x-\mu_{h,a})^2}{2\sigma^2_{h,a}}\right)$$

و $P(w_x|Y=c)$ را باید

$$P(w_x|Y=a)=\frac{1}{\sqrt{2\pi\sigma^2_{w,a}}}\exp\left(-\frac{(w_x-\mu_{w,a})^2}{2\sigma^2_{w,a}}\right)$$

محاسبه کنیم.

Scanned with CamScanner

: classification تابعون

$$y_{MLE} = \underset{y \in \{a,c\}}{\operatorname{argmax}}\ p(Y=y|X)$$

$$= \operatorname{argmax}\ p(X|Y=y)p(Y=y)$$ ۱۳۹۹

Test Data: $X = \langle h_x, w_x \rangle$

if $p(\langle h_x, w_x \rangle | Y=a)p(Y=a) > p(\langle h_x, w_x \rangle | Y=c)p(Y=c)$

if $p(h_x|Y=a)\,p(w_x|Y=a)\,p(Y=a) > p(h_x|Y=c)\,p(w_x|Y=c)\,p(Y=c)$

then class is adult
else class is children

μ و σ^2 برای population mean ، population Variance استفاده می‌شود اما ما در واقع

داریم روی یک sample از جمعیت کار می‌کنیم. نوشتن‌های درست: $\bar{X}_{h|c}$ $S^2_{h|c}$

نکته: naive bayes پارامتریک است و پارامترها همان احتمالات شرطی هستند (GNB هم پارامتریک)

نکته: KNN و Desision Tree غیرپارامتریک هستند

محاسبه‌ی $P(Y|X)$ برای GNB classifier:

فرض کنید Y یک متغیر بولین است که از توزیع برنولی پیروی می‌کند

$X = \langle X_1, X_2, \dots, X_n \rangle$ ، X_i ها متغیرهای تصادفی پیوسته هستند

برای هر X_i ، $P(X_i | Y=y_k)$ یک توزیع گوسی با فرم $N(\mu_{ik}, \sigma_i)$ است

برای همه‌ی زوج‌هایی که $i \neq j$ ، X_i و X_j از هم مستقل شرطی هستند به شرط داشتن Y

$$P(Y=1|X) = \frac{P(X|Y=1)P(Y=1)}{P(X)} = \frac{P(X|Y=1)P(Y=1)}{P(X|Y=1)P(Y=1) + P(X|Y=0)P(Y=0)}$$ ← marginalize

$$= \frac{1}{1 + \frac{P(X|Y=0)P(Y=0)}{P(X|Y=1)P(Y=1)}} = \frac{1}{1+\exp\left[\ln \frac{P(X|Y=0)P(Y=0)}{P(X|Y=1)P(Y=1)}\right]}$$

وفات حضرت خدیجه (س)

$$= \frac{1}{1+\exp\left[\ln \frac{P(X|Y=0)}{P(X|Y=1)} + \ln \frac{P(Y=0)}{P(Y=1)}\right]} = \frac{1}{1+\exp\left[\sum_{i=1}^{n} \ln \frac{P(x_i|Y=0)}{P(x_i|Y=1)} + \ln \frac{P(Y=0)}{P(Y=1)}\right]} \quad (I)$$

Scanned with CamScanner

$$\sum_{i=1}^{n} \ln \frac{P(x_i|Y=0)}{P(x_i|Y=1)} = \sum_i \ln \frac{\frac{1}{\sqrt{2\pi\sigma_i^2}} \exp\left(\frac{-(x_i-\mu_{i0})^2}{2\sigma_i^2}\right)}{\frac{1}{\sqrt{2\pi\sigma_i^2}} \exp\left(\frac{-(x_i-\mu_{i1})^2}{2\sigma_i^2}\right)}$$

به شرط اینکه واریانس‌های دو کلاس با هم برابر باشند، می‌توانیم ساده کنیم

$$= \sum_i \ln\left(\exp\left(\frac{(x_i-\mu_{i1})^2-(x_i-\mu_{i0})^2}{2\sigma_i^2}\right)\right) = \sum_i \frac{(x_i^2-2x_i\mu_{i1}+\mu_{i1}^2)-(x_i^2-2x_i\mu_{i0}+\mu_{i0}^2)}{2\sigma_i^2}$$

$$= \sum_i \frac{2x_i(\mu_{i0}-\mu_{i1})+\mu_{i1}^2-\mu_{i0}^2}{2\sigma_i^2} = \sum_i \left(\frac{\mu_{i0}-\mu_{i1}}{\sigma_i^2}x_i + \frac{\mu_{i1}^2-\mu_{i0}^2}{2\sigma_i^2}\right) \quad (II)$$

در ادامه‌ای که در خرج کسر صفحه قبل داشتیم می‌توانیم به صورت یک رابطه خطی بر اساس x_i نوشته شود

$$(I, II) \Rightarrow P(Y=1|X) = \frac{1}{1+\exp\left[\sum_{i=1}^{n}\left(\frac{\mu_{i0}-\mu_{i1}}{\sigma_i^2}x_i + \frac{\mu_{i1}^2-\mu_{i0}^2}{2\sigma_i^2}\right) + \ln\frac{P(Y=0)}{P(Y=1)}\right]}$$

$$P(Y=1|X) = \frac{1}{1+\exp\left(\sum_{i=1}^{n} w_i x_i + w_0\right)}$$

که در آن $w_0 = \ln\frac{1-P(Y=1)}{P(Y=1)} + \sum_{i=1}^{n}\frac{\mu_{i1}^2-\mu_{i0}^2}{2\sigma_i^2}$ ، $w_i = \frac{\mu_{i0}-\mu_{i1}}{\sigma_i^2}$

$$P(Y=0|X) = 1-P(Y=1|X) = \frac{\exp\left(\sum_{i=1}^{n} w_i x_i + w_0\right)}{1+\exp\left(\sum_{i=1}^{n} w_i x_i + w_0\right)}$$

برای گرفتن argmax بهتر است این‌ها را بر هم تقسیم کنیم:

if $(P(Y=1|X) \geq P(Y=0|X))$ then class is +

if $\frac{P(Y=1|X)}{P(Y=0|X)} = \frac{1}{\exp\left(\sum_{i=1}^{n} w_i x_i + w_0\right)} \geq 1$ then class is +

if $\exp\left(\sum_{i=1}^{n} w_i x_i + w_0\right) \leq 1$ then class is +

if $\sum_{i=1}^{n} w_i x_i + w_0 \leq 0$ then class is + else class is -

Scanned with CamScanner

$\sum_{i=1}^{n} w_i x_i + w_0$ یک ابرصفحه را نشان می‌دهد

در فضای دو بعدی یک خط است. این بدین معناست

۱۳۹۹ Guassian Naive Bayes که در درس

$\sigma_{ik} = \sigma_i$

مرز تقسیم‌ها یک مرز خطی است.

جایی که صورت و مخرج را ساده کردیم با این فرض بود که واریانس ویژگی از خود کلاس مستقل است

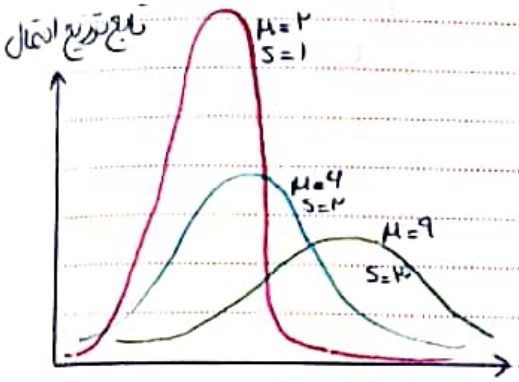
Logistic Distribution

خیلی شبیه به توزیع نرمال است

parameters : μ, location(real), $s>0$, scale(real)

support : $x \in (-\infty, +\infty)$

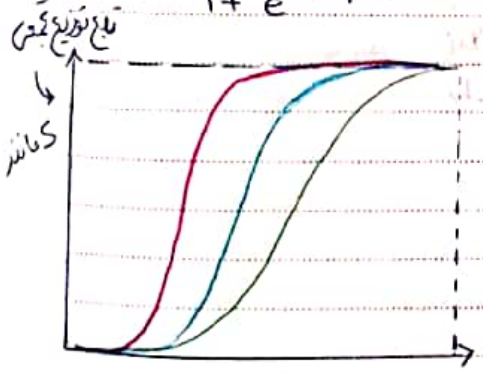
PDF: $\frac{e^{-(x-\mu)/s}}{s(1+e^{-(x-\mu)/s})^2}$

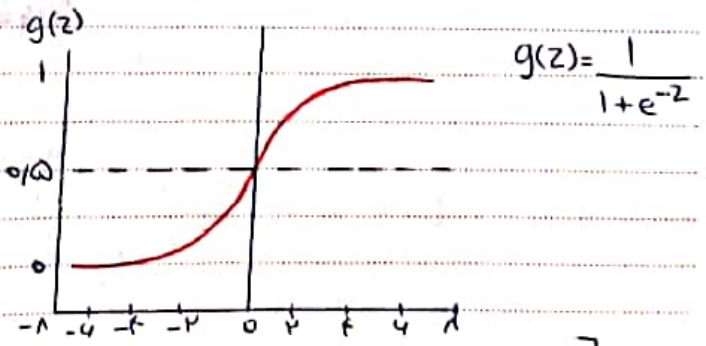


variance : $s^2\pi^2/3$

CDF: $\frac{1}{1+e^{-(x-\mu)/s}}$

Mean : μ Median : μ Mode : μ





$g(z) = \frac{1}{1+e^{-z}}$

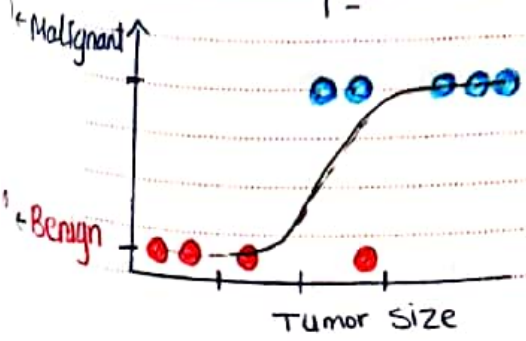
این فرم را sigmoid می‌گوییم با فرض اینکه تابع احتمال، تابع توزیع نرمال باشد. اما اگر logistic باشد

بهآن تابع logistic می‌گوییم.

$\frac{dg(z)}{dz} = g(z)[1-g(z)]$

این ← می‌خواهیم از این الگوریتم غیرخطی رگرسیون برای دسته‌بندی استفاده کنیم.

مسئله تشخیص تومور:



فقط سایز تأثیرگذار نیست، قطعاً ویژگی‌های دیگری هم

اثرگذارند به همین دلیل بعضی از آن‌ها دارد خوانده شده

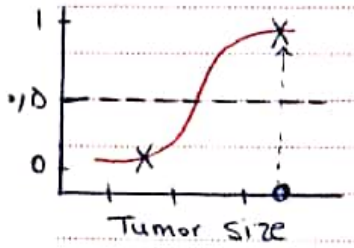
یک منحنی logistic‌ای سعی می‌کنیم روی داده‌ها ← رگرسیون غیرخطی

Scanned with CamScanner

تابع Logistic یک تابع توزیع تجمعی است و مبنای توانیم از تابع توزیع تجمعی برای محاسبه احتمال استفاده کنیم.

سپس استگاری میدانند که خود y را احتمال در نظر بگیریم

برای اینکه دسته‌بندی انجام بدهیم ← یک حد آستانه (به صورت خط افقی) در نظر بگیریم، اگر احتمال از این حد بیشتر باشد در دسته‌ی بدخیم و اگر کمتر باشد در دسته‌ی خوش خیم قرار بگیرد.



نکته: رگرسیون لجستیک یک الگوریتم دسته‌بندی است.

$$P(Y=1 \mid X=x) = \frac{1}{1+\exp(-x)} \Rightarrow P(Y=0 \mid X=x) = \frac{\exp(-x)}{1+\exp(-x)}$$

x is Tumor Size

↳ روابطی که به دست می‌آید تقریباً به همان فرمی است که GNB بود.

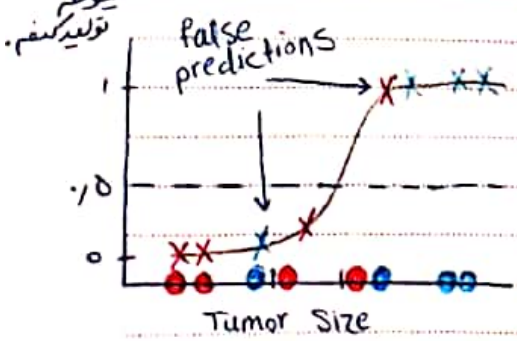
نکته: دو تا دسته‌بند Logistic regression و GNB به شدت به هم شبیه‌اند و اگر تعداد داده‌های آموزشی زیاد باشد این دو دسته‌بند یکی می‌شوند. اگر تعداد داده محدود باشد GNB بهتر عمل می‌کند به خاطر شرط استقلال و اگر داده‌ها بیشتر باشد LR بهتر عمل می‌کند.

نکته: تفاوتی GNB و LR سعی دارند $P(Y|X)$ را محاسبه کنند، تفاوتشان در این است که LR

روز بیماری های خاص و صعب العلاج

مستقیم این محاسبه را انجام می‌دهد و GNB با استفاده از قانون بیز و محاسبه $P(X|Y)P(Y)$ این کار را انجام می‌دهد.

LR دسته‌بند Discriminative (تمایزگر) می‌گویند که $P(Y|X)$ را مستقیم محاسبه می‌کند و GNB که برای محاسبه $P(Y|X)$ از یک واسط استفاده می‌کند دسته‌بند Generative (مولد) گفته می‌شود. در حالت مولد، خودمان می‌توانیم داده‌ی جدید هم تولید کنیم (داده مصنوعی جدید) وقتی میتونم $P(X|Y)$ را حساب کنم داده جدید هم میتونم تولید کنم.



Evaluation : False predictions

Actual \ predicted	Malignant	Benign
Malignant	3	1
Benign	1	3

← Confusion Matrix

threshold = 0.5

اگر threshold را 0.3 بدهیم

	M	B
M	۴	۰
B	۲	۲

تغییر دادن خطی False positive زیادی می‌شود

و نهایتاً در خوشه‌بندی به این صورت در می‌آید:

Scanned with CamScanner

اگر threshold را از ۰/۵ به ۰/۹ تغییر بدهیم

	M	B
M	۳	۱
B	۰	۴

خطای ما تغییر می‌کند:

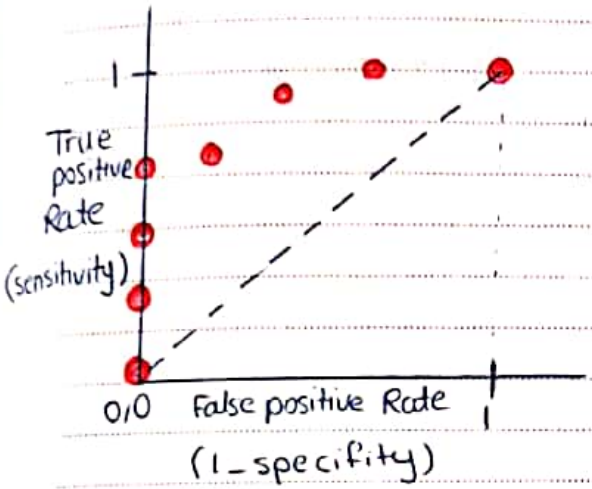
۲۰ | اردیبهشت ۱۵ رمضان ۱۴۴۱ | شنبه 9 May 2020

۱۳۹۹

به ازای هر threshold یک ماتریس درهم‌ریختگی ایجاد می‌شود و بررسی را سخت می‌کند. به همین دلیل

همه‌ی این موارد را در یک معیار به نام ROC وارد می‌کنیم که خلاصه‌ای از ماتریس‌های درهم‌ریختگی

به ازای حد آستانه‌های مختلف به ما نشان می‌دهد.



سوال: اگر حد آستانه را صفر در نظر بگیریم نقطه‌ی

متناظرش در ROC کجاست؟ بالا راست، چون

هر دوی TP و FP زیاد هستند

خطی که زاویه ۴۵° دارد یک وضع کاملا تصادفی است

(شیر یا خط ساده)

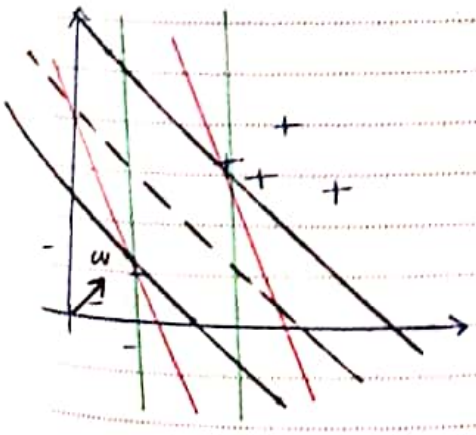
ناحیه‌ی زیر ROC هرچقدر از این خط بیشتر باشد الگوریتم بهتر عمل می‌کند (چون سطح زیر نمودار آن

یا همان AUC آن بیشتر است) ← برای مقایسه دو الگوریتم AUC استفاده می‌شود

وقتی دیتاست imbalanced باشد معمولا precision_Recall بهتر عمل می‌کند

جلسه چهاردهم ـ ۱۴۰۰/۱/۳۱

Support Vector Machines (SVMs)



فرض اولیه: $h : X \longrightarrow \{-1, +1\}$

← ایده ← خیابانی که عریض‌تر است بهتر داده‌ها را جدا می‌کند

به آن دیگرند "عریض‌ترین خیابان" هم گفته می‌شود

به شکل دوبعدی خط سیاه رنگ، داده‌ها را بهتر جدا می‌کند

مرز تصمیم ← خطی که از وسط خیابان می‌گذرد

margin ← فاصله بین داده‌ها و مرز تصمیم

ولادت امام حسن مجتبی (ع) (۳ هـ ق) و روز اکرام

← max margin را عریض‌ترین خیابان دارد

Scanned with CamScanner

معادله خط مرز تصمیم: $w.x + b = 0$

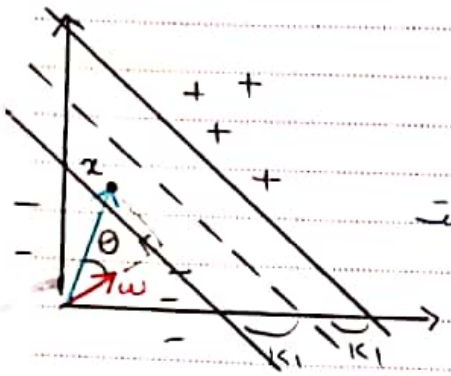
یا $w^T x + b = 0$

w بر خیابان عمود است.

شیب‌شان قرینه معکوس هم است $[w_1 \ w_2]\begin{bmatrix}x_1\\x_2\end{bmatrix}$ → اسکالر

w و b ← هر دو ناشناخته هستند

شیوه‌ی دسته‌بندی:



ضرب داخلی داده تست در بردار w: $w.x_{test}$

یک بردار از مبدا به داده تست رسم می‌کنیم، ضرب داخلی بردار داده تست در بردار w: $|w||x_{test}|\cos\theta$

↳ اندازه تصویر بردار تست بر روی w ضربدر اندازه w

اگر تصویر داده تست روی بردار w به مرز تصمیم نرسد ← کلاس − وگرنه مثبت

اگر بردار w را اینگونه فرض کنیم ← فقط کافیه خود تصویر رو در نظر بگیریم (همیشه یه عدد)

if $w.x_{test} \geq c$ then class is +

if $w.x_{test} + b \geq 0$ then class is +, s.t. $b = -c$

دو نامساوی می‌گذاریم:

راست: $w.x_+ + b \geq 1 \quad (y=+1)$

چپ: $w.x_- + b \leq -1 \quad (y=-1)$

$w_1 x_+ + b_1 = k_1 \xrightarrow{\div k_1} \underbrace{\left(\frac{w_1}{k_1}\right)}_{w} x_+ + \underbrace{\left(\frac{b_1}{k_1}\right)}_{k} = 1$

معادله خط وسطی: $w.x + b = 0$

" " چپی: $w.x + b = -1$

" " راست: $w.x + b = 1$

× y ↓

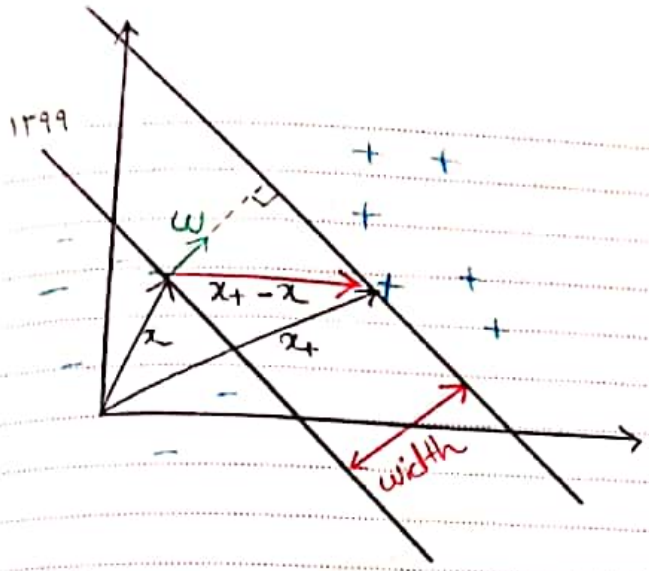
$y_i(w.x_i + b) - 1 \geq 0, \forall i$

support vector: داده‌هایی که روی خود خیابان قرار گرفته‌اند

$y_i(w.x_i + b) - 1 = 0$ iff x_i is a support vector

بردار w را با همان اندازه و همان راستا از مبدأ شیفت می‌دهیم ← پیکان w ← کمابیش عمود بر خیابان است

Scanned with CamScanner



ضرب داخلی $x_+ - x_-$ در w به ما عرض خیابان را می‌دهد (w بردار یکه است)

↓

به دنبال max کردن عرض خیابان هستیم

← یک مسئله بهینه‌سازی

$$width = (x_+ - x_-) \cdot \frac{w}{\|w\|} = (w.x_+ - w.x_-) \cdot \frac{1}{\|w\|} = \frac{2}{\|w\|}$$

طبق دو تا محدودیتی که اول داشتیم: $w.x_+ + b = 1 \quad , \quad w.x_- + b = -1$

هدف ما max کردن $\frac{2}{\|w\|}$ است ← معادل min کردن $\|w\|$ ← معادل min کردن $\frac{1}{2}\|w\|^2$

← محدودیتی که داریم: $y_i(w.x_i + b) - 1 \geq 0$ (تا انتها این محدودیت را باید حل کنیم)

primal problem: می‌توانیم محدودیت را بیاوریم در خود معادله و با ضرایب لاگرانژ آن‌ها را از بین ببریم

$$L(w,b) = \frac{1}{2}\|w\|^2 - \sum_i \alpha_i \left[y_i(w.x_i + b) - 1 \right] \qquad \alpha_i \geq 0, \forall i$$

هدف min کردن L نسبت به w و b است. مشتق می‌گیریم نسبت به هر دو:

$$\begin{cases} \frac{\partial L(w,b)}{\partial w} = w - \sum_i \alpha_i y_i x_i = 0 \rightarrow \boxed{w = \sum_i \alpha_i y_i x_i} \\ \frac{\partial L(w,b)}{\partial b} = -\sum_i \alpha_i y_i = 0 \rightarrow \boxed{\sum_i \alpha_i y_i = 0} \end{cases}$$

w را به ما می‌دهد

نقش‌آفرینی α در مورد بردارها: پشتیبان +۱ و -۱ را می‌گوید

α_i برای داده‌های غیر بردار پشتیبان برابر ۰ است در نتیجه فقط بردارهای پشتیبان در این ساختار نقش دارند.

y یا ۱ است یا ۱-. مثال:

$$\alpha_+ - \alpha_{1-} - \alpha_{2-} = 0$$

$$\Rightarrow \alpha_+ = \alpha_{1-} + \alpha_{2-}$$

Scanned with CamScanner

Dual problem :

سراحاکزین کنیم با چیزی که به دست آوردیم

$$L(\alpha) = \frac{1}{2}\left(\sum_i \alpha_i y_i x_i\right).\left(\sum_j \alpha_j y_j x_j\right) - \left(\sum_i \alpha_i y_i x_i\right)\left(\sum_j \alpha_j y_j x_j\right) -$$

$$\sum_i \alpha_i y_i b + \sum_i \alpha_i$$

$$\Rightarrow L(\alpha) = -\frac{1}{2}\sum_{i=1}^{m}\sum_{j=1}^{m} \underbrace{\alpha_i \alpha_j}_{\text{عدد}} \underbrace{y_i y_j}_{\text{۱ یا -۱}} \underbrace{x_i . x_j}_{\text{بردار}} + \sum_{i=1}^{m} \alpha_i \qquad \alpha_i \geq 0, \forall i$$

این فرم بسته به α درجه ۲ است و حلش مشکل است

نکته: فضای مسئله SVM یک فضای convex (محدب) است و در local Min ، local Max

m تعداد داده‌ها بردار پشتیبان

گیر می‌کند.

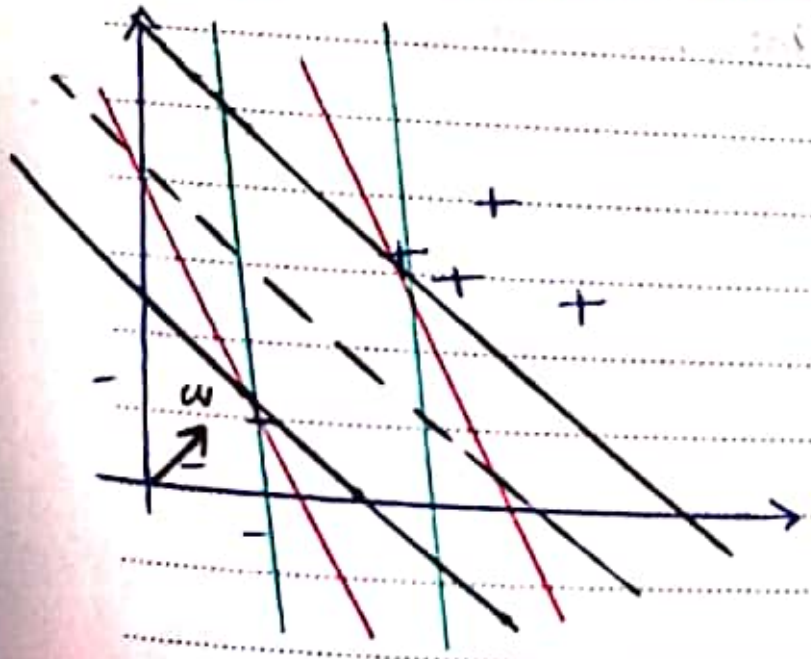
قانون دسته بندی:

$$\sum_{i=1}^{m} \alpha_i y_i x_i . x_{test} + b \geq 0 \Rightarrow \text{class is } +$$

Scanned with CamScanner

جلسه چهاردهم - ۱۴۰۰/۱/۳۱

Support Vector Machines (SVMs)



فرض اولیه: $h: X \longrightarrow \{-1, +1\}$

← ایده ← خیابانی که عریض‌تر است بهتر داده‌ها را جدا می‌کند

به آن رویکرد "عریض‌ترین خیابان" هم گفته می‌شود

در شکل روبه‌رو خط سیاه‌رنگ، داده‌ها را بهتر جدا می‌کند

مرز تصمیم ← خطی که از وسط خیابان می‌گذرد

margin ← فاصله بین داده‌ها و مرز تصمیم

ولادت امام حسن مجتبی (ع)(۳ هـ ق)و روز اکرام

← max margin را عریض‌ترین خیابان دارد

Scanned with CamScanner

معادله خط مرز تصمیم:

$$w.x + b = 0$$

یا

$$w^T x + b = 0$$

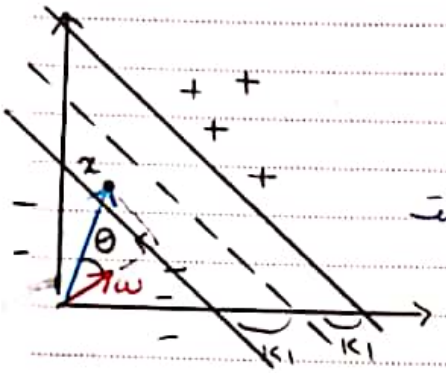
w بر خیابان عمود است.

ضرب داخلی مکوس هم است ← اسکالر $\begin{bmatrix} x_1 \\ x_2 \end{bmatrix} \rightarrow [w_1 \quad w_2]$

w و b ← هر دو ناشناخته هستند

۲ تا پارامتر داریم که باید برآورد کنیم

شیوه‌ی دسته‌بندی:



ضرب داخلی داده تست در بردار w: $w.x_{test}$

یک بردار از مبدا به داده تست رسم می‌کنیم، ضرب داخلی بردار داده تست در بردار w:

$$|w||x_{test}|\cos\theta$$

↳ اندازه تصویر بردار تست بر روی w ضربدر اندازه w

اگر تصویر داده تست روی بردار w به مرز تصمیم نرسد ← کلاس = دیگر نه مثبت

اگر بردار w را اینگونه فرض کنیم ← فقط کافیه حاصل تصویر رو در یه عدد ثابت بگیریم (همیشه یه عدد)

if $w.x_{test} \geq c$ then class is +

if $w.x_{test} + b \geq 0$ then class is +, s.t. $b = -c$

دو تا محدودیت می‌گذاریم:

راست: $w.x_+ + b \geq 1 \quad (y=+1)$

چپ: $w.x_- + b \leq -1 \quad (y=-1)$

$w_1 x_+ + b_1 = |k_1| \div k_1$

$\left(\frac{w_1}{k_1}\right) x_+ + \left(\frac{b_1}{k_1}\right) = 1$ ($\frac{w}{k}$)

معادله خط وسط: $w.x + b = 0$

معادله خط راستی: $w.x + b = 1$

چپ: $w.x + b = -1$

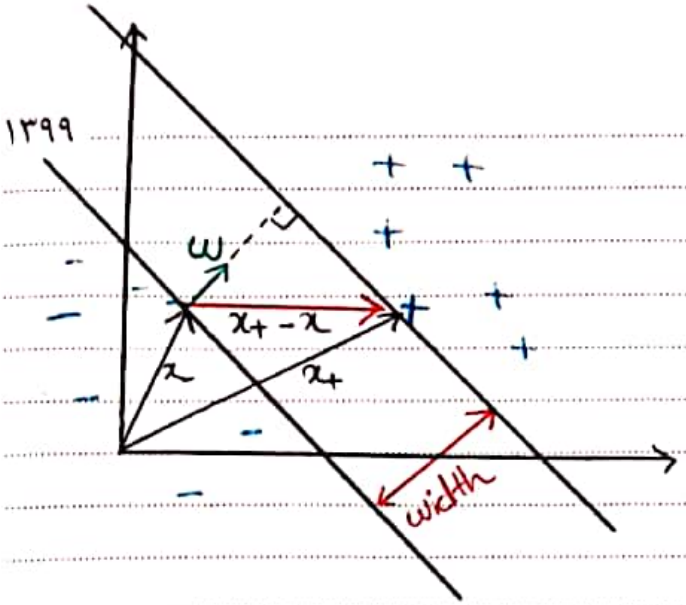
$y_i(w.x_i + b) - 1 \geq 0, \forall i$

support vector: داده‌هایی که روی خود خیابان قرار گرفته‌اند

$y_i(w.x_i + b) - 1 = 0$ iff x_i is a support vector

بردار w را با همان اندازه و همان راستا از مبدأ شیفت می‌دهیم ← پیکان w ← کماکان عمود بر خیابان است

Scanned with CamScanner



ضرب داخلی $x_+ - x_-$ در w به ما عرض خیابان را می‌دهد (w بردار یکه است)

↓

به دنبال max کردن عرض خیابان هستیم

← یک مسئله بهینه‌سازی

$$width = (x_+ - x_-) \cdot \frac{w}{\|w\|} = (w.x_+ - w.x_-) \cdot \frac{1}{\|w\|} = \frac{2}{\|w\|}$$

طبق دو تا محدودیتی که اول داشتیم: $w.x_+ + b = 1 \;,\; w.x_- + b = -1$

هدف ما max کردن $\frac{2}{\|w\|}$ است ← معادل min کردن $\|w\|$ ← معادل min کردن $\frac{1}{2}\|w\|^2$

محدودیتی که داریم: $y_i(w.x_i + b) - 1 \geq 0$ (با استفاده این محدودیت را باید حل کنیم)

می‌توانیم محدودیت را بیاوریم درخود معادله و با ضرایب لاگرانژ آن‌ها را از بین ببریم

primal problem:

$$L(w,b) = \frac{1}{2}\|w\|^2 - \sum_i \alpha_i \left[y_i(w.x_i + b) - 1 \right] \qquad \alpha_i \geq 0, \forall i$$

هدف min کردن L نسبت به w و b است. مشتق می‌گیریم نسبت به هر دو:

$$\frac{\partial L(w,b)}{\partial w} = w - \sum_i \alpha_i y_i x_i = 0 \rightarrow \boxed{w = \sum_i \alpha_i y_i x_i}$$ ← w را به ما می‌دهد

$$\frac{\partial L(w,b)}{\partial b} = -\sum_i \alpha_i y_i = 0 \rightarrow \boxed{\sum_i \alpha_i y_i = 0}$$ ← نقش یا وزن α در مورد بردارها پشتیبان $+1$ و -1 را می‌گوید

α_i برای داده‌های غیر بردار پشتیبان برابر ۰ است در نتیجه فقط بردارهای پشتیبان در این ستاری نقش دارند.

y یا ۱ است یا ۱- . مثال:

$$\alpha_+ - \alpha_{1-} - \alpha_{2-} = 0$$

$$\Rightarrow \alpha_+ = \alpha_{1-} + \alpha_{2-}$$

Scanned with CamScanner

: Dual problem

سراغ کلاسیفایر میریم که به دست آوردیم

$$L(\alpha)=\frac{1}{2}\left(\sum_i \alpha_i y_i x_i\right).\left(\sum_j \alpha_j y_j x_j\right)-\left(\sum_i \alpha_i y_i x_i\right)\left(\sum_j \alpha_j y_j x_j\right)-$$

$$\sum_i \alpha_i y_i b + \sum_i \alpha_i$$

$$\Rightarrow L(\alpha)=-\frac{1}{2}\sum_{i=1}^{m}\sum_{j=1}^{m}\alpha_i\alpha_j y_i y_j x_i.x_j+\sum_{i=1}^{m}\alpha_i \qquad \alpha_i \geq 0, \forall i$$

(عدد | ۱ یا ۱- | برحسب)

این فرم بسته به α درجه ۲ است و حلش مشکل است

نکته: فضای مسئله SVM یک فضای convex (تک) است و در local Max , local Min

m تعداد داده‌های برداری‌شان

$$\sum_{i=1}^{m}\alpha_i y_i x_i.x_{test}+b \geq 0 \Rightarrow \text{class is } +$$

گیر می‌کند.

قانون دسته بندی:

جلسه پانزدهم ـ ۱۴۰۰/۲/۵

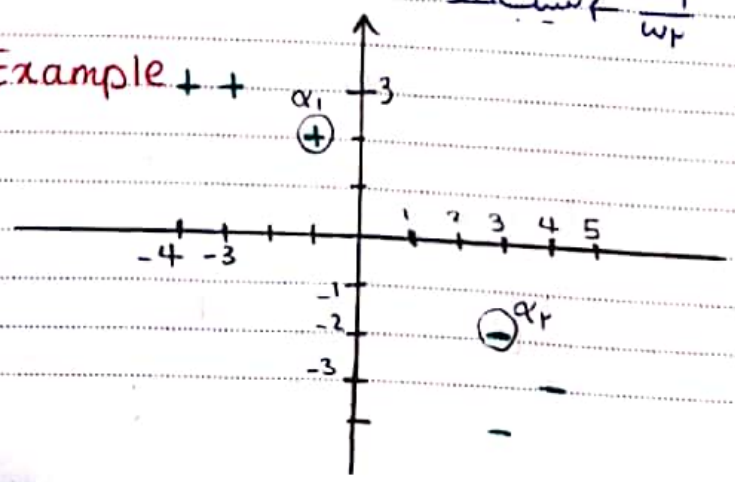
$w^T x+b=0 \xrightarrow{\text{فرم برداری}} \bar{w}.\bar{x}+b=0$

$w=\begin{bmatrix}w_1\\w_2\end{bmatrix}, x=\begin{bmatrix}x_1\\x_2\end{bmatrix} \Rightarrow w^T x+b=w_1x_1+w_2x_2+b=0$

$\Rightarrow$ فرم استاندارد (غیر برداری): $x_2=\frac{-w_1x_1}{w_2}-\frac{b}{w_2}$ (x_2 تابع x_1 و در معادله خط است)

$\frac{-w_1}{w_2} \leftarrow$ شیب خط $\qquad \frac{-b}{w_2} \leftarrow$ عرض از مبدأ

SVM Example



* در شکل روبه رو support vector ها کدام نقاط هستند؟

(3, -2), (-1, 2)

شب قدر

Scanned with CamScanner

برای support vector ها باید α های متناظرشان را به دست آوریم برای بقیه داده‌ها $\alpha_i = 0$ می‌باشد.

رابطه Dual:

$$L(\alpha) = -\frac{1}{2}\sum_i\sum_j \alpha_i\alpha_j y_i y_j x_i . x_j + \sum_i \alpha_i$$

$\alpha_i, \alpha_j > 0$ ← x_j, x_i هستند support vector

$$L(\alpha) = -\frac{1}{2}\left(\alpha_1\begin{bmatrix}-1\\2\end{bmatrix} - \alpha_2\begin{bmatrix}3\\-2\end{bmatrix}\right).\left(\alpha_1\begin{bmatrix}-1\\2\end{bmatrix} - \alpha_2\begin{bmatrix}3\\-2\end{bmatrix}\right) + \alpha_1 + \alpha_2$$

$$= -\frac{1}{2}(\alpha_1^2 + 4\alpha_1\alpha_2 + 9\alpha_2^2 + 4\alpha_1^2 + 8\alpha_1\alpha_2 + 4\alpha_2^2) + \alpha_1 + \alpha_2$$

$$= -\frac{1}{2}(5\alpha_1^2 + 12\alpha_1\alpha_2 + 13\alpha_2^2 - 2\alpha_1 - 2\alpha_2)$$

$$\Rightarrow \begin{cases} \dfrac{\partial L(\alpha)}{\partial \alpha_1} = 10\alpha_1 + 12\alpha_2 - 2 = 0 \quad (I) \\ \dfrac{\partial L(\alpha)}{\partial \alpha_2} = 12\alpha_1 + 26\alpha_2 - 2 = 0 \quad (II) \Rightarrow \begin{cases} 4\alpha_1 + 10\alpha_2 = 1 \\ \alpha_1 = \alpha_2 \end{cases} \Rightarrow \boxed{\alpha_1 = \alpha_2 = \frac{1}{14}} \\ \sum_i \alpha_i y_i = 0 \quad (III) \leftarrow \text{همیشه این رابطه را هم داریم} \end{cases}$$

دقت کنید که فقط (I) و (II) را می‌توانیم با هم ترکیب کنیم. ترکیب کردن (III) با قدرت α های دیگر و منفی با هم داده

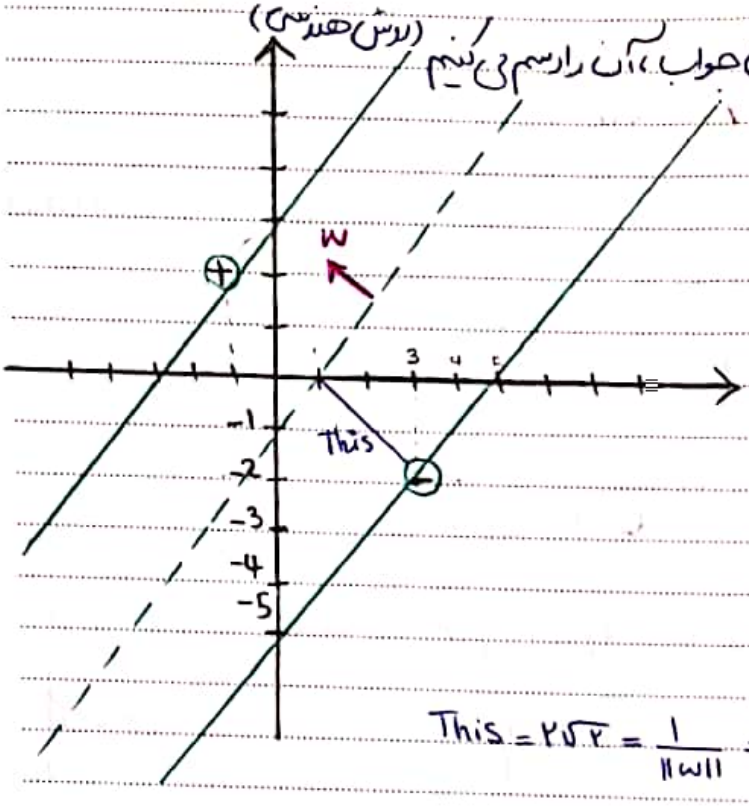
(I) یا (II) جواب اشتباهی به ما می‌دهد. رابطه (III) از مشتق رابطه نسبت به b به دست آمده بود اما (II) از مشتق رابطه نسبت به w به دست آمده بود.

$$\begin{cases} w = \sum_i \alpha_i y_i x_i \Rightarrow w = \frac{1}{14}\begin{bmatrix}-1\\2\end{bmatrix} - \frac{1}{14}\begin{bmatrix}3\\-2\end{bmatrix} \Rightarrow w = \begin{bmatrix}-1/4\\1/4\end{bmatrix} \\ y_i(w.x_i + b) - 1 = 0 \Rightarrow \begin{bmatrix}-\frac{1}{4} & \frac{1}{4}\end{bmatrix}\begin{bmatrix}-1\\2\end{bmatrix} + b - 1 = 0 \Rightarrow \boxed{b = 1/4} \end{cases}$$

ضربت خوردن امام علی (ع) (۴۰ هـ ق)

Scanned with CamScanner

نکته: در SVM بردار w همواره به سمت داده‌های مثبت قرار می‌گیرد. داده‌های مثبت را follow می‌کند.



Verification ← برای اطمینان از درستی جواب، آن را رسم می‌کنیم

معادله‌ی خط جداکننده: $x_2 = x_1 - 1$

$w \cdot x + b = 0 \rightarrow w_1 x_1 + w_2 x_2 + b = 0$

$x_2 = -\frac{w_1}{w_2} x_1 - \frac{b}{w_2}$

$$\begin{cases} x_2 = -\frac{w_1}{w_2} x_1 - \frac{b}{w_2} \\ x_2 = x_1 - 1 \end{cases} \Rightarrow \frac{w_1}{w_2} = -1$$

$$\frac{b}{w_2} = 1$$

$$This = 2\sqrt{2} = \frac{1}{\|w\|} \Rightarrow \|w\| = \frac{\sqrt{2}}{4} = \sqrt{w_1^2 + w_2^2}$$

شب قدر

۲۶ | اردیبهشت | جمعه

۲۱ رمضان ۱۴۴۱

15 May 2020

$$\begin{cases} w_1 = -k \\ w_2 = k \quad (k>0) \\ b = k \end{cases} \Rightarrow \begin{cases} \sqrt{w_1^2 + w_2^2} = \frac{\sqrt{2}}{4} \\ \sqrt{w_1^2 + w_2^2} = \sqrt{2}\,k \end{cases} \Rightarrow \begin{cases} w_1 = -1/4 \\ w_2 = 1/4 \\ b = 1/4 \end{cases}$$

$$\begin{cases} \alpha_+ = \alpha_- \\ \begin{bmatrix} -1/4 \\ 1/4 \end{bmatrix} = \alpha_+ \begin{bmatrix} -1 \\ 2 \end{bmatrix} - \alpha_- \begin{bmatrix} 3 \\ -2 \end{bmatrix} \Rightarrow \end{cases} \boxed{\alpha_+ = \alpha_- = 1/14}$$

دقت کنید که کامپیوتر از این روش استفاده نمی‌کند و ابتدا α ها را به دست می‌آورد. در اکثر روش هندسی مورد قبول نیست.

مسئله‌هایی که تا به حال حل کردیم جداپذیر خطی بودند، SVM در مسائل جداپذیر خطی در min محلی گیر نمی‌افتد.

راه حل SVM ها یک تابع نگاشت ϕ داده‌ها را به ابعاد بالاتر منتقل می‌کنیم و آن‌ها را بایک صفحه از هم جدا می‌کنیم.

Scanned with CamScanner

ایده: ظاهر داده‌ها (در فضای با ابعاد بالاتر) راحت‌تر از هم جدا می‌شوند.

به این کار kernel Trick (شگرد هسته) گفته می‌شود.

$$(x_1, x_2) \longrightarrow (x_1^2, x_2^2, \sqrt{2}\, x_1 x_2)$$

اگر بخواهیم تمام داده‌ها را یکی یکی مستقل کنیم به فضای با ابعاد بالاتر باز هم به زمان زیادی دارد

$$\begin{cases} L(\alpha) = -\frac{1}{2} \sum_i \sum_j \alpha_i \alpha_j y_i y_j x_i \cdot x_j + \sum_i \alpha_i \\ h(x_{test}) = sgn\left(\sum_i \alpha_i y_i x_i \cdot x_{test} + b \right) \end{cases}$$

وقتی به ابعاد بالاتر منتقل می‌شویم α_i و α_j و y_i و y_j که عددهای اسکالر هستند تغییری نمی‌کنند (ممکنه αها عوض بشن اما باز هم اسکالر خواهند بود)

چیزی که تغییر می‌کند بردارهای x_i و x_j هستند

$$L(\alpha) = -\frac{1}{2} \sum_i \sum_j \alpha_i \alpha_j y_i y_j \phi(x_i) \cdot \phi(x_j) + \sum_i \alpha_i$$

یعنی در یک فضای جدید (که هنوز ناشناخته)، ضرب داخلی

بین $\phi(x_i)$ و $\phi(x_j)$ انجام می‌شود.

شگرد کرنل این رو میگه: یه تابع معرفی می‌کنم که ضرب داخلی را میان x_iها و x_jها حساب بده (که x_i و x_j بردارهای پشتیبان هستند) انگار به فضای دیگری منتقل شده‌ایم، ضرب داخلی را محاسبه کرده و برگشته‌ایم. بنابراین از انتقال داده‌ها به فضای جدید اجتناب می‌کند.

$$L(\alpha) = -\frac{1}{2} \sum_i \sum_j \alpha_i \alpha_j y_j \underbrace{K(x_i, x_j)} + \sum_i \alpha_i$$

تابع هسته (kernel)

شب قدر

Scanned with CamScanner

داده‌ها را از فضای X به فضای Z منتقل می‌کنیم

$$\phi : X \longrightarrow Z$$

$$L(\alpha) = -\frac{1}{2}\sum_i\sum_j \alpha_i \alpha_j y_i y_j K(x_i, x_j) + \sum_i \alpha_i$$

تابع هسته باید چه ویژگی‌هایی داشته باشد؟

۱ اولین و مهم‌ترین ـ حتما باید یک ضرب داخلی میان بردارها را حساب کند

۲ خصلت جابه‌جایی دارد $K(x_i, x_j) = K(x_j, x_i)$

۳ positive semi-definite باشد

انواع کرنل‌ها:

① کرنل خطی

$$\text{linear}\ (x_i . x_j + c)$$

اگر $c=0$ باشد ـ هگن (homogenous) می‌شود

به وضوح ویژگی‌های گفته‌شده را دارد. ضرب داخلی ای‌ام می‌دهد خصلت جابه‌جایی هم دارد

کرنل خطی در واقع عام همان کت‌های است که تا به حال داشتیم. عام عاصی که گفته شد و اسمی هم از کرنل نبود در واقع از کرنل خطی استفاده می‌کند.

② چندجمله‌ای (polynomial)

$$(\alpha x_i . x_j + c)^d \ , \ d>1$$

با dهای مختلف پیچیدگی‌های مختلف به خودش می‌گیرد

③ Gaussian RBF

$$\exp\left(-\frac{\|x_i - x_j\|^2}{2\sigma^2}\right) = \exp\left(-\gamma \|x_i - x_j\|^2\right), \gamma = \frac{1}{2\sigma^2}$$

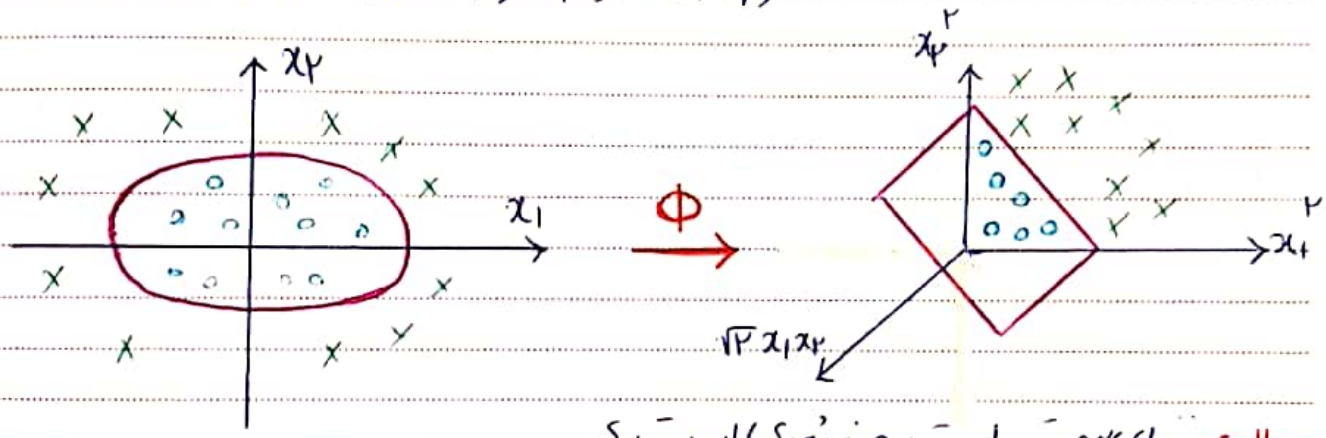
در مورد ۱ و ۲ واضح بود که ضرب داخلی ای‌ام می‌شود. در مورد سوی هم می‌دانیم که بسط به توان ۲ معادل ضرب داخلی است.

Scanned with CamScanner

پیچیدگی فضای ۲ از ۱ و ۳ از ۲ بیشتر است. اگر خواهیم داده‌ها را به یک فضای خیلی خیلی پیچیده انتقال دهیم از کرنل Gaussian RBF استفاده می‌کنیم. داده‌ها را به یک فضای بی‌نهایت بعدی منتقل می‌کند، چون وقتی می‌خواهیم رابطه آن را به صورت ضرب داخلی بنویسیم به صورت سری مک لورین بازنویسی می‌کنیم که این سری به فضای بی‌نهایت بعدی انتقال می‌دهد. RBF کرنل‌ها را دچار overfitting کند. پیچیدگی آن زیاد است.

جلسه شانزدهم - ۱۴۰۰/۲/۷

$$(x_1, x_2) \longrightarrow (x_1^2, x_2^2, \sqrt{2}x_1x_2)$$



سوال: فضای سمت راست چند بعدی است؟

ابعادی که داریم ← x_1 ، x_2 ، x_1^2 ، x_2^2 ، x_1x_2 ، ثابت (مستقل از x) ← ۶ بعد

پیشنهاد می‌شود از مدل ساده شروع کنیم و اگر جواب نداد مدل پیچیده‌تری را انتخاب کنیم.

زمان (پیچیدگی) یادگیری: rbf > poly > linear

قدرت برازش به داده‌ها: rbf > poly > linear

ریسک overfitting: rbf > poly > linear

ریسک underfitting: linear > poly > rbf

تعداد هایپرپارامترها: poly > rbf > linear

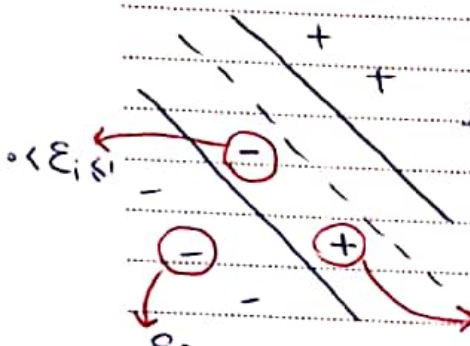
poly: α, d ، rbf: γ

Scanned with CamScanner

Soft Margin SVMs

آن چه تا به حال گفته‌ایم hard Margin SVM است یعنی نقض حاشیه‌ای در آن اتفاق نمی‌افتد. اگر اجازه بدهیم نقض حاشیه هم اتفاق بیفتد به آن Soft Margin SVM گفته می‌شود.

slack variable $\rightarrow \varepsilon_i$



① اگر $\varepsilon_i = 0$ ← داده به درستی دسته‌بندی شده،

② اگر $1 \geqslant \varepsilon_i > 0$ ← حاشیه را نقض کرده اما سمت درست حیابان است

③ اگر $\varepsilon_i > 1$ ← داده اشتباه دسته‌بندی شده و در سمت اشتباه خیابان قرار گرفته است.

محدودیت به این شکل در می‌آید:

$$y_i(w.x+b) \geqslant 1-\varepsilon_i \quad (\varepsilon_i \geqslant 0)$$

$$\text{total violation (مجموع کلی نقض حاشیه)} = \sum_{i=1}^{m} \varepsilon_i \geqslant 0$$

مسئله بهینه سازی هم به این شکل تغییر می‌کند:

$$\begin{cases} \text{minimize } \frac{1}{2}\|w\|^2 + C\sum_{i=1}^{m}\varepsilon_i \\ \text{محدودیت: } y_i(w.x+b) \geqslant 1-\varepsilon_i \ , \ \varepsilon_i \geqslant 0 \ , \ i = 1,2,\dots,m \end{cases}$$

یعنی می‌خواهیم در عین حال که عرض خیابان را max می‌کنیم (که معادل min کردن $\frac{1}{2}\|w\|^2$ بود) مقدار نقض حاشیه‌ها را هم به حداقل برسانیم.

پارامتر C ← پارامتر Regularization

روز ملی جمعیت

اگر C خیلی بزرگ باشد برای min شدن عبارت، ضریب یعنی $\sum \varepsilon_i$ باید خیلی کوچک باشد. یا به عبارتی over fitting می‌برد. متغیرهای slack هیچ نقض حاشیه‌ای نمی‌توانند داشته باشند.

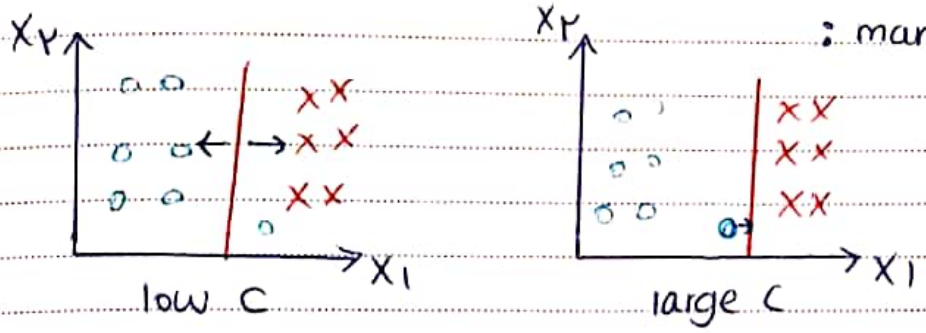
Scanned with CamScanner

داشته باشند. اگر C کم باشد اجازه تعداد نقض حاشیه به مدل می دهد.

small C — regularization parameter C — large C

underfitting ← → overfitting (hard margin)

تاثیر پارامتر C بر روی margin:



وقتی اجازه نقض حاشیه داریم، خیابان عریض تری داریم

$$L(w,b,\xi,\alpha,\beta)=\frac{1}{2}\|w\|^2+C\sum_{i=1}^{m}\xi_i-\sum_{i=1}^{m}\alpha_i\left[y_i(w.x_i+b)-1+\xi_i\right]-\sum_{i=1}^{m}\beta_i\xi_i$$

به خاطر مسئله بهینه سازی

به صرایب لاگرانژ اضافه می شود به خاطر بهینه سازی

هدف min کردن L نسبت به w و b و ξ و max کردن آن نسبت به αi و βi است

$$L(w,b,\xi,\alpha,\beta)=\frac{1}{2}\|w\|^2-\sum_{i=1}^{m}\alpha_i\left[y_i(w.x_i+b)-1\right]-\sum_{i=1}^{m}\xi_i(C-\alpha_i-\beta_i)$$

حال مشتق می گیریم:

دو مشتق اول مثل حالت قبل هستند

$$\begin{cases}\dfrac{\partial L}{\partial w}=w-\sum_{i=1}^{m}\alpha_i y_i x_i=0\\[2ex]\dfrac{\partial L}{\partial b}=-\sum_{i=1}^{m}\alpha_i y_i=0\\[2ex]\dfrac{\partial L}{\partial \xi_i}=C-\alpha_i-\beta_i=0\end{cases}$$

روز اهدای عضو، اهدای زندگی

Scanned with CamScanner

می دانستیم که ضرایب لاگرانژ همواره بزرگتر مساوی صفر هستند. پس داریم:

$$\begin{cases} C - \alpha_i = \beta_i \\ \beta_i \geq 0 \end{cases} \rightarrow \alpha_i \leq C \rightarrow \boxed{0 \leq \alpha_i \leq C}$$

اضافه کردن متغیر slack و اجازه دادن به نقض حاشیه ما را به این رساند که یک کران بالا برای α_i به دست آمد. (و از قبل هم می دانستیم که α_i ها بزرگتر مساوی ۰ اند) β_i را حذف کرد یعنی در گذشته هایی که مربوط به hard margin بود فقط لازم شد که یک کران بالا برای α_i بگذاریم تا برای soft margin هم قابل استفاده شود.

$$L(\alpha) = -\frac{1}{2}\sum_{i=1}^{m}\sum_{j=1}^{m} \alpha_i \alpha_j y_i y_j x_i . x_j + \sum_{i=1}^{m} \alpha_i \quad , \forall i$$

محدودیت: $0 \leq \alpha_i \leq C \quad , \forall i$

روز بهره وری و بهینه سازی مصرف - روز بزرگداشت ملاصدرا

۲ | خرداد | جمعه

۲۸ رمضان ۱۴۴۱

22 May 2020

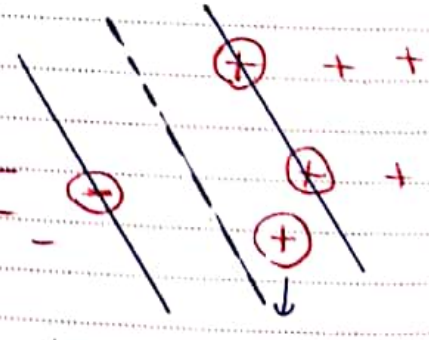
با تغییر پارامتر C می توانیم اجازه نقض حاشیه بدهیم یا نه و می توانیم عرض خیابان را کم و زیاد کنیم.

انواع support Vector

margin SV ←

مثلا فقط داده های روی حاشیه جلویی را SV در نظر می گرفتیم

این داده های کمین در تقسیم حاشیه خیابان هستند را هم non-margin SV ← SV در نظر می گیریم



این داده هم support vector است

$$\begin{cases} \text{non_SV}: \alpha_i = 0 \rightarrow y_i(w.x_i + b) > 1 \\ \text{margin SV}: 0 < \alpha_i < C \rightarrow y_i(w.x_i + b) = 1 \\ \text{non_margin SV}: \alpha_i = C \rightarrow y_i(w.x_i + b) < 1 \end{cases}$$

روز جهانی قدس (آخرین جمعه ماه رمضان)

Scanned with CamScanner

جلسه هفدهم — ۱۴۰۰/۲/۱۲

Ensembles of classifiers

یک مدل تجمیعی از دسته بندها که باهم عمل می کنند

هدف اصلی: افزایش دقت دسته بند، دسته بندی بسازیم که از تک تک دسته بندهای پایه بهتر عمل کند

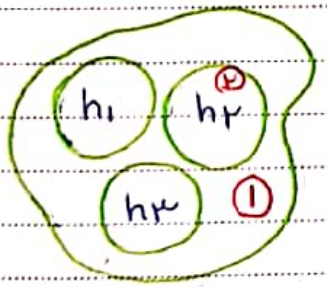
$h_1, h_2, \ldots, h_L$: L تا classifier را می خواهیم ترکیب کنیم

ترکیب می تواند وزن دار یا غیروزن دار باشد

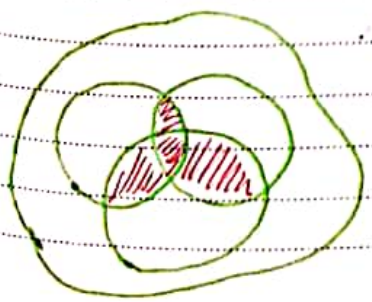
دسته بندهای پایه می توانند homogenous یا hetrogenous باشند

مثلا همه درخت تصمیم باشند مثلا SVM، KNN و نیز

سوال: چگونه می توانیم دسته بندهای پایه را تجمیع کنیم به طوری دقتش از تک تک دسته بندهای پایه بیشتر باشد؟



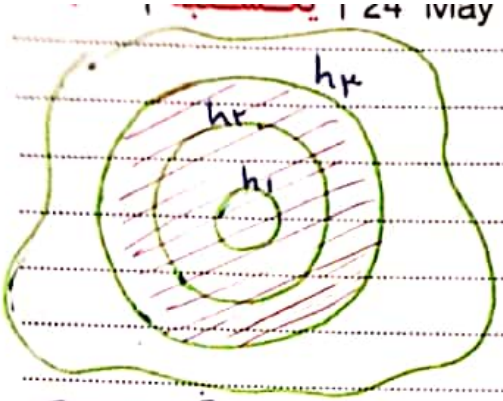
فرض کنید فضای مسئله مستطیل روبه رو باشد، دایره ها h_1، h_2 و h_3 مثل هایی هستند که دسته بندهای h_1، h_2، h_3 استاه جواب می دهند. بنابراین ترکیب این سه دسته بند، به ما دسته بندی می دهد که از تک تک h_1، h_2، h_3 بهتر عمل می کند. مثلا در نقطه ی ① هر سه دسته بند درست جواب می دهند پس ترکیبشان هم درست جواب می دهد. اگر داده در نقطه ی ② باشد h_1، h_3 درست جواب می دهد h_2 اشتباه جواب می دهد پس ترکیبشان درست جواب می دهد.



در شکل روبه رو نواحی قرمز رنگ به غلط دسته بندی می شوند

فتح خرمشهر

Scanned with CamScanner



وقتی از حالتی که تجمیع دسته بندها اوضاع را بدتر کند

در شکل روبرو ترکیب سه دسته بند h_1, h_2, h_3

از دسته بند h_1 بدتر است

بنابراین کاملا به شرایط خطای دسته بندها بستگی دارد که چقدر از هم مستقل باشند. هرچقدر

خطاها مستقل تر باشند ترکیب دسته بندها عملکرد بهتری دارد

overlap نداشته باشند

Ensemble Requirements:

① تا حایی که ممکنه دسته بندهای تکی باهم مخالفت کنند، باهم اشتراک نداشته باشند

② خطای هرکدامشان از ۵۰٪ کمتر باشد.

یعنی تصادفی عمل نکند. به همچین چیزی یک weak classifier می گویند (دسته بند ضعیف)

مثلا دسته بندی که خطایش ۴۵٪ است (نشان دهنده مقداری از ۵۰٪ بیشتر است. از دسته بند تصادفی

کمتر عمل می کند ولی در کل دسته بند ضعیفی است. یک هدف در روش های Ensemble این است

که با ترکیب یک سری weak classifier یک strong classifier داشته باشیم.

③ خطاها تا حایی که ممکنه uncorrelated باشند

دو دسته کلی از روش های Ensemble:

① Bagging (bootstrap aggregation)

② Boosting

عبارت هایی که ترکیبی از دسته بندهای heterogenous اطلاق می شود:

Stacking, blending, voting

عید سعید فطر (تعطیل)

Scanned with CamScanner

"Bagging"

m تا داده‌ی آموزشی داریم. میایم L تا دسته تصادفی با جایگذاری از این m تا برمیداریم.

(bootstrap step) هرکدام از L تا احتمالا حدود ٪۶۳ از داده ها را شامل می شود

این L تا را زیرمجموعه‌ای می سازیم شبیه به داده های اصلی هست اما عیناً یکی نیست چون

داریم جوان با جایگذاری برمیداریم ممکنه به تعدادی تکرار شده باشند

پس تا الان L تا دیتاست برای سن دیتاست اولیه‌مان ساخته‌ایم. به هرکدام از دسته‌بندهای

(h_1 تا h_L) داده‌ی مخصوص خودش را می دهیم و L تا مدل می سازیم.

(aggregation step) بعد بین مدل‌ها رأی‌گیری می کنیم

$$h : X \longrightarrow \{-1, +1\}$$

unweighted voting ← در bagging معمولا ترکیب‌مان غیر وزن دار است

چون خود دیتاست‌ها با هم متفاوتند انگار مفهوم وزن در خود دیتاست در نظر گرفته می شود

$$h(x_{test}) = \text{sgn}\left[h_1(x_{test}) + h_2(x_{test}) + \dots + h_L(x_{test})\right]$$

نکته: هرکدام از دسته‌بندهای Bagging دیتاست خودش را دارد که با دیتاست اصلی هم

متفاوت است پس دسته‌بند اصلی نمی تواند داده‌های اولیه را حفظ کند (و به خاطر بسپارد)

بنابراین جوابی که هرکدام از دسته‌بندهای دهد نمی تواند overfit کند.

⇐ این اصلی Bagging کاهش overfitting است

Bagging را روی هر الگوریتمی می توان اجرا کرد اما جایی که improvement چشمگیر و قابل توجه

است وقتی است که دسته‌بندهای پایه unstable باشند یعنی

تعطیل به مناسبت عید سعید فطر

Scanned with CamScanner

با تغییر کوچک در داده‌های آموزش، خیلی نتیجه‌شان متفاوت شود ← واریانس بالا، بایاس کم

واریانس دقتی زیاد است استعداد overfitting بالا است. با ترکیب این‌ها (1)، استعداد overfitting را پایین می‌آوریم. هم‌چنین اینکه داده‌ها را حفظ نمی‌کند و دیتاست اصلی را نگه می‌دارد (2)

هم موجب کاهش overfitting می‌شود

← یک گزینه خیلی خوب برای Bagging درخت‌های تصمیم هستند

Bagging برای مدل‌های خطی عمل نمی‌کند. چرا؟

اینکه برای مدل‌های خطی عمل نمی‌کند بدین معنی نیست که کار نمی‌کند یا بهبود نمی‌دهد. بدین معناست که بهبودش قابل توجه نیست. چون مدل اگر خطی باشد، ترکیبش هم خطی است و بهبود چندانی ندارد.

← مثال دیتاست iris در اسلایدها هم است

در مثال iris، با افزایش تعداد دسته‌بندهای پایه (درخت‌ها) overfitting الگوریتم کاهش یافته (واریانس)

الگوریتم Random Forest

همان دیتاکس‌هایی که در این جلسه گفته شد را دارد، برای ایجاد تنوع بیشتر در دسته‌بندهای اولیه (پایه)

این خود ویژگی‌ها (Features) هم میاد زیرمجموعه‌ای را انتخاب می‌کنه.

الگوریتم‌های یادگیری ماشین کلاسه دو دلیل خوب کار می‌کنند.

یکی واریانس بالا ← bagging سعی می‌کند آن را برطرف کند

یکی بایاس بالا ← boosting سعی ″ ″ ″ ″

Scanned with CamScanner

جلسه هجدهم - ۱۴۰۰/۲/۱۹

"Boosting"

هدف اصلی آن کاهش بایاس است، هرچند ممکن است باعث کاهش واریانس هم بشود

برخلاف bagging که دسته بندهای پایه را به صورت غیروزن دار ترکیب می کند، boosting

این کار را به صورت وزن دار انجام می دهد.

معروف ترین الگوریتم های دسته boosting، Adaboost است

(adaptive boosting)

AdaBoost Training phase

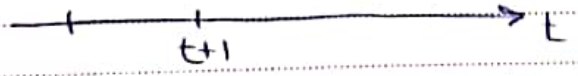
ما وزن داریم. یکی اینکه به هر دسته بندی که بعدا می خواهیم باهم ترکیبشان کنیم یک وزن اختصاص

می دهیم. قبل از آن، به هرکدام از داده ها وزنی را اختصاص می دهیم.

$$\begin{cases} w_i^1 = \frac{1}{m} & i = 1, 2, \dots, m \\ \epsilon^1 = \sum_i w_i^1 & \text{داده هایی که در مرحله 1 ام اشتباه دسته بندی شده اند} \end{cases}$$

الگوریتم boosting یک الگوریتم sequential است

یعنی بُعد زمان مطرح است



یعنی الگوریتمی که در زمان t+1 ساخته می شود براساس زمان قبلی آن (t) ساخته می شود

اندیس بالایی در w_i^1 به زمان اشاره می کند یعنی داده i ام در زمان 1.

در ابتدا اطلاعات خاصی در مورد داده ها نداریم و به هرکدام وزن یکسانی می دهیم.

$$\epsilon^t = \sum_i w_i^t$$ ← خطای کل در گام t ام

AdaBoost final classifier

$h: X \rightarrow \{+1, -1\}$

: weighted voting

$$h(x_{test}) = sgn\left[\alpha^1 h^1(x_{test}) + \alpha^2 h^2(x_{test}) + \dots\right]$$

الگوریتم boosting معمولا از دسته‌بند پایه decision stump (درخت تصمیم با عمق ۱) استفاده می‌کند)

← مثال از boosting در اسلایدهای خصمه

update شدن وزن‌ها در مراحل بعدی:

$$\begin{cases} w_i^{t+1} = \frac{w_i^t}{Z^t} \times \exp\left[-\alpha^t h^t(x_i)\, y(x_i)\right] \\ \alpha^t = \frac{1}{2} \ln \frac{1-\epsilon^t}{\epsilon^t} \end{cases}$$

خرداد ۹ | جمعه

۶ شوال ۱۴۴۱

29 May 2020

Z ← ضریب normalization، برای اینکه به صورت توزیع باشند و جمعشان ۱ شود.

$h^t(x_i)$ ← دسته‌بند زمان t چه چیزی اعلام می‌کند؟

$h^t(x_i)$ و $y(x_i)$ یا ۱ اند یا ۱-

α ← وزن

اگر وزن‌ها را جایگذاری کنیم:

$$w_i^{t+1} = \frac{w_i^t}{Z^t} \times \begin{cases} \sqrt{\frac{\epsilon^t}{1-\epsilon^t}} & h^t(x_i) = y_i \\ \sqrt{\frac{1-\epsilon^t}{\epsilon^t}} & h^t(x_i) \neq y_i \end{cases}$$

Scanned with CamScanner

۱۳۹۹ $1-\epsilon^t$ ϵ^t تعریف b،

ضریب نرمال سازی :

$$Z^t = \sum_i w_i^t \times \sqrt{\frac{\epsilon^t}{1-\epsilon^t}} + \sum_i w_i^t \times \sqrt{\frac{1-\epsilon^t}{\epsilon^t}} = 2\sqrt{\epsilon^t(1-\epsilon^t)}$$

به درستی دسته بندی شده است

اشتباه دسته بندی شده است

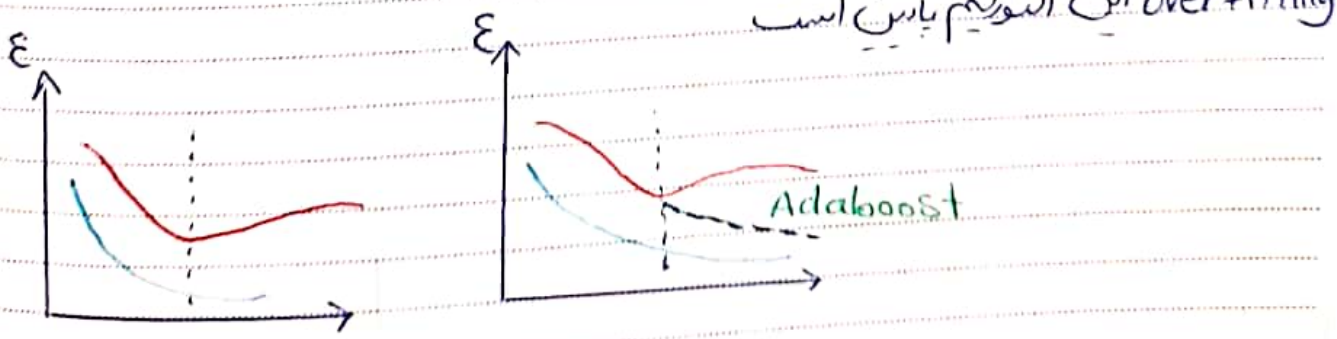
حالا Z^t را در رابطه update کردن وزن ها جایگذاری می کنیم :

برای داده ای درست دسته بندی شده ←	$w_i^{t+1} = \frac{w_i^t}{2} \times \frac{1}{1-\epsilon^t}$ $\quad h^t(x_i) = y_i$
برای داده های اشتباه دسته بندی شده ←	$w_i^{t+1} = \frac{w_i^t}{2} \times \frac{1}{\epsilon^t}$ $\quad h^t(x_i) \neq y_i$

w وزن خود داده هاست و α_t وزن یک دسته بند است در یک مرحله

این الگوریتم روی خود داده ها کار می کند و مثل الگوریتم های instance based است. الگوریتم هایی که این طوری اند قاعدتاً به نویز خیلی حساس هستند

adaboost به نویز و outlier خیلی حساس است اما اگر داده ها نویز نداشته باشند اسیر داد over fitting این الگوریتم پایین است



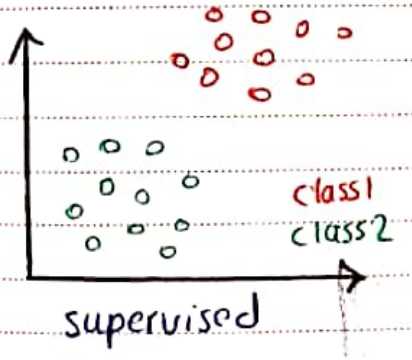
Scanned with CamScanner

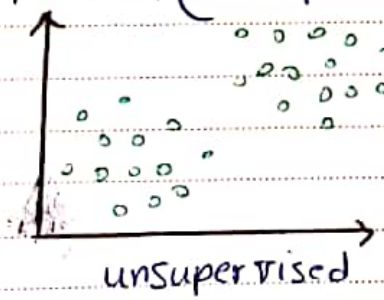
جلسه نوزدهم ـ ۱۴۰۰/۲/۲۸

از ابتدای ترم الگوریتم هایی که بررسی کرده ایم، شامل رگرسیون و بعد الگوریتم های دسته بندی، همه ی این ها نمونه هایی از الگوریتم های supervised (با نظارت) بوده اند.

داده های آموزش مان هم به صورت مجموعه ای از فیچر ها به همراه برچسب ها بوده است. به این مدل ها، مدل های predictive (پیش گویانه) اطلاق می شود.

در مقابل این مدل ها، مدل هایی هستند که عمدتا حالت descriptive دارند و داده ها را توصیف می کنند (چه آرایشی دارند، کدام کدام نزدیک هستند). مجموعه ای از tuple ها یا Feature vector هایی داریم که هیچ برچسبی هم ندارند





$D1_{train} = \{(X_1, y_1), (X_2, y_2), \dots, (X_m, y_m)\}$ $D2_{train} = \{X_1, X_2, \dots, X_m\}$

در کنار unsupervised هدف ما این است که ساختاری از داده ها کشف کنیم (discovery)

چرا می خواهیم این ساختارها را کشف کنیم؟

در واقع یک نمایش با معنی تری از داده هایی توانیم داشته باشیم.

Scanned with CamScanner

چند تا از task های معروف unsupervised learning:

① کاهش بُعد (Dimensionality Reduction) ③ خوشه‌بندی (clustering)

② تخمین چگالی (Density Estimation) ④ می‌تواند به عنوان مرحله پیش پردازش برای الگوریتم های یادگیری ماشین بشه

Dimensionality Reduction

مثلا ← autoencoder ، LSH

- کاهش بعد همیشه unsupervised نیست، حالت supervised هم دارد.
- the curse of dimensionality (مشکل کاهش ابعاد)

مثال supervised ← LDA (سعی می‌کند ویژگی‌هایی که از هم متفاوت‌تند و هدیگر را پوشش نمی‌دهند انتخاب کنه)

مثال unsupervised ← PCA (تحلیل مولفه اصلی) ← سعی می‌کند داده ها را در جهتی قرار دهد که واریانس بین مولفه‌های اصلی max شود. SVD هم مثالی از unsupervised است

Density Estimation

می‌خواهیم یک تابع چگالی احتمال براساس داده‌هایی که داریم تخمین بزنیم

هیستوگرام ساده‌ترین حالت جواب به این سوال است.

parzen window or kernel density estimation: تابع f را توسط ترکیبی از توزیع های پیوسته تخمین می‌زنند

مثالی از حالت unsupervised است.

خوشه‌بندی (clustering)

داده‌هایی داریم که می‌خواهیم برحسب برای فاصله به خوشه‌هایی تقسیم کنیم.

نیازی به برچسب ندارد.

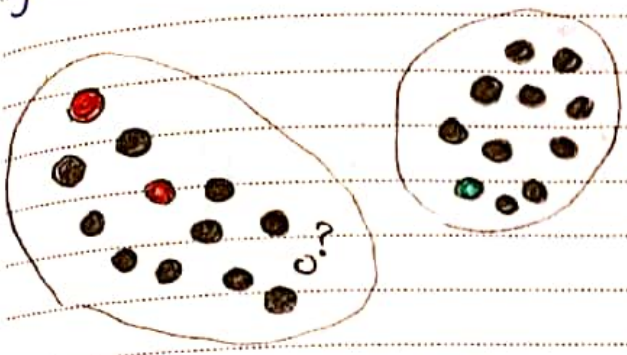
خوشه‌بندی می‌تواند در پیش پردازش روش های semi-supervised استفاده شود

روز صنایع دستی

Scanned with CamScanner

۱۳۹۹

Semi_Supervised ← مقداری از داده ها برچسب دارند که به آن ها ground truth گفته می شود. بیشتر داده ها برچسب ندارند



Intra_cluster distance ← فاصله ی بین داده های یک cluster

Inter_cluster distance ← فاصله ی داده های clusterهای مختلف

هدف ما این است که اولی min و دومی max شود

کاربرد خوشه بندی:

خوشه بندی اخبار، تحلیل احساسات، پزشکی، Market Segmentation، دسته بندی مشتریان، Anomaly detection ← احتمال داده هایی که در خوشه ها قرار نمی گیرند

روش های اصلی clustering:

① partitioning_based ← باید تعداد خوشه ها مشخص باشد

مثال: k_means, k_medoids, CLARA, CLARANS

② Density_based ← بیشتر از مسائل توسط دسته اول حل می شوند چون نمی توانند با خط از هم جدایشون کنیم. از جایی استفاده می کنیم. لازم نیست تعداد خوشه ها مشخص باشد

مثال: DBScan

③ Model_based

از یک مدل استفاده می کند

مثال: EM, SOM. الگوریتم K-means مثال خاص مدل EM است

یه شبکه عصبی است

Scanned with CamScanner

④ Hierarchical (سلسله مراتبی)

مثال ← Agnes ، Diana ، BIRCH ، CURE

⑤ Grid_based ← شبکه بندی می کنند

⑥ Frequent_pattern_based ← مثال p_cluster

⑦ Support Vector ← مثال: SVC ، k_means ، Kernel

⑧ Graph Theoretic ← مثل spectral clustering

partitioning_based Approach

مثال ← k_mean . K باید به الگوریتم داده شود به عنوان ورودی ← ابرپارامتر است

بین k_means ، non_parametric است

الگوریتم شامل ۲ بخش است:

① بقیه داده ها به خوشه ها آپدیت می شود

② مراکز خوشه ها (که ممکنه در ابتدا به صورت تصادفی انتخاب شده باشند) آپدیت می شود به گونه ای که واقعا میانگین داده های درون خوشه را نشان دهد

این دو مرحله آنقدر تکرار می شود تا همگرایی حاصل شود

z_i کلاستر مربوط به داده ی i ام است: $z_i = \arg\min_c \|x_i - \mu_c\|^2 \quad \forall i$

$\forall c, \ \mu_c = \frac{1}{m_c} \sum_{i \in S_c} x_i$ هر کلاستر را با میانگین داده های assign شده

$S_c = \{i : z_i = c\}, \ m_c = |S_c|$ به آن کلاستر نشان می دهیم

مقداردهی اولیه مراکز خوشه ها خیلی تاثیرگذار است.

خرداد ۲۳ جمعه

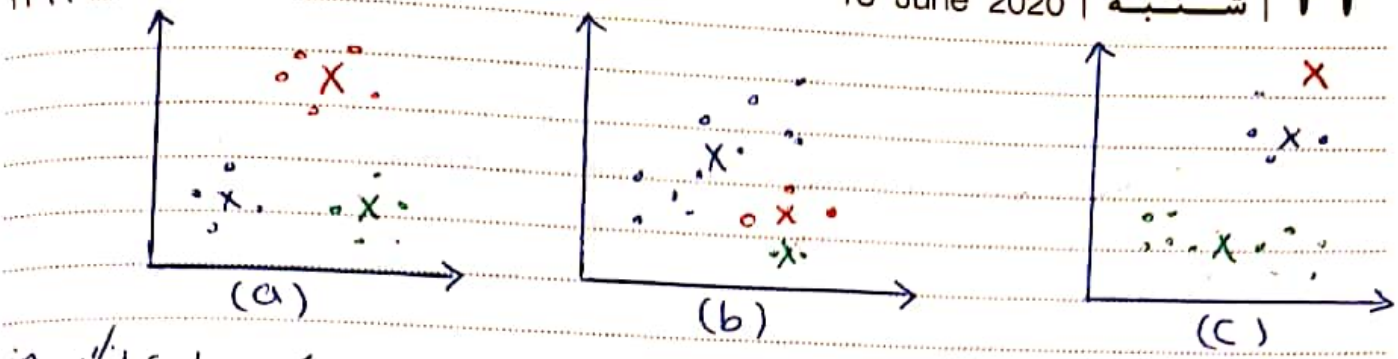
۲۰ شوال ۱۴۴۱

12 June 2020

Scanned with CamScanner

داده‌های یکسان و خوشه‌بندی آنها با مراکز اولیه متفاوت:

۱۳۹۹



در b) انگار در min محلی گیر افتاده ایم. به راه استفاده از randomness است

راه حل: تعداری مقادیر اولیه اجام بدهیم و بعد بهترین را انتخاب کنیم

یه راه حل هم اینه که سعی کنیم مراکز خوشه‌ها تا حد ممکن از هم دور باشند

K_means++ ← تفاوتش با K_means در مقادیر اولیه است که سعی می‌کند مراکز اولیه تا حد ممکن از هم فاصله داشته باشند.

* معیارهای فاصله:

فاصله منهتن ← l_1 norm (Manhatan Distance)

فاصله اقلیدسی ← l_2 norm (Euclidean Distance)

Cosine Similarity (شباهت کسینوسی)

* Centroids: K_means ← استاندارد از Mean و l_2 استفاده می‌کند

Mean (میانگین) ← خیلی نسبت به outlier حساس است

Median (میانه) ← حساسیت کمتری نسبت به outlier دارد

Medoid ← شبیه میانگین است ولی حتما باید یکی از خود اعداد باشد. مثلا وقتی در مورد گران صحبت می‌کنیم نمی‌توانیم یه عدد جدید بسازیم باید یکی از خود عددها را انتخاب کنیم. پس بهتره از medoid استفاده شود.

ویژگی‌های K-means

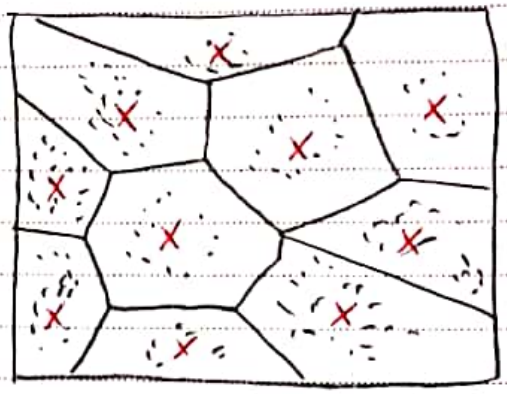
① Instance-based: فاصله تک تک داده‌ها با مراکز کلاسترها سنجیده می‌شود

② time complexity: $O(tkm)$ ← پیچیدگی زمانی پایین دارد

Scanned with CamScanner

④ non_parametric (غیرپارامتری)

انگار مجموعه‌ای از خطوط داره‌ها را جدا کرده‌اند و این حیطه‌هایی تشکیل شده است.



⑯ Linearly separable data (داده‌ها باید جدا پذیر خطی باشند)

← اینکه K را باید خودمان تعیین کنیم خیلی

کاربردی بزرگی نیست اما این مورد کاربردی

بزرگی است

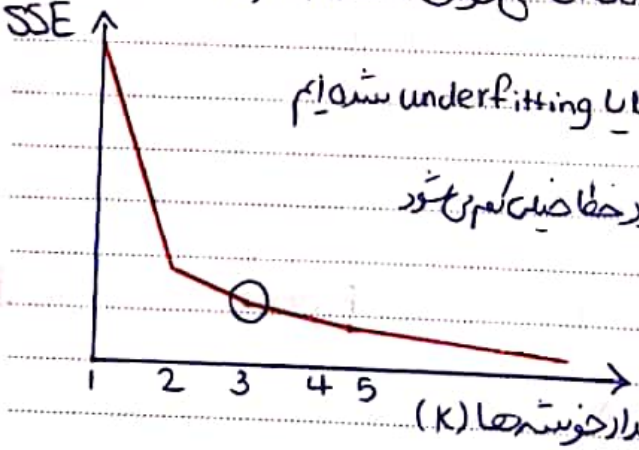
سنجش کیفیت clustering

$$SSE = \sum_k \sum_{x_i \in C_k} \|x_i - C_k\|^2$$

هدف ما این بود که فاصله اعضای داخلی

کلاستر را min کنیم که به تبع آن فاصله بین کلاستر ها زیاد می‌شود

برای پیدا کردن تعداد clusterها از روش Elbow می‌توان استفاده کرد:



ابتدا تعداد کلاسترها ↓ بوده که احتمالا رجا بیشه‌ی بایاس بالا یا underfitting شده‌ایم

بعد با افزایش K میزان خطا کم شده، از یجایی به بعد میزان بهبود خطا خیلی کم می‌شود

از جایی که بهبود خطا کم می‌شود دیگه ادامه نمی‌دهیم و همان تعداد K

خوب است.

K_means Variations

① K_medoids / PAM (partitioning Around Medoids)

② CLARA (Clustering Large Applications) ← برای داده‌های حجیم استفاده می‌شود

③ CLARANS (a clustering Algorithm based on Randomized Search)

Scanned with CamScanner

جلسه بیستم ـ ۱۴۰۰/۳/۲

گفتیم وقتی که داده‌ها نرم‌گرایی دارند از medoid استفاده می‌کنیم که خوشه‌ها حفظ آماری medoid باید خود داده‌ها باشد.

PAM Algorithm

در مورد مراکز اولیه خوشه‌ها دقتی نمی‌کنیم به صورت تصادفی انتخاب می‌شوند سعی بر این است که تا حد امکان از هم فاصله داشته باشند

(یک مثال از الگوریتم PAM با شکل در اسلایدها آمده)

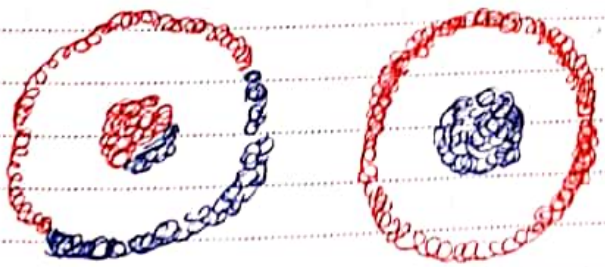
اصولا هدف از Randomness در هوش مصنوعی فرار از min محلی است.

در ابتدا k تا از داده‌ها را به عنوان medoid انتخاب کرده و داده‌ها را به خوشه‌های مناسب‌شان assign کرده، بعد فاصله داده‌ها تا هر خوشه از medoid حساب کرده و جمع کرده، بعد به صورت رندوم یک نقطه غیر medoid را به عنوان مرکز کلاستر انتخاب کرده و دوباره هزینه را حساب کنه، اگر هزینه کمتر پیدا کنه حالت جدید انتخاب می‌شه

برخی از variation های k-means:

① Fuzzy C-means ← یک داده می‌تواند به چند کلاستر متعلق باشد. کلاسترها با هم هم‌پوشانی دارند. مثلا داده‌ی ۱ درجه تعلقش به خوشه A، ۰/۳۵ و به خوشه B، ۰/۶۵ است

② kernel K-means



شکل سمت چپ یک شکل Concave (مقعر) است. Convex هاش (محدب) نیست. به همین دلیل k-means نمی‌تواند آن را جدا کند. چون شکل جدایی‌پذیر خطی نیست و k-means سعی کرده با خط آن‌ها را از هم جدا کند. اگر از کرنل استفاده کنیم به راحتی توسط یک صفحه از هم جدا می‌شوند.

Scanned with CamScanner

الگوریتم های Density Based

الگوریتم DBScan ← در این الگوریتم نیازی نیست k (تعداد کلاسترها) را به الگوریتم بدهیم

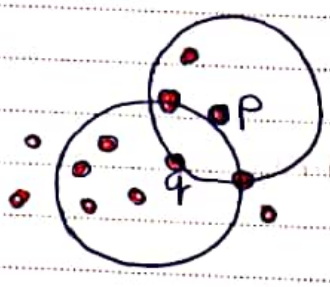
دو تا پارامتر: ϵ ← شعاع همسایگی

min # of points ← حداقل تعداد نقاطی که در همسایگی ϵ یک نقطه قرار گیرند

$N_\epsilon(q) = \{p \text{ in } D \mid d(p,q) \leq \epsilon\}$ ← همسایگی ϵ نقطه q

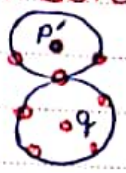
مثلا می گوییم از روی شعاع همسایگی یک نقطه حداقل ۵ تا نقطه قرار گرفتند آن را یک کلاستر می نامیم. اگر همسایگی min # of points را ارضا کرد به آن یک کلاستر می گوییم.

سه نوع داده داریم در این الگوریتم:



Core point (q) ← همسایگی حکایت از شعاع ϵ یک نقطه همسایگی را در نظر گرفتیم و از min # point بیشتر بوده

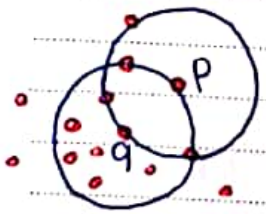
Border point (p') خودش عضو یک همسایگی حکایت نیست ولی در همسایگی یک dense neighborhood است.



outlier, noise ← نه خودش یک همسایگی حکایت را تشکیل می دهد نه می توان به آن رسید

Directly Density_reachable

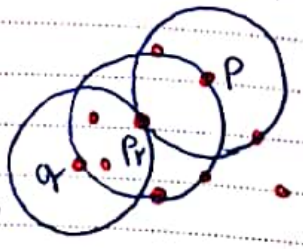
نقطه p، directly density-reachable از نقطه q است اگر: ① p در همسایگی ϵ از q باشد ($p \text{ in } N_\epsilon(q)$)



② $|N_\epsilon(q)| \geq \text{minPts}$ ← Core point Condition

Density_Reachable (ϵ, minPts)

نقطه p، density-reachable از نقطه q است اگر یک زنجیره از نقاط به صورت $p_1 = q$ و $p_n = p$ و هر نقطه p_{i+1} در این زنجیره $p_1, p_2, \ldots, p_n$ وجود داشته باشد که p_i از directly density-reachable باشد



Scanned with CamScanner

الگوریتم DBSCAN

یک نقطه p به صورت تصادفی از دیتابیس انتخاب می‌کنیم. تمام نقاط Density_reachable آن را پیدا می‌کنیم:

۱ اگر p یک core point باشد یک کلاستر شکل گرفته است

۲ اگر p یک border point باشد هیچ نقطه‌ای density_reachable از p نیست بنابراین الگوریتم نقاط بعدی دیتابیس را ویزیت می‌کند.

این فرآیند تا جایی ادامه پیدا می‌کند که همه‌ی نقطه‌ها process شوند.

Sensitivity to Parameters

حساسیت الگوریتم DBScan به پارامترهای آن:

شکل در اسلاید $\epsilon = 0.4$, $\epsilon = 0.5$ $minPts = 4$

با تغییر کوچکی در ϵ شکل خوشه‌بندی کاملا عوض شده، الگوریتمی وجود دارد که سعی دارد حساسیت را کم کند



database 3
جدایپذیر خطی نیست

database 2
جدایپذیر خطی نیست

database 1
جدایپذیر خطی است

DBSCAN هر سه تای این دیتا را می‌تواند خوشه‌بندی کند. این‌ها سه تا دیتابیس هستند که در مقاله اصلی DBSCAN از آن‌ها استفاده شده است.

Scanned with CamScanner

پنجشنبه ۳۱ | 18 June 2020

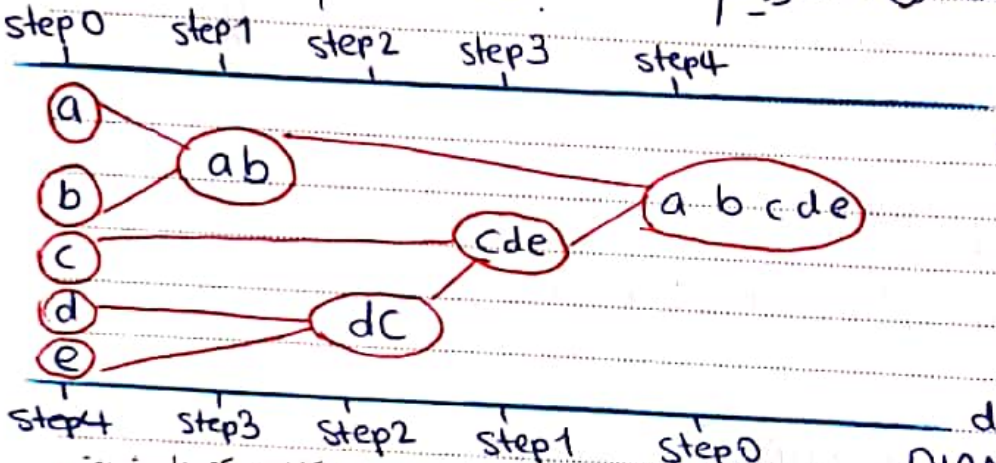
جلسه بیست و یکم ۱۴۰۰/۳/۴

الگوریتم های سلسله مراتبی (Hierarchical)

۲ تا حالت دارند: ① حالت bottom_up (Agglomerative) ← خوشه های کوچکتر را باهم ترکیب می کند و خوشه های بزرگتری می سازد

② حالت Divisive (top_down) ← خوشه بزرگ را به خوشه های کوچکتری می شکاند

الگوریتم AGNES ← برای حالت اول و الگوریتم DIANA برای حالت دوم



درگذشت دکتر علی شریعتی

توضیح چپ به راست:

در step1 نزدیکترین ها هم a و b بودند و باهم ترکیب شده اند

در step2 c و d نزدیکترین بوده اند

در step3 فاصله بین c و de کمترین بوده و کلاستر cde ساخته شده

در step4 ab و cde هم نزدیک بوده اند و تمام داده ها ۱ خوشه شده اند

خرداد ۳۰ جمعه

۲۷ شوال ۱۴۴۱

19 June 2020

در شکل بالا وقتی از چپ به راست می رویم واریانس کم و بایاس زیادی می شود. یعنی مقدار خوشه کم

high variance ⟵ ⟶ high bias

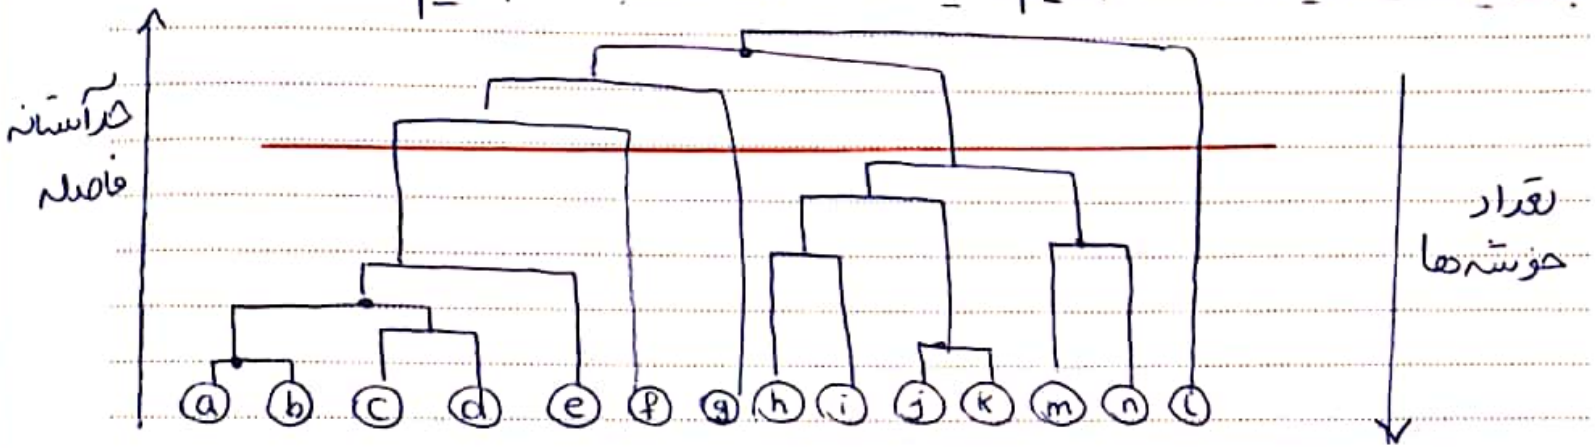
باعث بایاس زیاد و مقدار خوشه زیاد باعث واریانس زیادی می شود

فاصله ab با cd را با معیار مختلفی می توان سنجید. مثلا فاصله میانگین ها یا فاصله نزدیکترین دو تا داده.

Scanned with CamScanner

Dendrogram

برای اینکه به معیاری داشته باشیم از اینکه خوشه بندی را تا کجا ادامه بدهیم، استفاده می‌شود.



مرحله بعدی این است که از یک تریشولدی عمودار بالا را تعیین کنیم، آن‌هایی که بالای خط بیفتند ارتباطاتشان شکسته می‌شود و آن‌هایی که پایین باشند حفظ می‌شوند

نکته: الگوریتم‌های سلسله مراتبی DBSCAN نیاز به تعیین k (تعداد خوشه‌ها) ندارند ولی در سلسله مراتبی با تعیین threshold به طور ضمنی داریم تعداد خوشه‌ها را کنترل می‌کنیم

Scanned with CamScanner

فاصله‌ی بین دو تا کلاستر:

① Single Link: فاصله‌ی نزدیک‌ترین دو عضو از دو کلاستر

$$D(C_1, C_2) = \min(x_1, x_2)$$

② Complete Link: فاصله‌ی دورترین عنصر دو کلاستر

$$D(C_1, C_2) = \max(x_1, x_2)$$

③ Average Link: میانگین فاصله‌ی تمام جفت‌ها (average all pairwise distances)

این فاصله کمتر توسط outlierها تحت تأثیر قرار می‌گیرد (robust است)

④ Centroids: فاصله‌ی بین مراکز (mean) خوشه‌ها

⑤ روش Ward: مجموع انحراف‌ها از Centroid

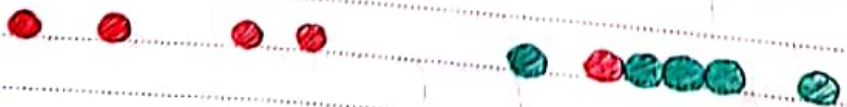
هرچقدر کوچک‌تر باشد، برای merge کردن بهتر است.

Model based Approach

مثال: EM clustering (Expectation_Maximization) ← سعی می‌کند با استفاده از مجموعه‌ای از توزیع‌های نرمال (گوسی) داده‌ها را خوشه‌بندی کند.

روش k_means زیرمجموعه‌ای از EM است.

Case1: فرض کنید دو شکل زیری داریم که کدام داده‌ها از توزیع قرمز و کدام از توزیع سبز آمده‌اند اما پارامترهای توزیع را نمی‌دانیم. (این را هم می‌دانیم که هر دو توزیع نرمال‌اند) با استفاده از این اطلاعات می‌توانیم یک سری اطلاعات دیگر مثل میانگین داده‌ها را بفهمیم.



Scanned with CamScanner

مثلا برای داده های قرمز میانگین

و واریانس را می‌توانیم حساب کنیم:

$$\mu_b = \frac{x_1 + x_2 + \dots + x_{n_b}}{n_b}$$

$$\sigma_b^2 = \frac{(x_1 - \mu_b)^2 + \dots + (x_n - \mu_b)^2}{n_b}$$

(هم چنین برای داده های سبز)

Case 2: تعداد داده داریم و نمی دانیم هرکدام از چه توزیعی است (سبز یا قرمز). اما پارامترهای توزیع‌های گوسی را می دانیم.



از قانون بیز می‌توانیم استفاده کنیم و بفهمیم هر داده‌ای متعلق به کدام توزیع است:

$$P(b|x_i) = \frac{P(x_i|b)P(b)}{P(x_i|b)P(b) + P(x_i|a)P(a)}$$

$$P(x_i|b) = \frac{1}{\sqrt{2\pi\sigma_b^2}} \exp\left\{-\frac{(x_i - \mu_i)^2}{2\sigma_b^2}\right\}$$

این Case 1 و Case 2 در واقع همان Expectation و Maximization هستند

الگوریتم EM:

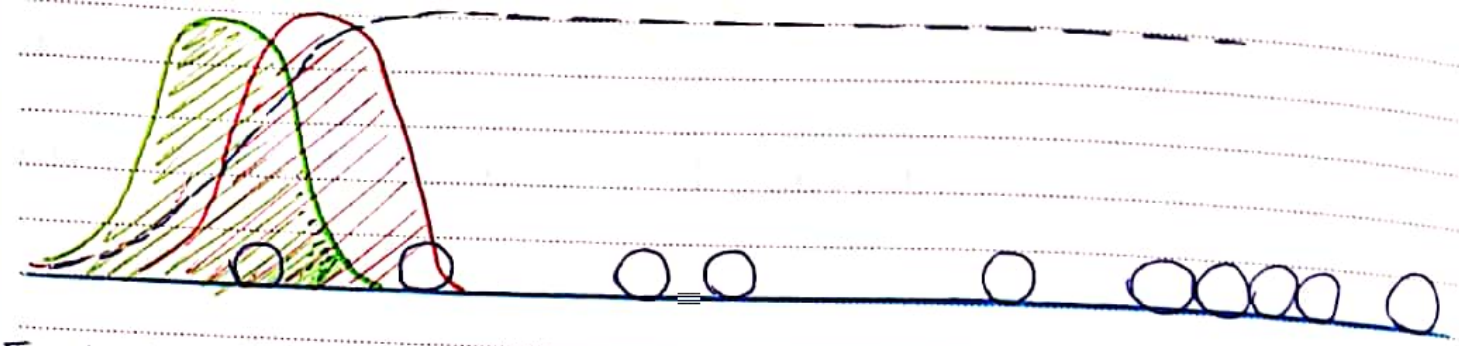
۱ ـ تا توزیع گاوسی را به صورت تصادفی انتخاب می‌کنیم

۲ ـ این دو مرحله را آنقدر تکرار می‌کنیم تا به همگرایی برسیم:

الف) با استفاده از توزیع‌ها سعی می‌کنیم بفهمیم هر داده از کدام خوشه آمده ← E-step (case 2)

ب) پارامترها را tune (تنظیم) می‌کنیم تا بهتر روی داده‌ها بنشیند ← M-step (case 1)

Scanned with CamScanner



Initialazation

در تکرار مراحل سعی داریم که این توزیع ها را

بهتر به داده ها فیت کنیم.

همین طور به سمت جلو می رویم احتمال تعلق هر داده به توزیع سبز و قرمز را حساب می کنیم و هر کدام

بیشتر بود داده به آن رنگ در می آید. این مثالی از soft computing است چون خوشه ها

هم پوشانی دارند

(شکل های بهتر در اسلایدها هست)

نکته: مقداردهی اولیه روی EM خیلی تاثیرگذار است و به آن حساس است. یعنی توزیع هایی که

در ابتدا انتخاب می کنیم خیلی مهم اند.

K را چگونه انتخاب می کنند؟ شبیه به روش Elbow را می توانیم این جا هم داشته باشیم.

Scanned with CamScanner

ارزیابی کیفیت خوشه بندی

دو روش وجود دارد: ① extrinsic (بیرونی) ② intrinsic (درونی)

extrinsic ← با نظارت، یک خوشه بندی مشخص از ابتدا وجود دارد و ما نتایج را با آن مقایسه می‌کنیم (ground truth داریم) ← حالت سر راست و راحتی است

intrinsic ← بدون نظارت

برچسب ها را در اختیار نداریم و باید بسنجیم چقدر داده ها خوب از هم جدا شده.

مثلا با آنتروپی یا خلوص. Entropy (purity).

نکته: دقت کنید که خوشه بندی unsupervised است ولی به منظور ارزیابی از این ایده ها بهره می‌بریم.

معیارهایی برای ارزیابی clustering:

① cluster homogenity

هرچقدر کلاستر خالص تر باشد بهتر است

② cluster Completness

داده ها را به همان کلاسترهایی که در ground truth ذکر شده، تخصیص بدهد

③ Rag bag

قرار دادن یک داده ناهمگون در یک خوشه‌ی خالص (pure) باید جریمه‌ی بیشتری از قرار دادن آن در یک Rag bag داشته باشد. Rag bag به معنای دسته‌ی "others" است

④ small cluster preservation

شکاندن یک خوشه‌ی کوچک به خوشه‌های کوچکتر ضرر بیشتری از شکاندن یک خوشه بزرگ به چند خوشه دارد.

Scanned with CamScanner

Clustering Quality

1) User inspection → خودکار خوشه‌ها را مشاهده می‌کند و بیان می‌کند که خوب هستند یا نه. بیشتر در کاربردهای تجاری مورد قبول است. اگر تجربه از این روش خوب است.

2) sum of squared error : $SSE = \sum_{j=1}^{k} \sum_{x \in C_j} \|x - \mu_j\|^2$

3) Entropy : $E_{total}(\Omega) = \sum_{w \in \Omega} \frac{m_w}{m} \times E(w)$

میزان خلوص خوشه‌ها

4) Silhouette Index

آنتروپی خوشه‌بندی:

$$E_{total}(\Omega) = \sum_{w \in \Omega} \frac{m_w}{m} \times E(w)$$

مجموعه‌ی کلاسترها ← $\Omega = \{w_1, w_2, \dots, w_k\}$

m_w ← تعداد نقاط در خوشه‌ی w

m ← تعداد کل نقاط

آنتروپی یک خوشه:

$$E(w) = -\sum_{c \in C} \frac{|w_c|}{m_w} \times \log_2 \frac{|w_c|}{m_w}$$

C ← کلاستر مورد نظر ما در مجموعه‌ی همه‌ی کلاسترها (C)

$|w_c|$ ← تعداد داده‌هایی که در کلاستر w هستند به عنوان C، classify شده‌اند

تیر ۶ | جمعه

۴ ذی القعده ۱۴۴۱

26 June 2020

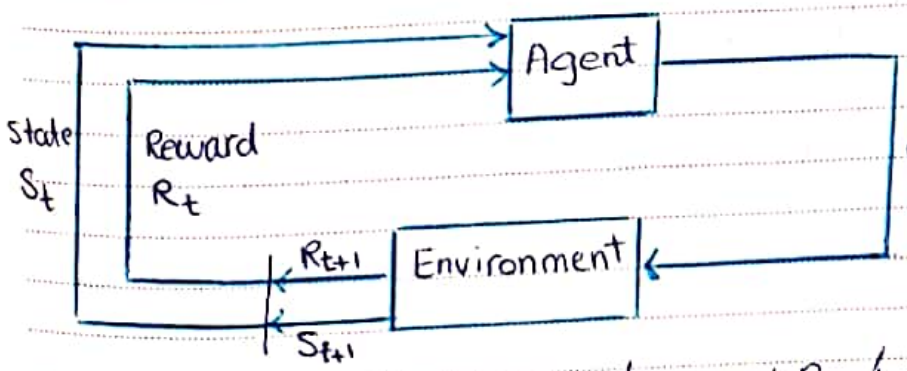
Scanned with CamScanner

جلسه بیست و دوم - ۱۴۰۰/۳/۹

یادگیری تقویتی (Reinforcement Learning)

یادگیری تقویتی	یادگیری بدون نظارت	یادگیری با نظارت
یک فیدبک یا تابع ارزش از محیط می‌گیریم به صورت سیگنال عددی است (Numeric reward signals)	هیچ label ای نداریم	برای هر ورودی label داریم
از روی تعامل با محیط یاد می‌گیریم	از روی داده‌هایی که برچسب ندارند، مثلا شباهتشان، یاد می‌گیریم	از روی مثال‌های برچسب خورده یاد می‌گیریم
Sequential decision making مجموعه‌ای از تصمیم‌ها باید بگیریم	one shot decision making مثلا یه داده میاد و یکه داده باید بره داخل این خوشه، برچسب زدن نوعی تصمیم‌گیری است	one shot decision making مثلا یک عکس داریم و باید تصمیم بگیریم متعلق به کدام دسته است

مثال از Delayed feedback ← بازی شطرنج، مثلا یک بازیکن در حرکت ۶۰ ام یک اشتباه می‌کند و بازیکن دیگر بازی را به دست می‌گیرد و در حرکت ۶۵ ام برنده می‌شود. یعنی سیگنال و فیدبک حرکت ۶۰ ام در حرکت ۶۵ ام می‌رسد. این جا بازیکن اول یک سیگنال منفی در حرکت ۶۵ ام می‌گیرد و زودتر هم نمی‌توانست بگیرد



یک عامل داریم که یک کار (action) را در زمان t انجام می‌دهد و یک محیط هم داریم که یا پاداش می‌دهد یا جریمه می‌کند. یک R یا جریمه، مقطعی است (immediate Reward) هدف این نیست که پاداش‌های لحظه‌ای زیاد دریافت کنیم بلکه هدف

Scanned with CamScanner

این است که در درازمدت پاداش‌ها یا جایزه maximum شوند.

در اثر انجام action در زمان t یک پاداش لحظه‌ای می‌گیریم و می‌رویم به S_{t+1}

هدف این است که agent یک خط‌مشی را یاد بگیرد به این معنی که در هر زمان (t) و با توجه به هر موقعیتی ($\pi_t(S,a)$) که تابعی از حالت و زمان است می‌خواهد یاد بگیرد که چه کنشی را باید انجام بدهد

$\pi_t(S,a) =$ احتمال اینکه در زمان $\underbrace{t}$ action $\underbrace{a}_{A_t=a}$ را انتخاب کنیم در حالی که در $\underbrace{S}_{S_t=S}$ state هستیم

Complications

۱ خروجی کنش (action) ای که انجام می‌دهید ممکن است مشخص نباشد (Stochastic باشد) مثلا ممکنه بخواهید ربات در یک جهتی حرکت اما باتری اش تمام شده باشد.

۲ ممکن است مشخصات جهان پیرامون را به طور کامل نتوانید درک کنید، نمی‌توانید با چند تا حرکت کلیت آن سیستم را درک کنید

۳ Reward هم مثل خروجی stochastic است

۴ فیدبک با تأخیر به دستتان می‌رسد (مثلا موشی در یک maze به دنبال غذا است در نهایت ممکنه برسه یا نرسه)

۵ اینکه جهان پیرامونتان چگونه به شما فیدبک می‌دهد کاملا در حالت‌های مختلف برای شما نامشخص است (black box)

۶ سیگنال Reward را اطلاعاتی نداریم که چگونه تولید می‌شود

۷ محیط ممکن است داینامیک باشد (مثلا رانندگی - اتومبیل‌های خودران)

۸ exploration در مقابل exploitation ← چه مدت زمان لازمه تا عامل مان یاد بگیرد؟

Scanned with CamScanner

Returns

مجموعه‌ی پاداش‌هایی که از زمان t به بعد دریافت می‌کنیم: $R_{t+1}, R_{t+2}, R_{t+3}, \dots$

هدف: امید ریاضی از زمان t به بعد را max کنیم

$$\text{maximize } E(R_t)$$

Discounted Return

$$G_t = R_{t+1} + \gamma R_{t+2} + \gamma^2 R_{t+3} + \dots = \sum_{k=0}^{\infty} \gamma^k R_{t+k+1}$$

$0 \leq \gamma < 1$, γ is discount rate

برای اینکه همگرا شود ضریب γ را اضافه کرده‌ایم

همچنین برای اینکه به هر پاداش وزن خاصی بدهیم و در نهایت G_t را طوری خواهیم max کنیم. اگر γ مقدارش زیاد باشد یعنی agent آینده‌نگر است

ویژگی مارکف (Markov property)

$$p(S_{t+1}=s', R_{t+1}=r \mid a_t, s_t, r_t, a_{t-1}, s_{t-1}, \dots, r_1, a_0, s_0)$$

$$= p(S_{t+1}=s', R_{t+1}=r \mid s_t, a_t)$$

یعنی می‌توانیم بگوییم فقط وابسته به state قبلی است و می‌توانیم بگیم از قبلی‌هاش مستقل است.

بنابراین فرض می‌کنیم که ویژگی مارکف برقرار است و مسئله را به صورت Markov Decision Process (MDP) در نظر می‌گیریم. برای تعریف MDP به این موارد نیاز است:

① مجموعه‌ی حالت‌ها و اکشن‌ها (کارهایی که می‌توانیم انجام بدهیم) ← states and actions

② احتمال انتقال از یک حالت به حالت دیگر:

$$T(s, a, s') = p(S_{t+1}=s' \mid S_t=s, A_t=a) \quad \forall s, s' \in S, \ a \in A(s)$$

③ احتمالات مربوط به پاداش‌ها: در حالت s با انجام a به state s' می‌رویم چه پاداشی می‌گیریم

$$R(s, a, s') = E[S_t=s, A_t=a, S_{t+1}=s']$$

$$\forall s, s' \in S, \ a \in A(s)$$

Scanned with CamScanner

value and Q Functions

مجموعه‌ای از Value Function ها را می‌خواهیم یاد بگیریم که متناظر با ارزش آن حالت هستند.
به ازای تمام حالت‌های مسئله اگر Value Function شان را پیدا کنیم خط مشی یا policy مسئله را یاد گرفته‌ایم. پس دفعه‌ی بعد که می‌خواهیم مسئله را حل کنیم می‌دانیم که هر کنش چه پاداشی را در درازمدت به همراه خواهد داشت

$$v_{\pi}(s) = E_{\pi}[G_t | S_t = s] = E_{\pi}\left[\sum_{k=0}^{\infty} \gamma^k R_{t+k+1} \mid S_t = s\right]$$

(policy ↗)

Value ← امید ریاضی پاداش‌هایی که با شروع از آن حالت دریافت می‌کنیم

q ← امید ریاضی پاداش‌هایی که با شروع از حالت s و انجام action a دریافت می‌کنیم

$$q_{\pi}(s,a) = E[G_t | S_t = s, A_t = a] = E_{\pi}\left[\sum_{k=0}^{\infty} \gamma^k R_{t+k+1} \mid S_t = s, A_t = a\right]$$

Bellman Equation for policy ↗

$$G_t = R_{t+1} + \gamma R_{t+2} + \gamma^2 R_{t+3} + \gamma^3 R_{t+4} \dots$$

$$= R_{t+1} + \gamma(R_{t+2} + \gamma R_{t+3} + \gamma^2 R_{t+4} + \dots) = R_{t+1} + \gamma G_{t+1}$$

$$v_{\pi}(s) = E_{\pi}[G_t | S_t = s] = E_{\pi}[R_{t+1} + \gamma v(S_{t+1}) \mid S_t = s]$$

$$v_{\pi}(s) = \sum_a \pi(s,a) \sum_{s'} p(s'|s,a)\left[R(s,a,s') + \gamma v_{\pi}(s')\right]$$

- $\pi(s,a)$: احتمال اتخاذ action a در حالت s
- $p(s'|s,a)$: حالتی که بعد از انتخاب a از s به آن وارد می‌شویم
- $R(s,a,s')$: پاداش لحظه‌ای که در s' دریافت می‌کنیم
- $\gamma v_{\pi}(s')$: مجموعه‌ی پاداش‌هایی که از s' به بعد دریافت می‌کنیم

روز صنعت و معدن

Scanned with CamScanner

برای یک مسئله MDP میشه optimal policy رو پیدا کرد

optimal value function:

$$v^*(s) = \max_{\pi} v^{\pi}(s) \quad \forall s \in S$$

optimal q function:

$$q^*(s,a) = \max_{\pi} q^{\pi}(s,a) \quad \forall s \in S, a \in A(s)$$

$$v^*(s) = \max_{a \in A(s)} \sum_{s'} p(s'|s,a)\left[R(s,a,s') + \gamma v^*(s')\right]$$

$$q^*(s,a) = \sum_{s'} p(s'|s,a)\left[R(s,a,s') + \gamma \max_{a'} q^*(s',a')\right]$$

optimal policy:

$$\pi^*(s) = \arg\max_{a \in A(s)} \sum_{s'} p(s'|s,a) v^*(s')$$

$$\pi^*(s) = \arg\max_{a \in A(s)} q^*(s,a)$$

یک مسئله یادگیری تقویتی را با روش های مختلفی می توان انجام داد از جمله v و q.

اگر با v حل کنیم ← Value Iteration Algorithm

در ابتدا $v_0^*(s) = 0$ ← چون در مرحله اول اطلاعاتی نداریم و مقادیر اولیه state ها یکسان است

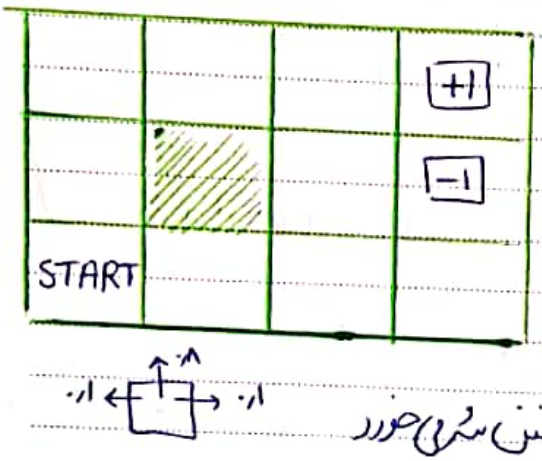
به صورت تکراری حلوی رویم و آنرا update می‌کنیم:

$$v_{i+1}(s) \leftarrow \max_a \sum_{s',r} p(s',r|s,a)[r+\gamma v_i(s')]$$

به این رابطه value update یا Bellman update گفته می‌شود

آن قدر آن را تکرار می‌کنیم تا به همگرایی برسیم

مثال: Grid World یک عامل داریم از خانه START آغاز می‌کند و می‌خواهد به خانه بالا راست برسد



اگر به خانه ۱- برسد یعنی باخته است، به خانه دیوار نمی‌تواند وارد شود. اگر بخواهد در جهتی حرکت کند به احتمال ۸۰ درصد به آن جهت می‌رود و به احتمال ۱۰ درصد و ۱۰ درصد به طرفین سُر می‌خورد

اگر بخواهد به سمت دیوار برود از جای خودش تکان نمی‌خورد.

بین agent ای که در محیط پرسه می‌زند و بعد به هدف می‌رسد و agent ای که مستقیم به هدف می‌رسد باید تفاوت قائل شویم. به همین دلیل از living Reward استفاده می‌کنیم. به ازای هر حرکتش یک جریمه

$$R(s) = -0.02$$

خیلی کم برایش در نظر می‌گیریم که کارش را سریع کند.

state های ۱+ و ۱-، state های جاذب هستند.

هدف max کردن مجموعه پاداش هاست.

$\gamma = 0.9$ ← agent همان آینده نگر است

(ادامه در اسلاید ۴ + توضیح استاد)

روز افشای حقوق بشر آمریکایی

۱۳ تیر جمعه

۱۱ ذی القعده ۱۴۴۱

3 July 2020

ولادت امام رضا (ع) (۱۴۸ هـ ق)

Scanned with CamScanner

جلسه بیست و سوم - ۱۴۰۰/۳/۱۱

ارزش یا Value حالت های خاص صفر است اما immediate Reward شان زیاد است

حالت های جاذب یا terminal state ها

حل مثال جلسه قبل:

۰	۰	۰/۷۹۶	+1
۰		۰	-1
۰	۰	۰	۰

$$(0/8)(1+(0/9)\times 0)+(0/1)(-0/02+(0/9)\times 0)+(0/1)(-0/02+(0/9)\times 0)$$

$$=0/8-0/002-0/002=0/796$$

الان مقدار خانه ی $\langle 3,3\rangle$ نسبت به مرحله قبل افزایش پیدا کرده چون در صورتی که به بالا برویم با برخورد به دیواره دوباره به همان خانه $\langle 3,3\rangle$ برمی گردیم که مقدار ۰/۷۹۶ در آن است به جای ۰. بنابراین مقدار این خانه افزایش پیدا می کند

۰	۰/۵۵۳	۰/۸۶۷	+1
۰		۰/۴۵۵	-1
۰	۰	۰	۰

$$V_2(\langle 3,3\rangle)=0/8(1+0/9\times 0)+0/1(-0/02+0/9\times 0/796)+0/1(-0/02+0/9\times 0)$$

$$=0/8+0/07164-0/002=0/87964$$

Policy Iteration

تا الان در مورد Value Iteration گفتیم اما می توانیم

policy iteration هم داشته باشیم. وقتی محیط پیوسته است بهتر است از Policy Iteration استفاده کنیم

Scanned with CamScanner